



UNIVERSIDAD TÉCNICA PARTICULAR DE LOJA

La Universidad Católica de Loja

FACULTAD DE INGENIERÍAS Y ARQUITECTURA

MAESTRÍA EN INTELIGENCIA ARTIFICIAL APLICADA

**Desarrollo de un prototipo móvil para la lectura de
medidores de agua potable usando técnicas de
procesamiento de imágenes**

Trabajo de titulación previo a la obtención del título de:

MAGÍSTER EN INTELIGENCIA ARTIFICIAL APLICADA

Autor: Pillaga Zhagñay, Luis Antonio

Director: Riofrio Calderón, Guido Eduardo

LOJA

2025

Aprobación del director del Trabajo de Titulación

Loja, 15 de febrero de 2025

Doctor

Luis Rodrigo Barba Guamán

Director de la maestría de Inteligencia Artificial Aplicada

Loja.-

De mi consideración:

Me permito comunicar que, en calidad de director del presente Trabajo de Titulación nominado: Desarrollo de un prototipo móvil para la lectura de medidores de agua potable usando técnicas de procesamiento de imágenes realizado por Luis Antonio Pillaga Zhagñay ha sido orientado y revisado durante su ejecución, así mismo ha sido verificado a través de la herramienta de similitud académica institucional, y cuenta con un porcentaje de coincidencia aceptable. En virtud de ello, y por considerar que el mismo cumple con todos los parámetros establecidos por la Universidad, doy mi aprobación a fin de continuar con el proceso académico correspondiente.

Particular que comunico para los fines pertinentes.

Atentamente,

Director: Guido Eduardo Riofrio Calderón, PhD.

C.I.: 1103214969

Correo electrónico: geriofrio@utpl.edu.ec

Declaración de autoría y cesión de derechos

Yo, Luis Antonio Pillaga Zhagñay, declaro y acepto en forma expresa lo siguiente:

Ser autor del Trabajo de Titulación denominado: Desarrollo de un prototipo móvil para la lectura de medidores de agua potable usando técnicas de procesamiento de imágenes, de la maestría en Inteligencia Artificial Aplicada, específicamente de los contenidos comprendidos en: Introducción, Capítulo 1: Marco Teórico, Capítulo 2: Metodología, Capítulo 3: Desarrollo y Resultados, Conclusiones y Recomendaciones, siendo Guido Eduardo Riofrio Calderón, director del presente trabajo; también declaro que la presente investigación no vulnera derechos de terceros ni utiliza fraudulentamente obras preexistentes. Además, ratifico que las ideas, criterios, opiniones, procedimientos y resultados vertidos en el presente trabajo investigativo, son de mi exclusiva responsabilidad. Eximo expresamente a la Universidad Técnica Particular de Loja y a sus representantes legales de posibles reclamos o acciones judiciales o administrativas, en relación a la propiedad intelectual de este trabajo.

Que la presente obra, producto de mis actividades académicas y de investigación, forma parte del patrimonio de la Universidad Técnica Particular de Loja, de conformidad con el artículo 20, literal j), de la Ley Orgánica de Educación Superior; y, artículo 91 del Estatuto Orgánico de la UTPL, que establece: “Forman parte del patrimonio de la Universidad la propiedad intelectual de investigaciones, trabajos científicos o técnicos y tesis de grado que se realicen a través, o con el apoyo financiero, académico o institucional (operativo) de la Universidad”, en tal virtud, cedo a favor de la Universidad Técnica Particular de Loja la titularidad de los derechos patrimoniales que me corresponden en calidad de autor/a, de forma incondicional, completa, exclusiva y por todo el tiempo de su vigencia.

La Universidad Técnica Particular de Loja queda facultada para ingresar el presente trabajo al Sistema Nacional de Información de la Educación Superior del Ecuador para su difusión pública, en cumplimiento del artículo 144 de la Ley Orgánica de Educación Superior.

Autor: Luis Antonio Pillaga Zhagñay

C.I.: 0301971495

Correo electrónico: lapillaga2@utpl.edu.ec

Dedicatoria

Este trabajo representa el fruto de años de esfuerzo, dedicación y el apoyo incondicional de personas muy especiales en mi vida. Con profundo cariño y gratitud, dedico este logro:

A mi madre Julia Zhagñay, por cada una de sus palabras de aliento durante todos mis años de estudio. Su apoyo incondicional ha sido mi fortaleza, y agradezco profundamente su mejor legado: el valor de siempre procurar ser una buena persona.

Para mi segunda madre, Evangelina Dután, quien con un corazón inmenso y sin necesidad de lazos de sangre, siempre cuidó de mí. Aunque hoy ya no estás, siento que desde el cielo continúas guiando mis pasos.

A mi nueva familia, Lesly y Luis Nicolás, por ser la inspiración y la fuerza que necesitaba para dar este importante paso. Su apoyo y paciencia han sido el pilar fundamental para poder terminar este trabajo.

Finalmente, extendiendo mi gratitud a cada ser humano que ha formado parte de mi camino, aportando a mi crecimiento personal y profesional.

Agradecimiento

TODO

Índice de contenido

Carátula	I
Aprobación del director del Trabajo de Titulación.....	I
Declaración de autoría y cesión de derechos	II
Dedicatoria	III
Agradecimiento	IV
Resumen	1
Abstract.....	2
Introducción.....	3
1 Introducción	4
1.1 Contextualización del problema: el agua y saneamiento en el sector rural.....	4
1.2 Problemática	4
1.3 Justificación	5
1.4 Objetivos.....	6
1.4.1 Objetivo general	6
1.4.2 Objetivos específicos	6
1.5 Alcance y limitaciones	7
1.5.1 Alcance del proyecto.....	7
1.5.2 Limitaciones de la investigación.....	7
1.6 Estructura del documento.....	8
2 Estado del arte	10
2.1 Contexto global y local de la gestión del agua potable.....	10
2.1.1 Acceso al agua y saneamiento como objetivo de desarrollo sostenible (ODS 6)	10
2.1.2 El desafío de la gestión comunitaria en zonas rurales de América Latina...	11
2.1.3 El rol de las JAAPS en Ecuador: desafíos operativos y la brecha tecnológica	11
2.2 Paradigmas de medición: de la lectura manual a la medición inteligente	13
2.2.1 Medidores tradicionales (analógicos y digitales) vs. medidores inteligentes (smart meters)	13
2.2.2 Ineficiencias y costos de los sistemas de lectura manual.....	14

2.2.3	El mercado del “smart metering” y la oportunidad para soluciones alternativas	15
2.3	Datasets y aumento de datos como fundamento para el AMR	16
2.3.1	Análisis de datasets públicos para AMR	16
2.3.2	Metodología de adquisición y anotación de datos de campo	17
2.3.3	Desafíos inherentes a la creación de datasets propios	18
2.3.4	Estrategias de aumento de datos para mejorar la robustez	19
2.4	Visión por computadora aplicada a la lectura automatizada de medidores (AMR) ..	19
2.4.1	Fundamentos del pipeline de detección-reconocimiento	19
2.4.2	El desafío de la detección: de cajas delimitadoras a la segmentación semántica.....	21
2.4.3	Técnicas de preprocesamiento de imágenes para escenarios reales	21
2.5	Reconocimiento óptico de caracteres (OCR) en el contexto de AMR.....	22
2.5.1	Evolución de enfoques: de métodos clásicos a deep learning	22
2.5.2	Análisis comparativo de arquitecturas neuronales para OCR en medidores	23
2.6	Habilitadores tecnológicos para el despliegue en dispositivos móviles (edge AI)...	25
2.6.1	Requerimientos del procesamiento en el borde: latencia, memoria y consumo energético.....	25
2.6.2	Arquitecturas optimizadas y frameworks (TensorFlow Lite).....	26
2.6.3	Técnicas de optimización: cuantización y transferencia de aprendizaje.....	26
2.7	Desarrollo de aplicaciones móviles para la captura y gestión de datos en campo ..	28
2.7.1	Arquitecturas de software para aplicaciones “offline-first”	28
2.7.2	Frameworks de desarrollo: nativo (Kotlin) vs. multiplataforma (Flutter)	29
2.7.3	Integración práctica de modelos TFLite en Android.....	30
2.7.4	UI/UX para captura guiada y usabilidad en campo	31
2.8	Desafíos técnicos en los ambientes rurales de la sierra ecuatoriana.....	32
2.8.1	Impacto de las condiciones variables de iluminación y oclusión por suciedad/humedad.....	32
2.8.2	El problema de los dígitos en transición (“rolling digits”).....	33
2.8.3	La necesidad del procesamiento offline ante la conectividad intermitente ..	34
2.9	Análisis comparativo de investigaciones clave	34
2.10	Resultados: brecha identificada y oportunidades para el proyecto	37

2.10.1 Tendencias actuales y futuras en la automatización de lectura de medidores	37
2.10.2 El vacío existente: la falta de soluciones validadas para el contexto específico de las JAAPS	38
2.10.3 Justificación del enfoque propuesto a la luz del estado del arte	39
Referencias	40

Índice de tablas

2.1	Comparativa de Tecnologías de Medición de Agua.	14
2.2	Comparativa de Arquitecturas de OCR para Lectura de Medidores.	24
2.3	Análisis comparativo de investigaciones previas en AMR.....	36

Índice de figuras

2.1	Ejemplo de medidor de agua en un entorno rural no controlado, similar a los encontrados en el área de estudio. La exposición a la intemperie, la suciedad y el desgaste son desafíos comunes para los sistemas de lectura por visión artificial.	12
2.2	Ejemplos de la diversidad de medidores y condiciones en diferentes datasets públicos. (a) Medidor electromecánico en un escenario no controlado (Laroca et al., 2021). (b) Medidor de diales (Salomon et al., 2022). (c) Medidor digital de multímetro (Peng et al., 2023).	17
2.3	Flujo de trabajo metodológico para la adquisición y anotación de un dataset de campo.	18
2.4	Diagrama de flujo del pipeline de dos etapas para AMR.	20
2.5	Flujo de trabajo para la optimización de un modelo de deep learning para su despliegue en dispositivos móviles mediante TensorFlow Lite.	28
2.6	Diagrama de una arquitectura de software moderna para Android con enfoque “offline-first”, mostrando la separación de responsabilidades y el flujo de datos.	29
2.7	Mapa mental que categoriza los principales desafíos para la lectura automática de medidores en entornos no controlados.	33

Resumen

El resumen se presentará en un único párrafo con un máximo de **180 palabras**, sintetiza el aporte que brinda el trabajo realizado. **Obligatoriamente** debe contener las palabras clave (**máximo tres**).

Ejemplo:

TODO

Palabras clave: xxxxxxxxx, xxxxxxxx, xxxxxx.

Abstract

Abstract es el resumen traducido al idioma inglés en donde se incluyen las palabras claves.

Obligatoriamente debe contener las palabras claves (**máximo tres**).

Ejemplo:

TODO

Keywords: xxxxxxxxxx, xxxxxxxx, xxxxxx.

Introducción

Se sugiere presentar en máximo **dos páginas** y considerar los siguientes puntos:

Capítulo uno

Introducción

1.1 Contextualización del problema: el agua y saneamiento en el sector rural

El acceso a agua potable y saneamiento constituye un derecho humano fundamental, reconocido como una piedra angular para el desarrollo sostenible, la salud pública y la prosperidad económica. La comunidad internacional ha ratificado su importancia a través de la Agenda 2030, donde el Objetivo de Desarrollo Sostenible 6 (ODS 6) insta a "garantizar la disponibilidad y la gestión sostenible del agua y el saneamiento para todos" (Naciones Unidas, 2015). A pesar de los avances globales, persisten brechas significativas, especialmente en las zonas rurales de países en desarrollo, donde las comunidades a menudo dependen de modelos de gestión descentralizados y comunitarios para la prestación de estos servicios esenciales.

En América Latina, y particularmente en Ecuador, la gestión del agua en zonas rurales recae sobre las Juntas Administradoras de Agua Potable y Saneamiento (JAAPS), la estructura legalmente reconocida para esta función. Se estima que más de 5,000 de estas organizaciones operan en el país y cumplen un rol esencial que el Estado no siempre puede asumir, dando servicio a una parte importante de la población rural. Su trabajo va más allá del suministro de agua, pues también fortalece la cohesión social y la gestión local de los recursos naturales. Por ello, mejorar la capacidad operativa de este modelo de gestión democrática significa robustecer directamente a las instituciones comunitarias y su resiliencia.

A pesar de su importancia, la sostenibilidad de estas organizaciones es un desafío. Aunque son efectivas para ampliar la cobertura, sus constantes limitaciones técnicas, financieras y administrativas comprometen su futuro a largo plazo. Esta situación se agrava por la falta de herramientas tecnológicas diseñadas para un entorno de recursos limitados y brechas de conocimiento técnico, lo que pone en riesgo la calidad del servicio. Este trabajo de titulación se enfoca, precisamente, en buscar una solución tecnológica que fortalezca a estas organizaciones, mejorando tanto su gestión como su autosuficiencia.

1.2 Problemática

Aunque las JAAPS son un pilar para el agua rural, su operación tradicional sufre de ineficiencias críticas que amenazan tanto su sostenibilidad financiera como la confianza de los usuarios. El principal problema se concentra en la toma de lecturas, un proceso manual que es clave para la facturación. El método actual, que obliga a un operario a transcribir a papel los

datos de cada medidor, es por naturaleza lento y propenso a errores humanos que generan *pérdidas comerciales* (Chaki et al., 2019). Estos fallos en la lectura y el manejo de datos, conocidos como pérdidas aparentes, subvaloran el consumo real y resultan en facturas incorrectas que afectan directamente los ingresos de la junta (Agencia de Cooperación Internacional del Japón (JICA), 2025).

Las cifras del problema son preocupantes. El Agua No Contabilizada (ANC), que mide tanto fugas como pérdidas comerciales, promedia un 51.8 % a nivel nacional en sistemas municipales, y se estima que la cifra es mayor en los sistemas comunitarios (Instituto Nacional de Estadística y Censos (INEC), 2024). A estas imprecisiones se suman los retos logísticos: el personal de las JAAPS debe recorrer áreas dispersas y de difícil acceso, causando demoras. A su vez, la falta de una conexión a internet fiable en estas zonas ha sido una barrera para adoptar soluciones digitales (Fieldeke et al., 2021). Esta “brecha digital” fuerza a las juntas a seguir usando papel, lo que duplica el trabajo de digitación y abre la puerta a más errores.

Estas fallas operativas provocan consecuencias en todo el sistema. Una factura incorrecta reduce la confianza del usuario, lo que puede llevar a una cultura de no pago que afecta la recaudación. Al mismo tiempo, sin datos de consumo fiables, la directiva no puede realizar análisis técnicos clave como el balance hídrico o la detección de fugas, ambos vitales para la sostenibilidad del recurso (Agencia de Cooperación Internacional del Japón (JICA), 2025). Como resultado, se crea un círculo vicioso de ineficiencia que limita la capacidad de las JAAPS para invertir, dar mantenimiento y, en definitiva, asegurar la viabilidad del servicio a largo plazo.

1.3 Justificación

La presente investigación se justifica en tres dimensiones interconectadas que responden directamente a la problemática expuesta.

En primer lugar, desde una perspectiva tecnológica, el proyecto es oportuno y pertinente. Los avances recientes en el campo del aprendizaje profundo (deep learning), específicamente en arquitecturas de redes neuronales convolucionales (CNN) optimizadas para dispositivos de bajos recursos, han abierto la puerta a soluciones que antes eran inviables. El uso de frameworks como TensorFlow Lite permite encapsular modelos de visión por computadora potentes en un formato ligero, capaz de ejecutar la inferencia directamente en un teléfono móvil estándar sin depender de una conexión a internet (Carvalho et al., 2023). Esta capacidad de procesamiento local (edge computing) es precisamente la innovación técnica que permite superar la barrera de la conectividad intermitente, el principal obstáculo para la digitalización

de procesos en las zonas rurales atendidas por las JAAPS.

En segundo lugar, la justificación social y económica es directa y de alto impacto. Al automatizar el proceso de lectura de medidores, el prototipo propuesto tiene el potencial de reducir drásticamente los errores de facturación, incrementando la precisión y, por ende, la recuperación de ingresos para las juntas. Esta optimización de recursos no solo fortalece la sostenibilidad financiera de la organización, sino que también libera tiempo del personal, que puede ser reasignado a tareas críticas de mantenimiento y operación de la red. De esta manera, el proyecto se alinea con la Meta 6.B de la Agenda 2030 para el Desarrollo Sostenible, que promueve explícitamente el apoyo y fortalecimiento de la participación de las comunidades locales en la mejora de la gestión del agua y el saneamiento (Naciones Unidas, 2015).

Finalmente, el proyecto presenta una clara justificación científica. Si bien existen soluciones genéricas de Reconocimiento Óptico de Caracteres (OCR), su rendimiento en condiciones no controladas (“in the wild”) es a menudo deficiente. La contribución de esta tesis radica en el desarrollo y la validación de un pipeline de visión artificial especializado para el dominio específico de los medidores de agua en contextos rurales, los cuales presentan una alta variabilidad de modelos, estados de deterioro, condiciones de iluminación y oclusiones parciales. La investigación aportará un dataset específico para esta tarea y analizará la eficacia de arquitecturas de modelos ligeros y técnicas de *data augmentation* para lograr la alta precisión ($\geq 98\%$) requerida. Por lo tanto, el trabajo no solo resuelve un problema práctico, sino que también contribuye con conocimiento aplicable al campo del OCR en entornos industriales desafiantes y en hardware con recursos limitados.

1.4 Objetivos

1.4.1 Objetivo general

Desarrollar un prototipo móvil para la lectura automática de medidores de agua potable mediante técnicas de procesamiento de imágenes, que permita extraer indicadores de consumo con alta precisión y eficiencia.

1.4.2 Objetivos específicos

1. Realizar una revisión sistemática de literatura para identificar arquitecturas y herramientas que fundamenten el diseño técnico del sistema de lectura de medidores de agua.
2. Desarrollar una aplicación móvil para la captura y procesamiento de imágenes, implementando algoritmos de visión por computadora resistentes a variaciones ambientales, para obtener datos de entrada optimizados para el reconocimiento.

3. Implementar un modelo de Reconocimiento Óptico de Caracteres, utilizando técnicas de aprendizaje automático optimizadas para dispositivos móviles, para extraer con precisión las lecturas numéricas de los medidores.
4. Validar la funcionalidad del prototipo completo, mediante pruebas comparativas en condiciones reales, para demostrar su viabilidad como solución al problema de lectura manual de medidores.

1.5 Alcance y limitaciones

A continuación, se definen las fronteras del presente trabajo de titulación, especificando tanto los entregables y funcionalidades que se desarrollarán, como los aspectos que quedan fuera del estudio.

1.5.1 Alcance del proyecto

El alcance de esta investigación cubre los siguientes puntos:

- El desarrollo de un prototipo funcional de una aplicación móvil para la plataforma Android, capaz de capturar imágenes de medidores de agua.
- La creación de un dataset de imágenes propio, compuesto por fotografías de medidores de agua analógicos, recolectadas en condiciones de campo representativas de las Juntas Administradoras de Agua Potable y Saneamiento (JAAPS) rurales.
- El entrenamiento y la optimización de un modelo de aprendizaje profundo (OCR), específicamente diseñado para la detección y lectura de los dígitos de los medidores de agua, y preparado para su ejecución local en el dispositivo móvil (offline).
- La implementación de una aplicación móvil que captura imágenes de medidores para posteriormente ser procesadas por el modelo de IA, extraer la lectura y registrarla en el dispositivo.
- La validación técnica del prototipo en un entorno de campo controlado, donde se medirá y comparará su precisión y el tiempo de lectura frente al método manual tradicional.

1.5.2 Limitaciones de la investigación

Para mantener el enfoque del proyecto, se establecen las siguientes limitaciones:

- El prototipo no es un sistema de gestión comercial completo. No incluirá funcionalidades avanzadas de facturación, gestión de abonados, o generación de reportes complejos,

aunque su diseño permitirá la integración futura con dichos sistemas.

- El modelo de OCR se especializará en los medidores de tipo analógico (de reloj o dial) identificados en el estudio. No se abordará la lectura de medidores digitales ni de modelos analógicos con características muy atípicas que no formen parte del dataset.
- La aplicación móvil será desarrollada únicamente para el sistema operativo Android.
- La validación se centrará en la viabilidad y el rendimiento técnico (precisión, eficiencia) del prototipo. No se realizará un estudio a largo plazo sobre el impacto socioeconómico de la adopción de la herramienta en las JAAPS.
- El despliegue y las pruebas de campo se realizarán con un número limitado y representativo de JAAPS, por lo que los resultados no pueden ser generalizados a todas las juntas del país sin estudios adicionales de escalabilidad.

1.6 Estructura del documento

El presente trabajo de titulación se articula en seis capítulos, diseñados para presentar la investigación de forma lógica y coherente.

- **Capítulo 1: Introducción.** Presenta la problemática de la lectura manual de medidores en las JAAPS rurales, justificando la solución propuesta y definiendo los objetivos y el alcance del proyecto.
- **Capítulo 2: Estado del Arte.** Analiza la literatura científica sobre gestión del agua, visión por computadora y modelos de OCR optimizados para dispositivos móviles, estableciendo el fundamento teórico del trabajo.
- **Capítulo 3: Metodología.** Detalla el diseño experimental y las fases del proyecto, incluyendo la creación del dataset, la selección y entrenamiento de los modelos de IA, y el protocolo para la validación en campo.
- **Capítulo 4: Desarrollo del sistema.** Describe la implementación técnica del prototipo, detallando la arquitectura del sistema, la optimización del modelo y el desarrollo de la aplicación Android con funcionalidad *offline*.
- **Capítulo 5: Evaluación y resultados.** Expone los resultados cuantitativos de la validación en campo, comparando la precisión y eficiencia del prototipo frente al método manual mediante métricas de rendimiento objetivas.

- **Capítulo 6: Conclusiones y recomendaciones.** Discute los hallazgos de la investigación, extrae las conclusiones sobre la viabilidad de la solución, y propone recomendaciones para trabajos futuros y la escalabilidad del proyecto.

Los capítulos subsiguientes amplían cada uno de estos aspectos, articulando la solución propuesta con el estado actual de la investigación y las necesidades operativas de las JAAPS.

Capítulo dos

Estado del arte

2.1 Contexto global y local de la gestión del agua potable

La gestión eficiente del agua potable es uno de los pilares fundamentales para el desarrollo sostenible, la salud pública y la estabilidad económica a nivel global. Sin embargo, la brecha entre la disponibilidad del recurso y su acceso equitativo y gestionado de manera sostenible sigue siendo un desafío mayúsculo, especialmente en las zonas rurales de países en desarrollo. En este contexto, la innovación tecnológica, y en particular la inteligencia artificial (IA), emerge no como un fin en sí misma, sino como una herramienta catalizadora con el potencial de transformar modelos de gestión comunitarios, superando barreras históricas de eficiencia, transparencia y viabilidad financiera. Esta sección establece el marco contextual de la presente investigación, partiendo de los objetivos globales de sostenibilidad para aterrizar en los desafíos operativos concretos que enfrentan las organizaciones de agua en el Ecuador rural, identificando así la oportunidad para una intervención tecnológica pertinente y de alto impacto.

2.1.1 Acceso al agua y saneamiento como objetivo de desarrollo sostenible (ODS 6)

La comunidad internacional, a través de la Agenda 2030 para el Desarrollo Sostenible, reconoció la centralidad del agua al establecer el Objetivo de Desarrollo Sostenible 6 (ODS 6): “Garantizar la disponibilidad de agua y su gestión sostenible y el saneamiento para todos” (Naciones Unidas, 2015). Este objetivo va más allá de la simple provisión de acceso a una fuente de agua; su núcleo reside en la **gestión sostenible**, un concepto que implica eficiencia en el uso, reducción de pérdidas y la creación de sistemas resilientes y económicamente viables. Es precisamente en este punto donde los modelos de gestión tradicionales, basados en procesos manuales, muestran sus limitaciones más profundas.

La falta de datos precisos y oportunos sobre el consumo y las pérdidas de agua impide una gestión informada. Sistemas de lectura manual, propensos a errores y con largos periodos de recolección, obstaculizan la capacidad de los proveedores para implementar estrategias efectivas de conservación y para asegurar la sostenibilidad financiera del servicio. En el nexo Agua-Energía-Alimentos, la gestión ineficiente del agua tiene efectos en cascada, afectando la seguridad alimentaria y la disponibilidad de energía (Roa-García et al., 2019). Por lo tanto, la modernización de los procesos de medición y facturación no es solo una optimi-

zación operativa, sino una condición necesaria para avanzar hacia el cumplimiento del ODS 6.

2.1.2 *El desafío de la gestión comunitaria en zonas rurales de América Latina*

En vastas regiones de América Latina, la provisión de servicios de agua y saneamiento en áreas rurales dispersas no es asumida directamente por el Estado, sino por organizaciones de base comunitaria (Banco Interamericano de Desarrollo (BID), 2022). Este modelo de gestión, si bien es esencial para garantizar la cobertura, se enfrenta a desafíos estructurales que amenazan su perdurabilidad.

La principal vulnerabilidad de estos sistemas, a menudo operados por voluntarios con recursos limitados y capacidades técnicas en desarrollo, radica en la fragilidad de sus procesos administrativos y comerciales. La ausencia de herramientas tecnológicas para una medición precisa, una facturación automatizada y un cobro eficiente compromete directamente la viabilidad financiera de la organización. Esta carencia limita severamente su capacidad para reinvertir en el mantenimiento correctivo y la expansión de la infraestructura, afectando en última instancia la sostenibilidad y la calidad del servicio a largo plazo (Banco Interamericano de Desarrollo (BID), 2022; Toma et al., 2020).

2.1.3 *El rol de las JAAPS en Ecuador: desafíos operativos y la brecha tecnológica*

En el Ecuador, las Juntas Administradoras de Agua Potable y Saneamiento (JAAPS) son la manifestación concreta del modelo de gestión comunitaria, amparadas por un marco legal que fomenta su creación para suplir la cobertura estatal. Se estima que más de 5,000 de estas juntas proveen servicio a una porción considerable de la población rural (Banco Interamericano de Desarrollo (BID), 2022). Su estructura democrática, basada en el trabajo voluntario de sus directivos, es a la vez su mayor fortaleza social y su principal debilidad operativa (Toma et al., 2020).

El proceso de lectura de medidores ejemplifica claramente estos retos operativos. Al ser un ciclo enteramente manual, el registro visual en cuadernos y su posterior transcripción a sistemas centralizados representa una fuente constante de errores. De hecho, datos preliminares de esta investigación sugieren que estas fallas pueden generar desviaciones de hasta un 10 % en la facturación. Estos errores, catalogados como “pérdidas comerciales”, se suman al ya crítico problema del Agua No Contabilizada (ANC). A nivel nacional, el promedio de ANC en los Gobiernos Autónomos Descentralizados (GAD) Municipales alcanza un alarmante 51.8 % (Instituto Nacional de Estadística y Censos (INEC), 2024, p. 15). Es plausible que esta cifra

sea aún mayor en los sistemas comunitarios, donde a las pérdidas técnicas por fugas se añade una mayor incidencia de pérdidas comerciales debido, precisamente, a la fragilidad de estos procesos manuales (Agencia de Cooperación Internacional del Japón (JICA), 2025).



Figura 2.1: *Ejemplo de medidor de agua en un entorno rural no controlado, similar a los encontrados en el área de estudio. La exposición a la intemperie, la suciedad y el desgaste son desafíos comunes para los sistemas de lectura por visión artificial.*

En consecuencia, la adopción de paradigmas modernos como la Infraestructura de Medición Avanzada (AMI) se enfrenta a barreras prácticamente insuperables en este contexto. La viabilidad de una implementación de esta naturaleza se ve comprometida no solo por el prohibitivo costo de inversión en medidores inteligentes y la red de comunicaciones asociada, incompatible con la capacidad financiera de una JAAP, sino también por obstáculos técnicos fundamentales como la intermitencia o ausencia de conectividad a internet y la inestabilidad del suministro eléctrico, factores endémicos en muchas zonas rurales (Banco Interamericano de Desarrollo (IADB), 2022; Fieldeke et al., 2021).

Esta confluencia de factores define una clara “brecha tecnológica”: mientras existe una necesidad urgente de automatización, las soluciones comerciales de vanguardia resultan inaccesibles. Es en este vacío donde la visión por computadora ejecutada en dispositivos móviles emerge como un “puente tecnológico” idóneo. Dicho enfoque aprovecha la base de medidores mecánicos ya instalada y el hardware de consumo masivo —los teléfonos inteligentes— para digitalizar el proceso de lectura con una inversión marginal, garantizando además una opera-

ción completamente autónoma y offline, adaptada a las realidades del entorno rural (Carvalho et al., 2023; Santiago & Alvares, 2020).

2.2 Paradigmas de medición: de la lectura manual a la medición inteligente

La evolución en la gestión de servicios públicos está intrínsecamente ligada a la evolución de sus tecnologías de medición. El medidor no es solo un dispositivo de facturación; es el principal sensor de la red, cuya capacidad para generar datos define el potencial de un proveedor para optimizar sus operaciones. El paso de un paradigma de lectura manual y reactiva a uno de gestión inteligente y proactiva depende fundamentalmente del tipo de tecnología de medición desplegada en el campo.

2.2.1 Medidores tradicionales (analógicos y digitales) vs. medidores inteligentes (smart meters)

El parque de medidores de agua instalado a nivel mundial es tecnológicamente heterogéneo. En un extremo se encuentran los **medidores mecánicos o analógicos**, que constituyen la gran mayoría de los dispositivos en servicio, especialmente en instalaciones antiguas y en la mayoría de las zonas rurales de América Latina (Salomon et al., 2022; Santiago & Alvares, 2020). Estos dispositivos operan mediante mecanismos internos (como turbinas o discos oscilantes) que mueven un conjunto de engranajes. La lectura se presenta en un contador de tipo ciclómetro (ruedas numéricas) o, en modelos más antiguos, en una serie de diales analógicos. Su principal característica, y a la vez su mayor limitación, es la ausencia total de capacidades de comunicación; son dispositivos pasivos que requieren una inspección visual directa.

Una evolución de estos son los **medidores digitales**, que reemplazan el contador mecánico por una pantalla de cristal líquido (LCD). Aunque la medición interna puede seguir siendo mecánica, la presentación digital elimina los errores de interpretación de los diales. No obstante, en su gran mayoría, estos medidores tampoco cuentan con módulos de comunicación integrados, por lo que siguen dependiendo de una lectura visual en sitio (Peng et al., 2023).

El salto cualitativo lo representan los **medidores inteligentes (Smart Meters)**. Un medidor inteligente es un dispositivo electrónico que no solo registra el consumo de agua, sino que fundamentalmente posee capacidad de comunicación bidireccional. Esta característica es la que habilita la implementación de una Infraestructura de Medición Avanzada (AMI, por sus siglas en inglés), permitiendo la transmisión automática y periódica de datos a un sistema central y la recepción de comandos remotos (Banco Interamericano de Desarrollo (IADB), 2022;

Laroca et al., 2021). Esta tecnología es el fundamento de las redes de agua inteligentes o *smart water grids*. La Tabla 2.1 resume las características clave de cada tipología.

Tabla 2.1: *Comparativa de Tecnologías de Medición de Agua.*

Característica	Mecánico / Analógico	Digital (No-comunicante)	Inteligente (Smart Meter)
Principio de Lectura	Visual (ruedas numéricas o diales).	Visual (pantalla LCD).	Electrónica y remota.
Comunicación	Inexistente.	Inexistente.	Bidireccional (RF, celular, PLC).
Recolección de Datos	Manual, en sitio.	Manual, en sitio.	Automática (AMR/AMI).
Frecuencia de Datos	Mensual o bimensual.	Mensual o bimensual.	Desde casi tiempo real (minutos) hasta diaria.
Capacidades Adicionales	Ninguna.	Ninguna.	Detección de fugas, gestión de válvulas, alertas de manipulación, perfil de consumo.
Costo Relativo	Bajo.	Bajo-Medio.	Alto.

Nota. La información se basa en la síntesis de las características descritas en la literatura por (Banco Interamericano de Desarrollo (IADB), 2022; Laroca et al., 2021; Peng et al., 2023; Salomon et al., 2022; Santiago & Alvares, 2020).

2.2.2 Ineficiencias y costos de los sistemas de lectura manual

El paradigma de la lectura manual, si bien es el más extendido por su bajo costo inicial, arrastra una serie de ineficiencias sistémicas que impactan directamente en la sostenibilidad de los proveedores de agua. La principal es la **ineficiencia operativa**, que se manifiesta en altos costos de tiempo y mano de obra. En contextos rurales con usuarios dispersos, el desplazamiento físico de un operario para visitar cada medidor representa el costo operativo más significativo para una JAAP (Santiago & Alvares, 2020).

A esto se suma una alta **propensión al error humano**. La literatura identifica dos fuentes principales de error: los de lectura y los de transcripción. Los errores de lectura ocurren en campo debido a factores como el ángulo de visión (error de paralaje), medidores en lugares de difícil acceso, o carátulas deterioradas por la suciedad o la condensación (Laroca et al., 2021). Los errores de transcripción, por su parte, se producen cuando el dato anotado manualmente

en una libreta es posteriormente digitado en un sistema de registro, un doble paso que inevitablemente introduce fallos (Chaki et al., 2019; Khan et al., 2024). Estos errores, aunque parezcan menores, pueden llevar a una facturación incorrecta, generando conflictos con los usuarios y pérdidas financieras directas para la organización.

Quizás la deficiencia más crítica de la lectura manual es la **pobreza de los datos** que genera. Al obtener un único dato de consumo al mes, es imposible realizar una gestión proactiva de la red. Tareas como la elaboración de perfiles de consumo, la optimización de la presión o la detección temprana de fugas —una de las principales causas del Agua No Contabilizada— son inviables con datos tan espaciados en el tiempo (Kainz et al., 2021). La falta de datos granulares impide a los gestores pasar de un modelo reactivo a uno predictivo.

2.2.3 El mercado del “smart metering” y la oportunidad para soluciones alternativas

A nivel global, la industria de servicios públicos avanza hacia la adopción masiva de medidores inteligentes, un mercado en constante crecimiento impulsado por la necesidad de eficiencia y digitalización (Global Growth Insights, 2023). Sin embargo, esta tendencia global encuentra barreras significativas para su despliegue en contextos rurales y en países en vías de desarrollo. Los informes del Banco Interamericano de Desarrollo y otros estudios señalan dos obstáculos principales: el **costo prohibitivo de la inversión** y la **dependencia de una infraestructura de conectividad** robusta (Banco Interamericano de Desarrollo (IADB), 2022; Fieldeke et al., 2021).

Para una organización comunitaria como una JAAP, el costo de reemplazar cientos de medidores mecánicos por medidores inteligentes, sumado al despliegue y mantenimiento de la red de comunicaciones (AMI), es una barrera insuperable. Este escenario crea la oportunidad para el desarrollo de “soluciones puente”, que ofrezcan los beneficios de la digitalización sin requerir una sustitución completa de la infraestructura existente.

Aquí es donde la visión por computadora aplicada a través de dispositivos móviles se posiciona como la alternativa más viable y costo-efectiva. Este enfoque, que se enmarca dentro de las tendencias de Industria 4.0 y Ciudades Inteligentes, aprovecha dos recursos ya existentes y extendidos: la base instalada de medidores mecánicos y la alta penetración de los teléfonos inteligentes (Ktari et al., 2022). Al desarrollar una aplicación móvil que actúa como un “lector inteligente”, se eliminan los principales costos de inversión. La solución se centra en el software y el uso de un hardware de consumo, democratizando el acceso a la medición avanzada. Proyectos como los de (Carvalho et al., 2023) y (Santiago & Alvares,

2020) validan la factibilidad técnica de ejecutar estos sistemas en dispositivos de borde (edge devices), demostrando que es posible lograr una alta precisión en la lectura de forma rápida y, crucialmente, sin depender de una conexión a internet para el procesamiento.

Este enfoque basado en la inteligencia artificial, sin embargo, introduce un nuevo requisito fundamental que no existía en los paradigmas anteriores: la necesidad de un conjunto de datos robusto y representativo para entrenar los modelos de visión. La eficacia de cualquier sistema de IA no reside únicamente en la arquitectura de su modelo, sino, y de manera primordial, en la calidad y pertinencia de los datos con los que aprende. Por lo tanto, antes de profundizar en las arquitecturas y algoritmos, es indispensable analizar el estado del arte en lo que respecta a la materia prima de estos sistemas: los datasets para AMR.

2.3 Datasets y aumento de datos como fundamento para el AMR

El rendimiento, la robustez y la capacidad de generalización de cualquier modelo de aprendizaje profundo están fundamentalmente determinados por la calidad, cantidad y diversidad de los datos con los que es entrenado. En el campo de la Lectura Automatizada de Medidores, la creación de un conjunto de datos (dataset) de alta calidad es un desafío en sí mismo, presentando problemas específicos de adquisición, anotación, balance de clases y representatividad del entorno real de despliegue.

2.3.1 *Análisis de datasets públicos para AMR*

La existencia de datasets públicos y benchmarks estandarizados es vital para el avance de la investigación, ya que permite una comparación objetiva y reproducible entre diferentes enfoques metodológicos. En los últimos años, la comunidad académica ha publicado varios datasets significativos para AMR.

Uno de los más influyentes es el **UFPR-AMR**, que en sus distintas versiones ha servido como base para numerosos estudios (Laroca et al., 2021). Este conjunto de datos, aunque valioso, fue recolectado en condiciones relativamente controladas (un almacén de la empresa de servicios), lo que no captura toda la complejidad de las instalaciones en campo. Para abordar esto, el mismo grupo de investigación liberó posteriormente el dataset **Copel-AMR**, mucho más grande (12,500 imágenes) y representativo, ya que fue capturado “en la naturaleza” por los propios empleados de la compañía eléctrica. De manera crucial, Copel-AMR incluye una categoría de medidores “ilegibles/defectuosos”, lo que permite entrenar y evaluar sistemas en su capacidad de rechazar lecturas inviables, una función indispensable para una aplicación real (Laroca et al., 2021).

Otros investigadores también han creado y utilizado datasets específicos para sus estudios, como el de Hong et al. (2021), enfocado en capturar una amplia gama de “entornos desafiantes”, o el dataset SYSU-DM de Peng et al. (2023), centrado en medidores digitales de multímetro capturados desde múltiples ángulos para validar sus técnicas de corrección de perspectiva. Si bien estos recursos son fundamentales para el desarrollo de algoritmos, su principal limitación es la especificidad contextual: están compuestos por modelos de medidores y condiciones ambientales propias de Brasil, China o entornos de laboratorio, que no necesariamente se corresponden con la realidad de las JAAPS en Ecuador.




Figura 2.2: Ejemplos de la diversidad de medidores y condiciones en diferentes datasets públicos. (a) Medidor electromecánico en un escenario no controlado (Laroca et al., 2021). (b) Medidor de diales (Salomon et al., 2022). (c) Medidor digital de multímetro (Peng et al., 2023).

2.3.2 Metodología de adquisición y anotación de datos de campo

La creación de un dataset de alta calidad no es un acto improvisado, sino un proceso metodológico que requiere planificación y una ejecución sistemática para asegurar la diversidad y la fiabilidad de los datos. El objetivo no es solo acumular imágenes, sino construir un conjunto de datos que represente fielmente la variabilidad del problema. Este proceso, ilustrado en la Figura 2.3, se desglosa en varias fases clave.

El primer paso es el **diseño del protocolo de adquisición**. Esto implica definir las condiciones bajo las cuales se realizarán las capturas. Para asegurar la diversidad, la recolección de imágenes debe planificarse para cubrir: variabilidad temporal (diferentes horas del día), variabilidad climática (días soleados, nublados) y variabilidad de pose (múltiples ángulos y distancias).

El segundo paso es la **captura y validación en campo**. Utilizando una aplicación de captura de datos específica, el operario toma la fotografía y, en el mismo instante, ingresa

manualmente la lectura correcta del medidor. Este dato, conocido como *ground-truth*, se almacena como metadato de la imagen y es crucial para la posterior validación del modelo de IA.

Finalmente, el **proceso de anotación** transforma las imágenes en datos de entrenamiento. Con herramientas de etiquetado como CVAT o LabelImg, se generan las anotaciones para cada imagen, incluyendo la localización de la Región de Interés (ROI) y la transcripción de la secuencia de texto. Este ciclo concluye con una fase de revisión de calidad para asegurar la máxima fiabilidad del dataset.




Figura 2.3: Flujo de trabajo metodológico para la adquisición y anotación de un dataset de campo.

2.3.3 Desafíos inherentes a la creación de datasets propios

Aun siguiendo una metodología rigurosa, la creación de un dataset presenta desafíos intrínsecos. El primero es la **representatividad**, es decir, asegurar que la muestra de imágenes capture adecuadamente la “fauna” local de medidores en todos sus modelos, antigüedades y

estados de conservación.

El proceso de **anotación o etiquetado** es el cuello de botella más significativo por su alta demanda de tiempo y su propensión al error humano. Finalmente, un problema inherente a los datos de medidores es el **desbalance de clases**. Los dígitos más significativos (a la izquierda) cambian con muy poca frecuencia, lo que resulta en un dataset donde el dígito ‘0’ es abrumadoramente más común en esas posiciones que, por ejemplo, un ‘8’ o un ‘9’. Sin una estrategia para mitigar este desbalance, el modelo no tendrá suficientes ejemplos para aprender a reconocer los dígitos menos frecuentes (Laroca et al., 2021).

2.3.4 Estrategias de aumento de datos para mejorar la robustez

El aumento de datos (*data augmentation*) es el conjunto de técnicas utilizadas para incrementar artificialmente el tamaño y la diversidad de un dataset de entrenamiento. Es la principal estrategia para combatir el sobreajuste y los problemas de desbalance de clases.

Las **técnicas tradicionales** incluyen transformaciones geométricas y fotométricas. Si bien son esenciales, no resuelven el problema del desbalance de clases. Para ello, enfoques específicos como la **permutación de caracteres** (Laroca et al., 2021) o, de manera más avanzada, el **aumento de datos generativo**, han demostrado ser soluciones efectivas. Este último utiliza redes neuronales generativas para crear imágenes sintéticas fotorrealistas de los dígitos menos frecuentes, e incluso de los esquivos dígitos en transición, fortaleciendo la robustez del modelo de una manera que las otras técnicas no pueden lograr (Sripanuskul et al., 2022).

2.4 Visión por computadora aplicada a la lectura automatizada de medidores (AMR)

La visión por computadora (CV) constituye el pilar tecnológico que habilita la automatización de la lectura de medidores a partir de imágenes. Su objetivo es emular la capacidad humana de percepción visual para interpretar y extraer información estructurada —en este caso, una secuencia numérica— a partir de datos no estructurados como son los píxeles de una fotografía. En el contexto del AMR, la aplicación de CV no se limita a un único algoritmo, sino que implica el diseño de un *pipeline* o secuencia de etapas de procesamiento, donde cada una resuelve una parte específica del problema general (Hong et al., 2021). Este enfoque modular permite abordar la complejidad de la tarea de una manera ordenada y robusta.

2.4.1 Fundamentos del pipeline de detección-reconocimiento

El análisis de la literatura más influyente revela un consenso en torno a un *pipeline* de dos etapas fundamentales como el enfoque más efectivo para el AMR basado en imágenes (Khan et al., 2024; Laroca et al., 2021; Van et al., 2025). Esta arquitectura secuencial ha demos-

trado ser superior a los intentos de resolver el problema en un único paso, ya que descompone la tarea en dos subproblemas más manejables y computacionalmente optimizados.

La **primera etapa es la detección y localización de la Región de Interés (ROI)**. Su propósito es encontrar y aislar el área específica del medidor que contiene los dígitos (el contador o la “rueda de palabras”), descartando el resto del fondo de la imagen. Este paso es crítico porque reduce drásticamente la cantidad de información irrelevante y el ruido visual que se debe procesar en la siguiente fase, permitiendo que el modelo de reconocimiento se concentre exclusivamente en su tarea (Liang et al., 2022).

La **segunda etapa es el reconocimiento de la secuencia de caracteres**. Una vez que la ROI ha sido extraída y, a menudo, normalizada, se introduce en un modelo de Reconocimiento Óptico de Caracteres (OCR) cuyo objetivo es transcribir los píxeles de los dígitos en una secuencia de texto editable. La eficacia de esta etapa depende en gran medida de la calidad y precisión de la localización obtenida en la primera (Peng et al., 2023). El flujo general de este proceso se ilustra en la Figura 2.4.




Figura 2.4: Diagrama de flujo del pipeline de dos etapas para AMR.

2.4.2 *El desafío de la detección: de cajas delimitadoras a la segmentación semántica*

La etapa de detección ha experimentado una notable evolución. Los primeros enfoques y los más directos utilizan modelos de detección de objetos, como las diferentes versiones de YOLO, para predecir una **caja delimitadora (bounding box)** horizontal que enmarque la ROI (Liang et al., 2022). Si bien este método es rápido y eficaz en imágenes frontales y bien alineadas, su rendimiento se degrada significativamente cuando las imágenes son capturadas desde ángulos oblicuos, un escenario común en el trabajo de campo.

Para superar esta limitación, la investigación de vanguardia ha avanzado hacia técnicas más sofisticadas. Un enfoque intermedio es la **detección de puntos clave (keypoint detection)**, donde el modelo no predice una caja, sino las cuatro esquinas del contador. Esto permite aplicar una transformación de perspectiva para rectificar la imagen y obtener una vista frontal normalizada, mejorando drásticamente los resultados del posterior OCR (Peng et al., 2023).

El enfoque más avanzado y preciso hasta la fecha es la **segmentación semántica**. En lugar de predecir coordenadas, el modelo predice a nivel de píxel a qué clase pertenece cada uno (fondo o región del contador). Modelos recientes como CAM-YOLOv8 utilizan mecanismos de atención para lograr una segmentación extremadamente precisa de la “rueda de palabras”, logrando delinear el contorno exacto de la ROI incluso en condiciones complejas (Wang et al., 2025). Esta precisión en la localización es fundamental para maximizar el rendimiento de la etapa de reconocimiento.

2.4.3 *Técnicas de preprocesamiento de imágenes para escenarios reales*

Independientemente de la sofisticación del modelo de detección o reconocimiento, la calidad de la imagen de entrada es un factor determinante en el rendimiento del sistema. Dado que las imágenes capturadas en campo rara vez son ideales, el preprocesamiento de imágenes no es un paso opcional, sino una etapa obligatoria para la normalización y mejora de los datos de entrada (Zou et al., 2021).

Las técnicas de preprocesamiento se pueden agrupar en dos categorías principales. La primera son las **correcciones geométricas**, destinadas a normalizar la pose y la orientación del medidor. Como se mencionó anteriormente, la corrección de perspectiva es la más importante para manejar ángulos de cámara variables (Peng et al., 2023). Adicionalmente, módulos específicos de **alineación de orientación** pueden corregir la rotación en el plano de la imagen, asegurando que los dígitos se presenten horizontalmente al modelo de OCR (Hong

et al., 2021).

La segunda categoría es la **mejora de la calidad visual**. Esto incluye operaciones más tradicionales pero igualmente efectivas:

- **Conversión a escala de grises:** Reduce la complejidad computacional al procesar un solo canal de color en lugar de tres, sin perder la información esencial de la forma de los dígitos.
- **Normalización de la iluminación:** Técnicas como la ecualización de histograma, y en particular la ecualización adaptativa de histograma limitada por contraste (CLAHE), son efectivas para mitigar los efectos de sombras profundas o reflejos brillantes, estandarizando el contraste de la ROI.
- **Filtrado de ruido:** La aplicación de filtros como el gaussiano o el de mediana puede ayudar a suavizar el ruido de la imagen capturada por sensores de baja calidad o en condiciones de poca luz.

La aplicación de un pipeline de preprocesamiento robusto es una condición indispensable para que los modelos de aprendizaje profundo puedan generalizar su rendimiento del laboratorio al impredecible entorno de campo (Chaki et al., 2019).

2.5 Reconocimiento óptico de caracteres (OCR) en el contexto de AMR

Una vez que la región de interés ha sido localizada, aislada y normalizada, la tarea central del sistema es transcribir la imagen de los dígitos a una secuencia de caracteres procesable. Esta es la función del Reconocimiento Óptico de Caracteres (OCR). Al igual que en la etapa de detección, el campo del OCR ha experimentado una profunda transformación, migrando desde métodos clásicos basados en reglas y características manuales hacia arquitecturas de aprendizaje profundo que ofrecen una robustez y precisión significativamente mayores, especialmente en los desafiantes entornos de campo.

2.5.1 Evolución de enfoques: de métodos clásicos a deep learning

Los primeros enfoques para el OCR en la lectura de medidores se basaban en técnicas de procesamiento de imágenes tradicionales. Un método común era la **coincidencia de plantillas (template matching)**, donde imágenes predefinidas de cada dígito (del 0 al 9) se comparan con segmentos de la imagen de entrada. La plantilla con la mayor similitud, a menudo medida por un coeficiente de correlación, determina el dígito reconocido (Chaki et al., 2019). Si bien este enfoque es computacionalmente simple, su fragilidad es su principal in-

conveniente; es extremadamente sensible a variaciones de escala, rotación, grosor del trazo y ruido en la imagen, lo que limita severamente su aplicabilidad en escenarios no controlados.

Una alternativa más robusta dentro de los métodos clásicos es el uso de motores de OCR de código abierto como **Tesseract**. Estos sistemas son más avanzados, ya que internamente realizan sus propios procesos de segmentación y reconocimiento de características. Algunos trabajos lo han utilizado como base para sus sistemas (Maheshwari & Singh, 2023). No obstante, aunque Tesseract funciona bien con texto impreso de alta calidad (como documentos escaneados), su rendimiento tiende a decaer en imágenes “salvajes” o *in the wild*, como las fotografías de medidores, que presentan ruido, baja resolución y condiciones de iluminación deficientes.

La revolución del *deep learning* superó estas limitaciones. En lugar de depender de características o plantillas predefinidas, las Redes Neuronales Convolucionales (CNNs) aprenden a extraer jerarquías de características visuales directamente de los datos de entrenamiento. Esto les confiere una capacidad de generalización y una robustez muy superiores frente a las variaciones que inutilizan a los métodos clásicos. El cambio de paradigma más significativo fue la adopción de arquitecturas *end-to-end*, que procesan la secuencia completa de dígitos en la ROI sin necesidad de una segmentación previa y explícita de cada carácter individual. Este enfoque holístico es inherentemente más robusto a los problemas de alineación y espaciado irregular entre los dígitos del medidor.

2.5.2 Análisis comparativo de arquitecturas neuronales para OCR en medidores

Dentro del dominio del aprendizaje profundo, varias arquitecturas han sido propuestas y validadas para la tarea de reconocimiento de secuencias de texto en medidores. Una de las más influyentes y utilizadas como base es la **Red Neuronal Convolutiva Recurrente (CRNN, por sus siglas en inglés)**. Un modelo CRNN combina lo mejor de dos mundos: las capas convolucionales (CNN) para la extracción de características visuales de la imagen, y las capas recurrentes (RNN), usualmente con unidades LSTM bidireccionales, para capturar el contexto secuencial de los dígitos. Finalmente, una capa de transcripción, que a menudo utiliza la función de pérdida de Clasificación Temporal Conexiónista (CTC), traduce las predicciones de la red a la secuencia de caracteres final sin requerir una segmentación perfecta (Carvalho et al., 2023; Shen et al., 2023).

Si bien la arquitectura CRNN ha demostrado ser un punto de partida sólido, la investigación reciente se ha centrado en evaluar y desarrollar modelos aún más precisos. Un estudio

comparativo exhaustivo realizado por Van et al. (2025) evaluó seis arquitecturas diferentes para la lectura de medidores de agua, incluyendo CRNN, TrOCR (basado en Transformers) y PP-OCRv3. Sus resultados concluyeron que **PP-OCRv3** obtuvo la mayor precisión (93 %), atribuyendo su éxito a sus módulos de optimización de imagen y a una arquitectura robusta que maneja eficientemente las anomalías de los caracteres. Este hallazgo es consistente con otros trabajos, como el de Khan et al. (2024), quienes lograron una precisión del 96.92 % al afinar un modelo de PaddleOCR, la base sobre la que se construye PP-OCRv3.

La Tabla 2.2 presenta una síntesis de las arquitecturas de OCR más relevantes discutidas en la literatura para el AMR.

Tabla 2.2: *Comparativa de Arquitecturas de OCR para Lectura de Medidores.*

Modelo	Principio de Funcionamiento	Precisión Reportada (Aprox.)	Referencia Clave
Tesseract	Motor de OCR clásico basado en análisis de componentes conectados y reconocimiento de patrones.	Variable, pero generalmente inferior a los modelos de DL en imágenes de campo.	(Maheshwari & Singh, 2023)
CRNN	Combina una CNN para extracción de características, una RNN (LSTM) para contexto secuencial y una pérdida CTC para transcripción.	Sólida como base, pero superada por arquitecturas más modernas.	(Carvalho et al., 2023; Shen et al., 2023)
PP-OCRv3	Sistema de OCR ultraligero con módulos optimizados para detección, corrección de dirección y reconocimiento.	93 % en estudios comparativos, destacando por su robustez y eficiencia.	(Van et al., 2025)
PaddleOCR	Framework de OCR basado en DL (similar a PP-OCRv3) que, al ser afinado, ha demostrado un rendimiento de vanguardia.	96.92 % en implementaciones específicas para medidores.	(Khan et al., 2024)

Nota. La precisión reportada puede variar significativamente según el dataset y las condiciones del experimento. La tabla busca sintetizar los hallazgos generales de la literatura citada.

La literatura reciente permite concluir que, para generar datos de consumo fiables que sirvan como base para un ciclo de facturación, el umbral de precisión de los métodos clásicos de OCR es insuficiente. La evidencia apunta de manera consistente hacia la adopción de modelos de aprendizaje profundo, donde una exactitud superior al 98 % se vuelve un requisito indispensable para minimizar errores con impacto económico y asegurar la confianza en el sistema automatizado. En este panorama, arquitecturas como CRNN se establecen como un estándar de base robusto, mientras que sistemas más optimizados como PP-OCRV3 representan la vanguardia, ofreciendo el rendimiento necesario para el prototipo que esta investigación se propone construir.

2.6 Habilitadores tecnológicos para el despliegue en dispositivos móviles (edge AI)

La implementación de un sistema de AMR en el contexto de las JAAPS rurales presenta un desafío que va más allá de la precisión del modelo: la necesidad de un despliegue en dispositivos de borde (*edge devices*) con recursos computacionales limitados y sin dependencia de una conexión a internet. Este paradigma, conocido como Inteligencia Artificial en el Borde (Edge AI), implica que todo el procesamiento, desde la captura de la imagen hasta la inferencia del modelo, se realiza localmente en el dispositivo móvil del operario (Li et al., 2023). Este enfoque es la única alternativa viable frente a los modelos basados en la nube, ya que ofrece una latencia mínima, garantiza el funcionamiento en zonas sin cobertura y mantiene la privacidad de los datos al no transmitirlos a servidores externos.

2.6.1 Requerimientos del procesamiento en el borde: latencia, memoria y consumo energético

El hardware de un teléfono inteligente, aunque potente, es un entorno de recursos restringidos en comparación con un servidor. El despliegue de modelos de aprendizaje profundo en estos dispositivos impone un conjunto estricto de requerimientos no funcionales que deben ser abordados desde el diseño (Poddar et al., 2024).

El primero es la **latencia**. Para que la aplicación sea usable en campo, el tiempo total desde que se captura la foto hasta que se muestra la lectura reconocida debe ser mínimo, idealmente inferior a un par de segundos. Una latencia elevada frustra al usuario y reduce drásticamente la eficiencia que se busca lograr (Carvalho et al., 2023).

El segundo requerimiento es el uso de **memoria**. Los modelos de *deep learning* pueden ocupar cientos de megabytes, tanto en almacenamiento (el tamaño del archivo del modelo) como en RAM durante la ejecución. Un modelo demasiado grande no solo es difícil de distribuir

e instalar, sino que corre el riesgo de ser terminado por el sistema operativo Android si su consumo de RAM es excesivo, especialmente en dispositivos de gama media o baja.

Finalmente, el **consumo energético** es un factor crítico. Las operaciones de las redes neuronales, particularmente las convoluciones, son computacionalmente intensivas y pueden drenar la batería del dispositivo rápidamente. Una solución que agote la batería del teléfono del operario a mitad de su jornada de trabajo es, en la práctica, inviable. Por tanto, la eficiencia energética del modelo es tan importante como su precisión (Poddar et al., 2024).

2.6.2 Arquitecturas optimizadas y frameworks (TensorFlow Lite)

Para satisfacer los estrictos requerimientos del borde, la comunidad de investigación ha desarrollado arquitecturas de redes neuronales diseñadas explícitamente para la eficiencia. La innovación clave fue la introducción de las **convoluciones separables en profundidad** (*depthwise separable convolutions*), que reducen drásticamente el número de parámetros y operaciones computacionales en comparación con las convoluciones estándar. Esta técnica es la piedra angular de familias de redes tan influyentes como **MobileNet** (Poddar et al., 2024).

Posteriormente, arquitecturas como **EfficientNet** introdujeron un método de escalado compuesto que optimiza de manera balanceada la profundidad, el ancho y la resolución de la red para lograr un mejor equilibrio entre precisión y eficiencia (Tan & Le, 2021). Investigaciones más recientes incluso han explorado la adaptación de los Transformers, tradicionalmente pesados, a entornos móviles con modelos como **MobileViT** (Mehta & Rastegari, 2022). Trabajos aplicados al AMR, como el de Zou et al. (2021), demuestran que es posible diseñar CNNs ligeras y personalizadas que alcanzan una alta precisión con una complejidad reducida.

Para desplegar estos modelos en un dispositivo Android, es necesario utilizar un *framework* de inferencia móvil. El estándar de la industria para este fin es **TensorFlow Lite (TFLite)**. TFLite no es un entorno de entrenamiento, sino un conjunto de herramientas que permite tomar un modelo estándar de TensorFlow, convertirlo y optimizarlo para su ejecución en el borde. El *framework* proporciona un intérprete ligero que se integra en la aplicación móvil y que es capaz de aprovechar los aceleradores de hardware del dispositivo (GPU, DSP, NPU) para una inferencia más rápida y eficiente (Albonico et al., 2023; Santiago & Alvares, 2020).

2.6.3 Técnicas de optimización: cuantización y transferencia de aprendizaje

Además de elegir una arquitectura ligera, existen técnicas de optimización posterior al entrenamiento que son cruciales para reducir aún más el tamaño y la latencia del modelo. La más importante de ellas es la **cuantización**. Este proceso consiste en reducir la precisión

numérica de los pesos del modelo, usualmente de números de punto flotante de 32 bits (FP32) a enteros de 8 bits (INT8). Los beneficios de la cuantización son triples: reduce el tamaño del modelo en aproximadamente 4 veces, acelera la inferencia (especialmente en hardware con soporte para operaciones con enteros) y disminuye el consumo de energía (Ghosh et al., 2023). El entrenamiento consciente de la cuantización (QAT) es una técnica que simula los efectos de la cuantización durante el entrenamiento, lo que generalmente permite preservar una mayor precisión en el modelo final en comparación con la cuantización post-entrenamiento (PTQ).

Otra estrategia fundamental para proyectos con datasets limitados, como es el caso de esta investigación, es la **transferencia de aprendizaje (*transfer learning*)**. En lugar de entrenar una red neuronal desde cero, lo que requeriría una enorme cantidad de imágenes, se parte de un modelo ligero pre-entrenado en un dataset a gran escala (como MobileNet entrenado en ImageNet). Se congelan las capas iniciales que han aprendido a extraer características visuales genéricas (bordes, texturas, formas) y se re-entrenan únicamente las últimas capas sobre el dataset específico de medidores de agua. Esta técnica reduce drásticamente el tiempo de entrenamiento y la cantidad de datos necesarios, al tiempo que permite alcanzar una alta precisión (Poddar et al., 2024).

La culminación de este proceso de optimización es un archivo de modelo ligero y eficiente, listo para ser integrado como el “cerebro” de una aplicación móvil.




Figura 2.5: Flujo de trabajo para la optimización de un modelo de deep learning para su despliegue en dispositivos móviles mediante TensorFlow Lite.

2.7 Desarrollo de aplicaciones móviles para la captura y gestión de datos en campo

La efectividad de un modelo de inteligencia artificial optimizado se materializa únicamente a través de su integración en una aplicación de software que sea robusta, usable y adaptada al flujo de trabajo del usuario final. En el marco de este proyecto, dicha herramienta es un prototipo móvil para la plataforma Android, concebido para operar en las exigentes condiciones del trabajo de campo. Por consiguiente, un análisis completo debe trascender los algoritmos de visión por computadora para abarcar también las mejores prácticas en la arquitectura y el desarrollo de software móvil, especialmente aquellas que garantizan la operación offline y una alta usabilidad en entornos rurales.

2.7.1 Arquitecturas de software para aplicaciones “offline-first”

El requisito fundamental de operación en zonas rurales sin acceso a internet obliga a adoptar una arquitectura de software “offline-first”. En este paradigma, la aplicación debe ser 100 % funcional sin conexión; la sincronización de datos con un servidor central se consi-

dera una operación secundaria que ocurre de manera eventual, cuando la conectividad está disponible (Santiago & Alvares, 2020).

Para lograr esto, la práctica estándar en el desarrollo de Android moderno es el uso del **Patrón de Repositorio (Repository Pattern)**. Este patrón de diseño desacopla la lógica de la aplicación de las fuentes de datos. El repositorio actúa como la única fuente de verdad para la aplicación, gestionando internamente si los datos se obtienen de una base de datos local o de un servicio web remoto. Para el almacenamiento local persistente, la biblioteca **Room**, una capa de abstracción sobre SQLite, es la solución recomendada por Google por su robustez y facilidad de uso.

La sincronización de los datos recolectados (las lecturas de los medidores) se gestiona de manera asíncrona. Herramientas como **WorkManager**, parte de Android Jetpack, permiten programar tareas de sincronización diferidas y garantizadas. El sistema operativo se encarga de ejecutar la tarea de carga de datos cuando detecta que el dispositivo ha recuperado una conexión a internet, asegurando que ninguna lectura se pierda, incluso si el dispositivo se reinicia.




Diagrama de Arquitectura Offline-First (generado con PlantUML).

Figura 2.6: *Diagrama de una arquitectura de software moderna para Android con enfoque “offline-first”, mostrando la separación de responsabilidades y el flujo de datos.*

2.7.2 Frameworks de desarrollo: nativo (Kotlin) vs. multiplataforma (Flutter)

La elección del framework de desarrollo tiene implicaciones directas en el rendimiento y las capacidades de la aplicación. En el ecosistema actual, las dos vertientes principales son

el desarrollo nativo y el multiplataforma.

El **desarrollo nativo** para Android, utilizando lenguajes como **Kotlin** o Java, ofrece la ventaja fundamental de un rendimiento óptimo y un acceso directo y sin restricciones a todas las APIs del sistema operativo. Esto es particularmente crítico para aplicaciones que dependen intensivamente del hardware, como es el caso de un prototipo de visión por computadora. El acceso directo a las APIs de la cámara (CameraX) para un control granular de la captura y, sobre todo, a los delegados de aceleración de hardware (NNAPI) para los modelos de IA, es más sencillo y eficiente en un entorno nativo.

Por otro lado, los **frameworks multiplataforma** como **Flutter** (usando el lenguaje Dart) o React Native permiten escribir una única base de código que se compila tanto para Android como para iOS, lo que puede acelerar el desarrollo. Sin embargo, esta abstracción puede introducir una capa de sobrecarga (overhead) que impacte la latencia de la inferencia del modelo. Además, el acceso a las APIs nativas más avanzadas de hardware a menudo requiere el uso de “puentes” o *plugins* de terceros, lo que puede añadir complejidad y puntos de fallo. Para una aplicación donde el rendimiento de la inferencia de IA en el borde es el núcleo funcional, la literatura y la práctica de la industria a menudo se inclinan por el enfoque nativo para maximizar la velocidad y la fiabilidad.

2.7.3 Integración práctica de modelos TFLite en Android

La integración de un modelo de TensorFlow Lite (‘.tflite’) en una aplicación Android es un proceso técnico que va más allá de simplemente añadir el archivo al proyecto. Requiere una gestión cuidadosa de los recursos para asegurar una ejecución fluida.

El componente central es el **Intérprete de TFLite**, que se encarga de cargar el modelo y ejecutar la inferencia. Un aspecto crítico es el manejo de hilos de ejecución (*threading*). La inferencia del modelo es una operación bloqueante que puede tardar desde milisegundos hasta varios segundos; ejecutarla en el hilo principal de la interfaz de usuario (UI thread) provocaría que la aplicación se congelara, resultando en un error de “Aplicación no responde” (ANR). Por ello, es imperativo que toda la lógica de inferencia se ejecute en un hilo de fondo. Las **Corrutinas de Kotlin** son la herramienta moderna y recomendada en Android para gestionar estas operaciones asíncronas de manera eficiente y legible.

Para acelerar la ejecución, el intérprete de TFLite puede utilizar **delegados** para derivar la computación a procesadores especializados. El delegado de GPU puede acelerar modelos con gran cantidad de operaciones en paralelo, mientras que el delegado de NNAPI (Neural

Networks API) permite al sistema operativo distribuir la carga entre la GPU, el DSP (Procesador de Señal Digital) o una NPU (Unidad de Procesamiento Neuronal) si el dispositivo dispone de ella (Albonico et al., 2023).

Finalmente, el desarrollador debe manejar la conversión de datos. La imagen capturada ('Bitmap') debe ser preprocesada (cambio de tamaño, normalización de píxeles) y convertida a un 'TensorBuffer' o 'ByteBuffer' con el formato exacto que el modelo espera. De igual manera, los tensores de salida del modelo deben ser decodificados para extraer la información útil, como las coordenadas de las cajas delimitadoras y las probabilidades de cada clase.

2.7.4 UI/UX para captura guiada y usabilidad en campo

Una aplicación técnicamente perfecta puede fracasar si su uso es complicado o frustrante para el operario. En el contexto de las JAAPS, donde los usuarios pueden tener distintos niveles de familiaridad con la tecnología, el diseño de la Interfaz de Usuario (UI) y la Experiencia de Usuario (UX) es un factor crítico de éxito.

El principio rector debe ser el de un **diseño centrado en la tarea**, minimizando la cantidad de pasos y decisiones que el usuario debe tomar. Una estrategia clave para mejorar la calidad de las imágenes de entrada es la **captura guiada**. Utilizando la API **CameraX** de Android, es posible superponer en la vista previa de la cámara una guía visual (por ejemplo, un recuadro o unas esquinas) que indique al operario cómo debe encuadrar el medidor. La aplicación puede incluso analizar los fotogramas de la vista previa en tiempo real para detectar cuándo el medidor está bien alineado y enfocado, y disparar la captura automáticamente, simplificando al máximo el proceso.

Además, el sistema debe proporcionar **feedback constante e inequívoco**. El uso de vibraciones (feedback háptico), sonidos cortos y cambios de color en la interfaz puede confirmar acciones como "captura exitosa", "procesando..." y "lectura reconocida", dando seguridad al operario en cada paso del proceso. Estos principios de diseño, enfocados en la simplicidad y la asistencia activa, son fundamentales para asegurar la adopción y el uso efectivo de la herramienta en las condiciones reales de campo.

Sin embargo, incluso la aplicación mejor diseñada y más usable fracasará si el motor de inteligencia artificial que la impulsa no es capaz de manejar la enorme variabilidad del entorno de campo. El diseño de la interfaz ayuda al usuario a capturar una buena imagen, pero es el modelo de IA el que debe ser intrínsecamente robusto a los desafíos visuales que presentan los medidores reales. La siguiente sección profundiza en estos desafíos específicos del contexto

rural, que constituyen la prueba de fuego final para la viabilidad de la tecnología.

2.8 Desafíos técnicos en los ambientes rurales de la sierra ecuatoriana

Si bien las secciones anteriores han delineado los habilitadores tecnológicos que hacen posible el AMR en dispositivos móviles, la eficacia de cualquier sistema de visión por computadora no se mide en condiciones ideales de laboratorio, sino en su capacidad para operar de manera robusta en el entorno de despliegue real. El contexto de las JAAPS en la sierra ecuatoriana presenta un conjunto de desafíos particulares que deben ser abordados explícitamente desde el diseño del modelo y el pipeline de procesamiento para garantizar su éxito y fiabilidad.

2.8.1 Impacto de las condiciones variables de iluminación y oclusión por suciedad/humedad

Los medidores de agua en el contexto rural no suelen encontrarse en condiciones ideales para una captura de imagen limpia. Su ubicación, a menudo a la intemperie o en nichos de difícil acceso, implica una exposición constante a factores ambientales que degradan la calidad de la imagen. De hecho, la literatura especializada en AMR para “escenarios no controlados” ha identificado precisamente estas condiciones como la causa principal de fallos en los sistemas de reconocimiento automático (Hong et al., 2021; Salomon et al., 2022).

Las **condiciones de iluminación** son el desafío más recurrente. Por un lado, la luz solar directa puede causar deslumbramientos y reflejos especulares sobre el visor de plástico o cristal del medidor, ocultando parcial o totalmente los dígitos. Por otro lado, los medidores ubicados en nichos o en días muy nublados sufren de sombras profundas y bajo contraste, dificultando la diferenciación entre los trazos de los dígitos y el fondo (Laroca et al., 2021).

La **oclusión por suciedad y humedad** es igualmente problemática. El polvo, el lodo y las telarañas pueden acumularse sobre el visor, obstruyendo la vista. Adicionalmente, la condensación interna o las gotas de lluvia en la superficie externa actúan como lentes que distorsionan la imagen subyacente, alterando la forma de los números y confundiendo a los algoritmos de reconocimiento. A esto se suma el **deterioro físico** de los propios medidores, muchos de los cuales llevan años en servicio y presentan rayones, visores amarillentos o descoloridos que reducen aún más la legibilidad.




Figura 2.7: Mapa mental que categoriza los principales desafíos para la lectura automática de medidores en entornos no controlados.

2.8.2 El problema de los dígitos en transición (“rolling digits”)

Un desafío inherente a los medidores mecánicos de tipo ciclómetro es el estado de transición de los dígitos. A medida que el consumo avanza, las ruedas numéricas giran, y durante un breve periodo, un dígito no se muestra de forma completa, sino que se observa la mitad inferior del número actual y la mitad superior del siguiente. Este fenómeno, conocido en la literatura como “rolling digits” o dígitos en transición, es una de las principales causas de error de los sistemas de OCR, incluso en los más avanzados (Laroca et al., 2021).

La ambigüedad de estos “medios caracteres” puede llevar al modelo a una clasificación incorrecta, generando un error de lectura que, dependiendo de la posición del dígito, puede tener un impacto significativo en la facturación. Abordar este problema requiere estrategias específicas que vayan más allá del entrenamiento con imágenes de dígitos completos. Una de las soluciones propuestas es la de tratar estos estados intermedios como clases nuevas y distintas. Por ejemplo, Shen et al. (2023) propone un esquema de “caracteres agentes”, donde se re-etiquetan manualmente estos casos para que el modelo aprenda a interpretarlos.

Sin embargo, la recolección de suficientes ejemplos de cada posible transición es una tarea ardua. Una solución más escalable y potente es el **aumento de datos generativo**. El trabajo de Sripanuskul et al. (2022) demuestra el uso de redes generativas (en su caso, un Y-Autoencoder) para crear artificialmente un gran volumen de imágenes sintéticas de alta calidad que simulan estos estados de transición. Al entrenar el modelo de OCR con este dataset aumentado, su capacidad para reconocer correctamente los dígitos en rotación mejora de manera drástica, demostrando ser una técnica de vanguardia para solventar este desafío específico.

2.8.3 La necesidad del procesamiento offline ante la conectividad intermitente

Una de las restricciones más determinantes del contexto rural de la sierra ecuatoriana es la infraestructura de comunicaciones. La cobertura de datos móviles es, en el mejor de los casos, intermitente, y en muchas de las áreas donde operan las JAAPS, es simplemente inexistente. Esta realidad invalida cualquier solución tecnológica que dependa de una conexión constante a internet para enviar imágenes a un servidor en la nube para su procesamiento (Fieldeke et al., 2021).

Por tanto, el **procesamiento offline** no es una característica deseable, sino un requisito de diseño fundamental y no negociable. El pipeline completo de visión por computadora —desde la detección del medidor y la corrección de perspectiva hasta el reconocimiento final de los dígitos— debe ejecutarse íntegramente en el hardware del dispositivo móvil. Esta restricción tiene implicaciones directas en la elección de la arquitectura del modelo y las técnicas de optimización, reforzando la necesidad de los habilitadores tecnológicos discutidos en la sección 2.6.

El enfoque “offline-first” garantiza la funcionalidad y autonomía de la herramienta en el 100 % del territorio de trabajo del operario. La sincronización de los datos ya procesados (las lecturas finales en formato de texto) puede ser gestionada de manera asíncrona, programando su envío a un servidor central para cuando el dispositivo se conecte a una red WiFi o de datos móviles, sin interrumpir ni depender de la conectividad durante la crucial tarea de recolección en campo (Carvalho et al., 2023; Santiago & Alvares, 2020).

2.9 Análisis comparativo de investigaciones clave

Una vez examinados los componentes tecnológicos y los desafíos inherentes a la lectura automática de medidores, es pertinente realizar un análisis comparativo y sistemático de las investigaciones más influyentes que conforman el estado del arte. Este análisis no busca ser un mero listado de trabajos, sino una síntesis crítica que permita identificar patrones,

tendencias dominantes y, fundamentalmente, las brechas de conocimiento que justifican la presente investigación. Para ello, se ha seleccionado una decena de estudios representativos publicados entre 2019 y 2025, los cuales se evalúan en función de su enfoque metodológico, el problema central que abordan, los conjuntos de datos que emplean y sus resultados más destacados. La Tabla 2.3 consolida esta evaluación comparativa.

Tabla 2.3: *Análisis comparativo de investigaciones previas en AMR.*

Referencia	Problema Central	Enfoque Metodológico	Resultados Clave	Contribución Principal
Chaki et al. (2019)	Automatización con métodos clásicos.	Proc. de Imágenes (Hough, Otsu, Correlación).	Acc: 96 %.	Demuestra un pipeline no basado en DL, aunque frágil.
Hong et al. (2021)	Robustez en entornos adversos.	YOLOv3 + Corrección de orientación y guianza espacial.	Mejora la robustez ante rotación y baja calidad.	Aporta corrección geométrica como paso clave pre-OCR.
Zou et al. (2021)	Eficiencia en dispositivos de borde.	Lightweight CNN con capas reconstruidas.	Acc: 98.85 % con modelo de baja complejidad.	Valida el alto rendimiento de arquitecturas ligeras.
Sripanuskul et al. (2022)	Escasez de datos y dígitos en transición.	Data Augmentation con Redes Generativas (Y-Autoencoder).	Mejora drástica en la precisión de "rolling digits".	Soluciona la escasez de datos para casos difíciles.
Carvalho et al. (2023)	Despliegue en tiempo real en el borde.	EAST Detector + CRNN en Android.	Latencia <1.5s en móvil de gama baja.	Valida la factibilidad de un pipeline completo en hardware real.
Peng et al. (2023)	Distorsión de perspectiva.	YOLO-CPDM (detección de esquinas) + OCR.	Acc: >99.6 %, Lat: <9ms.	Aporta rectificación de ROI de alta precisión.
Shen et al. (2023)	Reconocimiento de "medios caracteres".	DBnet + CRNN. Propone esquema de "caracteres agentes".	Mejora la precisión en 'rolling digits' del 61 % al 81 %.	Ofrece un enfoque pragmático para el re-etiquetado.
Khan et al. (2024)	AMR de bajo costo y alta precisión.	YOLOv8 + PaddleOCR afinado.	Acc. Reconocimiento: 96.92 %.	Demuestra el alto rendimiento de arquitecturas SOTA.
Van et al. (2025)	Comparativa de modelos de OCR.	YOLOv8 + 6 modelos OCR.	PP-OCRv3 es el más preciso (93 %).	Ofrece un benchmark directo para la etapa de OCR.
Wang et al. (2025)	Segmentación precisa de la ROI.	CAM-YOLOv8 (atención coordinada + MobileNet).	Acc. Segmentación: >99 %.	Representa el SOTA en la delimitación de la ROI.

El análisis comparativo de la Tabla 2.3 permite destilar varias tendencias clave. Primero, existe un consenso abrumador en la adopción de arquitecturas de aprendizaje profundo, habiendo dejado atrás los métodos de procesamiento de imágenes clásicos por su falta de

robustez. Segundo, dentro de los modelos de detección, la familia YOLO, y específicamente sus versiones más recientes como YOLOv8, se ha consolidado como el estándar de facto por su excelente equilibrio entre velocidad y precisión. Tercero, se observa una clara evolución en la complejidad del pipeline: los trabajos más avanzados ya no se conforman con una simple caja delimitadora, sino que incorporan pasos de corrección de perspectiva y orientación, reconociendo que la calidad de la localización de la ROI es un factor determinante para el éxito del OCR. Finalmente, una línea de investigación emergente y de alta relevancia para aplicaciones prácticas se centra en la eficiencia computacional y el despliegue en dispositivos de borde, validando la factibilidad de llevar estas soluciones de IA al campo de manera autónoma y offline.

2.10 Resultados: brecha identificada y oportunidades para el proyecto

El recorrido a través del estado del arte, desde el contexto socio-operativo de la gestión del agua hasta las arquitecturas de inteligencia artificial más avanzadas, permite trazar un mapa claro del panorama actual. Se ha evidenciado que la tecnología de visión por computadora para AMR es un campo maduro y en rápida evolución. Sin embargo, un análisis crítico de la literatura también revela brechas significativas entre las soluciones existentes y las necesidades concretas de las organizaciones comunitarias como las JAAPS. Esta sección final sintetiza las tendencias, define con precisión el vacío en la investigación actual y posiciona el presente proyecto de tesis como una respuesta directa y pertinente a dicho vacío.

2.10.1 Tendencias actuales y futuras en la automatización de lectura de medidores

El análisis comparativo de la sección anterior desvela tres tendencias dominantes que definen la frontera de la investigación en AMR:

1. **De la precisión a la robustez total:** La investigación ha trascendido la simple meta de reconocer dígitos en condiciones ideales. El foco actual está en desarrollar pipelines *end-to-end* que sean inherentemente robustos a los “escenarios no controlados”. Esto se manifiesta en la incorporación de módulos de corrección de perspectiva y orientación como un estándar de facto, y en la exploración de técnicas avanzadas, como el aumento de datos con redes generativas, para manejar los casos más complejos como los dígitos en transición (Peng et al., 2023; Sripanuskul et al., 2022).
2. **La inevitable transición al borde (Edge AI):** Existe un reconocimiento creciente de que la viabilidad de las soluciones de AMR a gran escala, especialmente en contextos con

conectividad limitada, depende de su capacidad para operar en el borde. Esto ha impulsado una intensa investigación en arquitecturas de CNN ligeras (Lightweight CNNs) y en técnicas de optimización como la cuantización, con el objetivo de ejecutar modelos complejos en el hardware limitado de un dispositivo móvil sin sacrificar la precisión (Carvalho et al., 2023; Zou et al., 2021).

3. **Hacia aplicaciones de valor añadido:** La tendencia futura apunta a utilizar los datos recolectados no solo para la facturación, sino para una gestión más inteligente de la red. La capacidad de analizar patrones de consumo en tiempo casi real abre la puerta a servicios como la detección temprana de fugas y la gestión proactiva de la demanda, transformando al medidor en un sensor clave para la sostenibilidad del sistema hídrico (Kainz et al., 2021).

2.10.2 El vacío existente: la falta de soluciones validadas para el contexto específico de las JAAPS

A pesar de la sofisticación técnica alcanzada, el estado del arte presenta una brecha fundamental cuando se contrasta con la realidad de las Juntas Administradoras de Agua Potable y Saneamiento. Esta brecha no es principalmente tecnológica, sino contextual y de aplicación.

Primero, la gran mayoría de los estudios y datasets públicos de alto impacto, como UFPR-AMR o Copel-AMR, se han desarrollado y validado en contextos geográficos y operativos (Brasil, China, Europa) muy diferentes a los de la sierra andina ecuatoriana (Laroca et al., 2021; Liang et al., 2022). No existen garantías de que un modelo entrenado con medidores brasileños pueda generalizar su rendimiento a la “fauna” de medidores, a menudo más antiguos y de diversa procedencia, que se encuentran en las JAAPS. Las condiciones climáticas (humedad, radiación UV) y ambientales (polvo) también presentan particularidades que no están representadas en los benchmarks existentes.

Segundo, y más importante, existe un abismo socio-económico. Las soluciones propuestas en la literatura son o bien prototipos académicos que no abordan la implementación completa, o bien se enmarcan en una lógica de mercado industrial inviable para una organización comunitaria y sin fines de lucro. No se ha reportado en la literatura una solución *end-to-end* que sea a la vez técnicamente robusta, de código abierto, diseñada para operación offline y con un modelo de despliegue y mantenimiento de costo casi nulo. La literatura sobre las ba-

rreras a la digitalización en zonas rurales confirma que la falta de soluciones tecnológicamente “apropiadas” es un obstáculo clave para el desarrollo (Fieldeke et al., 2021).

2.10.3 Justificación del enfoque propuesto a la luz del estado del arte

El enfoque de esta tesis se posiciona directamente en la intersección de las brechas identificadas. No busca inventar un nuevo algoritmo de reconocimiento desde cero, sino diseñar, integrar, optimizar y, crucialmente, **validar una solución completa en el contexto específico donde se necesita**.

El desarrollo de un prototipo móvil, basado en una arquitectura de CNN ligera para su ejecución offline en dispositivos Android, se alinea directamente con la tendencia de la industria hacia el Edge AI (Carvalho et al., 2023; Zou et al., 2021). La selección de un pipeline que utiliza un detector basado en YOLOv8 y un reconocedor de OCR avanzado como CRNN o PP-OCRv3 sigue el paradigma que la comunidad científica ha validado como el más efectivo (Khan et al., 2024; Van et al., 2025).

La contribución original y fundamental de esta investigación radica en abordar la brecha de validación contextual. Al crear un dataset propio a partir de los medidores de la JAAP de Jerusalén y probar el prototipo en las condiciones reales de campo que enfrentan sus operarios, este trabajo generará un conocimiento empírico invaluable sobre la aplicabilidad real de estas tecnologías de vanguardia en un entorno rural andino. Por lo tanto, esta tesis no solo aportará una solución tecnológica tangible y de alto impacto social, sino que también contribuirá con datos y hallazgos que enriquecerán el estado del arte global sobre la implementación de IA para la gestión sostenible del agua en comunidades.

Referencias

- Agencia de Cooperación Internacional del Japón (JICA). (2025). *Agua No Contabilizada: Documento Técnico 2025* (inf. téc.) (Documento de trabajo sobre la gestión de pérdidas de agua en Ecuador). JICA.
- Albonico, A., Pagliari, D. J., Risso, M., Averta, G., & Garza, P. (2023). A Benchmark of Deep Learning Frameworks for Mobile and Embedded Devices. *2023 IEEE 7th International Conference on Fog and Edge Computing (ICFEC)*, 90-99. <https://doi.org/10.1109/ICFEC58326.2023.00019>
- Banco Interamericano de Desarrollo (BID). (2022). *La Gestión Comunitaria del Agua en América Latina: Modelos, Desafíos y Oportunidades* (inf. téc.) (Documento de análisis sectorial sobre los servicios de agua y saneamiento). BID.
- Banco Interamericano de Desarrollo (IADB). (2022). *La Medición Inteligente en América Latina y el Caribe: Recomendaciones regulatorias para incentivar el despliegue* (inf. téc.). IADB. <https://publications.iadb.org/publications/spanish/document/La-Medicion-Inteligente-en-America-Latina-y-el-Caribe-Recomendaciones-regulatorias-para-incentivar-el-despliegue-de-la-medicion-inteligente-a-nivel-nacional.pdf>
- Carvalho, R., Melo, J., Graça, R., Santos, G., & Vasconcelos, M. J. M. (2023). Deep learning-powered system for real-time digital meter reading on edge devices. *Applied Sciences*, 13(4), 2315. <https://doi.org/10.3390/app13042315>
- Chaki, S., Shila, D. A., & Jahan, N. (2019). Automation of water meter billing process based on digital image processing approach. *Journal of Advances in Technology and Engineering Research*, 5(5), 207-218. <https://doi.org/10.20474/jater-5.5.3>
- Fieldeke, I. C., Schraven, A., & Jensen, C. B. (2021). Barriers to the Digital Transformation of Rural Water Services in Sub-Saharan Africa. *Water*, 13(16), 2273. <https://doi.org/10.3390/w13162273>
- Ghosh, A., PU, R., & Muralidhara, V. N. (2023). A Survey on Quantization Techniques in Deep Neural Networks. *SN Computer Science*, 4(4), 348. <https://doi.org/10.1007/s42979-023-01783-0>
- Global Growth Insights. (2023). Análisis del mercado de medidores de agua inteligentes 2023-2033 [Informe de mercado sobre tecnologías de medición de agua.].

- Hong, Q., Ding, Y., Lin, J., Wang, M., Wei, Q., Wang, X., & Zeng, M. (2021). Image-Based Automatic Watermeter Reading under Challenging Environments. *Sensors*, 21(2), 434. <https://doi.org/10.3390/s21020434>
- Instituto Nacional de Estadística y Censos (INEC). (2024). *Encuesta de Gestión de Agua Potable y Saneamiento 2023* (inf. téc.) (Publicado en el sitio web del INEC con resultados del año 2023). INEC. Quito, Ecuador.
- Kainz, O., Petija, R., Michalko, M., Jakab, F., & Dujava, M. (2021). Measurement of Water Consumption based on Image Processing. *2021 IEEE 19th World Symposium on Applied Machine Intelligence and Informatics (SAMI)*. <https://doi.org/10.1109/SAMI50585.2021.9378611>
- Khan, F., Rafique, S., & Khan, G. M. (2024). Low-Cost Smart Metering Using Deep Learning [DOI no encontrado]. *International Journal of Innovations in Science & Technology (IJIST), Special Issue*, 93-104.
- Ktari, J., Frikha, T., Hamdi, M., Elmannai, H., & Hmam, H. (2022). Lightweight AI Framework for Industry 4.0 Case Study: Water Meter Recognition. *Big Data and Cognitive Computing*, 6(3), 72. <https://doi.org/10.3390/bdcc6030072>
- Laroca, R., Araujo, A. B., Zanolrensi, L. A., Almeida, E. C. D., & Menotti, D. (2021). Towards Image-Based Automatic Meter Reading in Unconstrained Scenarios: A Robust and Efficient Approach. *IEEE Access*, 9, 67569-67584. <https://doi.org/10.1109/ACCESS.2021.3077415>
- Li, J., Yipeng-Gen, Chuan-Chi & Yichuan-Li. (2023). A Survey on Deep Learning-based Edge-AI. *arXiv preprint arXiv:2307.03967*.
- Liang, Y., Liao, Y., Li, S., Wu, W., Qiu, T., & Zhang, W. (2022). Research on water meter reading recognition based on deep learning. *Scientific Reports*, 12(1), 12861. <https://doi.org/10.1038/s41598-022-17255-3>
- Maheshwari, U., & Singh, K. K. (2023). Automatic Meter Detection and Recognition: A Robust Approach Based on Image Processing Techniques. *International Journal for Research in Applied Science and Engineering Technology (IJRASET)*, 11(6). <https://doi.org/10.22214/ijraset.2023.54438>
- Mehta, S., & Rastegari, M. (2022). MobileViT: Light-weight, General-purpose, and Mobile-friendly Vision Transformer. *International Conference on Learning Representations (ICLR)*.

- Naciones Unidas. (2015). Transformar nuestro mundo: la Agenda 2030 para el Desarrollo Sostenible [Resolución aprobada por la Asamblea General el 25 de septiembre de 2015. Consultado el 16 de junio de 2025]. <https://sdgs.un.org/2030agenda>
- Peng, J., Zhou, W., Han, Y., Li, M., & Liu, W. (2023). Deep learning-based autonomous real-time digital meter reading recognition method for natural scenes. *Measurement*, 222, 113615. <https://doi.org/10.1016/j.measurement.2023.113615>
- Poddar, A. K., Singh, S., & Chakraborty, T. (2024). A survey of deep learning models for resource-constrained edge devices. *Artificial Intelligence Review*. <https://doi.org/10.1007/s10462-024-10775-8>
- Roa-García, M. C., Brown, S., & Urquijo, J. (2019). Water Governance in Latin America: A Look at the Water-Energy-Food Nexus. *Water*, 11(1), 131. <https://doi.org/10.3390/w11010131>
- Salomon, G., Laroca, R., & Menotti, D. (2022). Image-Based Automatic Dial Meter Reading in Unconstrained Scenarios [También disponible como preimpresión de arXiv arXiv:2201.02850]. *Measurement*. <https://doi.org/10.1016/j.measurement.2022.112025>
- Santiago, G. V., & Alvares, A. J. (2020). Deployment framework for the Internet of water meters using computer vision on ARM platform. *Journal of Ambient Intelligence and Smart Environments*, 12, 35-60. <https://doi.org/10.3233/AIS-200544>
- Shen, Y., Wang, X., & Yin, M. (2023). Water Meter Reading Recognition Based on Deep Learning. *Proceedings of the 2nd International Conference on Algorithms, Data Mining, and Information Technology (ADMIT)*, 27-33. <https://doi.org/10.1145/3625403.3625409>
- Sripanuskul, N., Buayai, P., & Mao, X. (2022). Generative Data Augmentation for Automatic Meter Reading Using CNNs. *IEEE Access*, 10, 28471-28486. <https://doi.org/10.1109/ACCESS.2022.3157706>
- Tan, M., & Le, Q. V. (2021). EfficientNetV2: Smaller Models and Faster Training. *Proceedings of the 38th International Conference on Machine Learning (ICML)*, 10096-10106.
- Toma, C., Márquez, W., Pumisacho, V., Aldás, M., & Márquez, M. (2020). Factors Affecting the Sustainability of Rural Drinking Water Services in the Andean Region of Ecuador. *Sustainability*, 12(23), 9964. <https://doi.org/10.3390/su12239964>
- Van, B. N., Nguyen, A., Trung, K. T., Huong, T. H., Hong, H. D. T., Trung, H. N., & Hoang, V. T. (2025). Water Meter Reading Based on Text Recognition Techniques and Deep Learning. *IEEE Access*. <https://doi.org/10.1109/ACCESS.2025.3547225>

- Wang, H., Wang, N., & An, X. (2025). CAM-YOLO v8: A model for water meter word wheel region segmentation. *Proceedings of the 2nd International Conference on Generative Artificial Intelligence and Information Security (GAIIIS)*. <https://doi.org/10.1145/3728725.3728769>
- Zou, F., Shi, Z., Gan, Z., Liao, L., & Xu, J. (2021). Water Meter Reading Recognition Based on Lightweight CNN. *Proceedings of the International Conference on Frontiers of Electronics, Information and Computation Technologies (ICFEICT)*. <https://doi.org/10.1145/3474198.3478237>