



UNIVERSIDAD TÉCNICA PARTICULAR DE LOJA

La Universidad Católica de Loja

FACULTAD DE INGENIERÍAS Y ARQUITECTURA

MAESTRÍA EN INTELIGENCIA ARTIFICIAL APLICADA

**Desarrollo de un prototipo móvil para la lectura de
medidores de agua potable usando técnicas de
procesamiento de imágenes**

Trabajo de titulación previo a la obtención del título de:

MAGÍSTER EN INTELIGENCIA ARTIFICIAL APLICADA

Autor: Pillaga Zhagñay, Luis Antonio

Director: Riofrio Calderón, Guido Eduardo

LOJA

2025

Aprobación del director del Trabajo de Titulación

Loja, 15 de febrero de 2025

Doctor

Luis Rodrigo Barba Guamán

Director de la maestría de Inteligencia Artificial Aplicada

Loja.-

De mi consideración:

Me permito comunicar que, en calidad de director del presente Trabajo de Titulación nominado: Desarrollo de un prototipo móvil para la lectura de medidores de agua potable usando técnicas de procesamiento de imágenes realizado por Luis Antonio Pillaga Zhagñay ha sido orientado y revisado durante su ejecución, así mismo ha sido verificado a través de la herramienta de similitud académica institucional, y cuenta con un porcentaje de coincidencia aceptable. En virtud de ello, y por considerar que el mismo cumple con todos los parámetros establecidos por la Universidad, doy mi aprobación a fin de continuar con el proceso académico correspondiente.

Particular que comunico para los fines pertinentes.

Atentamente,

Director: Guido Eduardo Riofrio Calderón, PhD.

C.I.: 1103214969

Correo electrónico: geriofrio@utpl.edu.ec

Declaración de autoría y cesión de derechos

Yo, Luis Antonio Pillaga Zhagñay, declaro y acepto en forma expresa lo siguiente:

Ser autor del Trabajo de Titulación denominado: Desarrollo de un prototipo móvil para la lectura de medidores de agua potable usando técnicas de procesamiento de imágenes, de la maestría en Inteligencia Artificial Aplicada, específicamente de los contenidos comprendidos en: Introducción, Capítulo 1: Marco Teórico, Capítulo 2: Metodología, Capítulo 3: Desarrollo y Resultados, Conclusiones y Recomendaciones, siendo Guido Eduardo Riofrio Calderón, director del presente trabajo; también declaro que la presente investigación no vulnera derechos de terceros ni utiliza fraudulentamente obras preexistentes. Además, ratifico que las ideas, criterios, opiniones, procedimientos y resultados vertidos en el presente trabajo investigativo, son de mi exclusiva responsabilidad. Eximo expresamente a la Universidad Técnica Particular de Loja y a sus representantes legales de posibles reclamos o acciones judiciales o administrativas, en relación a la propiedad intelectual de este trabajo.

Que la presente obra, producto de mis actividades académicas y de investigación, forma parte del patrimonio de la Universidad Técnica Particular de Loja, de conformidad con el artículo 20, literal j), de la Ley Orgánica de Educación Superior; y, artículo 91 del Estatuto Orgánico de la UTPL, que establece: “Forman parte del patrimonio de la Universidad la propiedad intelectual de investigaciones, trabajos científicos o técnicos y tesis de grado que se realicen a través, o con el apoyo financiero, académico o institucional (operativo) de la Universidad”, en tal virtud, cedo a favor de la Universidad Técnica Particular de Loja la titularidad de los derechos patrimoniales que me corresponden en calidad de autor/a, de forma incondicional, completa, exclusiva y por todo el tiempo de su vigencia.

La Universidad Técnica Particular de Loja queda facultada para ingresar el presente trabajo al Sistema Nacional de Información de la Educación Superior del Ecuador para su difusión pública, en cumplimiento del artículo 144 de la Ley Orgánica de Educación Superior.

Autor: Luis Antonio Pillaga Zhagñay

C.I.: 0301971495

Correo electrónico: lapillaga2@utpl.edu.ec

Dedicatoria

Este trabajo representa el fruto de años de esfuerzo, dedicación y el apoyo incondicional de personas muy especiales en mi vida. Con profundo cariño y gratitud, dedico este logro:

A mi madre Julia Zhagñay, por cada una de sus palabras de aliento durante todos mis años de estudio. Su apoyo incondicional ha sido mi fortaleza, y agradezco profundamente su mejor legado: el valor de siempre procurar ser una buena persona.

A mi segunda madre, Evangelina Dután, quien sin lazos de sangre pero con un corazón inmenso, siempre estuvo dispuesta a acogerme y velar por mi bienestar. Aunque ya no estés físicamente conmigo, sé que desde el cielo continúas cuidándome y guiando mis pasos.

A mi nueva familia, Lesly y Luis Nicolás, quienes se convirtieron en el motor que me impulsó a dar este importante paso. Su apoyo y comprensión fueron fundamentales para que pudiera completar este trabajo.

Finalmente, extendiendo mi gratitud a cada ser humano que ha formado parte de mi camino, aportando a mi crecimiento personal y profesional, y enseñándome las valiosas lecciones que la vida ofrece en sus múltiples facetas.

Agradecimiento

TODO

Índice de contenido

Carátula	I
Aprobación del director del Trabajo de Titulación.....	I
Declaración de autoría y cesión de derechos	II
Dedicatoria	III
Agradecimiento	IV
Resumen	1
Abstract.....	2
Introducción.....	3
1 Introducción	4
1.1 Contextualización del Problema: El Agua y Saneamiento en el Sector Rural.....	4
1.2 Problemática	5
1.3 Justificación	6
1.4 Objetivos.....	7
1.4.1 Objetivo general	7
1.4.2 Objetivos específicos	7
1.5 Alcance y Limitaciones	7
1.5.1 Alcance del Proyecto	8
1.5.2 Limitaciones de la Investigación	8
1.6 Estructura del Documento	9
2 Estado del arte	10
2.1 Gestión del agua en comunidades rurales: contexto y desafíos tecnológicos	10
2.1.1 Las JAAPS como modelo de gestión comunitaria del agua	10
2.1.2 Evolución tecnológica en la lectura de medidores de agua	11
2.2 Reconocimiento óptico de caracteres aplicado a medidores	13
2.2.1 Fundamentos del OCR en entornos industriales	13
2.2.2 Arquitecturas de redes neuronales para OCR	14
2.2.3 Datasets y benchmarks relevantes	16
2.3 Deep Learning en dispositivos móviles con recursos limitados.....	17
2.3.1 Arquitecturas eficientes para edge computing	17
2.3.2 Optimización y compresión de modelos	18

2.3.3	Frameworks de inferencia móvil	18
2.4	Sistemas de visión artificial para lectura automática de medidores	19
2.4.1	Pipeline completo de procesamiento	19
2.4.2	Robustez ante condiciones adversas	21
2.4.3	Implementaciones existentes: análisis crítico	22
2.5	Desarrollo de aplicaciones móviles offline con IA integrada.....	23
2.5.1	Arquitecturas offline-first.....	23
2.5.2	Integración de modelos de IA en Android	24
2.5.3	Consideraciones de usabilidad rural	26
2.6	Análisis comparativo y oportunidades de innovación	27
2.6.1	Matriz de evaluación de soluciones existentes	27
2.6.2	Brechas identificadas en el estado del arte	29
2.6.3	Justificación del enfoque propuesto	30
3	Metodología	32
3.1	Enfoque general del desarrollo	32
3.2	Fases metodológicas del proyecto	32
3.2.1	Revisión de literatura	32
3.2.2	Construcción del dataset.....	32
3.2.3	Entrenamiento y optimización de modelos	32
3.2.4	Desarrollo de la aplicación	32
3.2.5	Validación del prototipo	32
3.3	Herramientas y tecnologías utilizadas	32
3.4	Consideraciones éticas y operativas	32
4	Desarrollo del sistema.....	33
4.1	Diseño de la arquitectura del sistema.....	33
4.2	Adquisición, etiquetado y depuración del dataset	33
4.3	Diseño y entrenamiento del modelo OCR ligero	33
4.4	Implementación de lógica de captura asistida de imágenes	33
4.5	Desarrollo de la aplicación móvil y sincronización de datos.....	33
4.6	Integración del sistema y pruebas internas	33
5	Evaluación y resultados	34
5.1	Diseño de experimentos y métricas de evaluación	34

5.2	Resultados de precisión, latencia y eficiencia energética	34
5.3	Comparativa con procesos tradicionales de lectura	34
5.4	Validación en campo con usuarios reales	34
5.5	Discusión de resultados y cumplimiento de objetivos	34
6	Conclusiones y recomendaciones	35
6.1	Conclusiones generales	35
6.2	Lecciones aprendidas del proceso de desarrollo	35
6.3	Limitaciones técnicas y metodológicas.....	35
6.4	Recomendaciones para futuras investigaciones	35
6.5	Posibilidades de escalabilidad y transferencia tecnológica	35
	Referencias	36

Índice de tablas

2.1	Comparativa de arquitecturas eficientes modernas (ejemplo en ImageNet).....	18
2.2	Análisis crítico de tipos de implementaciones de lectura automática.....	22
2.3	Tabla de consideraciones de diseño de UI/UX para contextos rurales.	27
2.4	Matriz de evaluación comparativa de soluciones para lectura de medidores en el contexto de las JAAPS.	28

Índice de figuras

2.1	Pipeline completo de procesamiento para la lectura automática de medidores.....	20
2.2	Arquitectura recomendada para una aplicación offline-first en Android.	24

Resumen

El resumen se presentará en un único párrafo con un máximo de **180 palabras**, sintetiza el aporte que brinda el trabajo realizado. **Obligatoriamente** debe contener las palabras clave (**máximo tres**).

Ejemplo:

Texto por completar. El resumen debe ser claro y conciso, describiendo los objetivos, metodología, resultados y conclusiones del trabajo de investigación o proyecto. Es importante que el lector pueda entender rápidamente el propósito y los hallazgos principales sin necesidad de profundizar en el documento completo.

Palabras clave: xxxxxxxxx, xxxxxxxx, xxxxxx.

Abstract

Abstract es el resumen traducido al idioma inglés en donde se incluyen las palabras claves.

Obligatoriamente debe contener las palabras claves (**máximo tres**).

Ejemplo:

Texto por completar. The abstract should be clear and concise, summarizing the objectives, methodology, results, and conclusions of the research or project. It is important that the reader can quickly understand the purpose and main findings without needing to delve into the full document.

Keywords: xxxxxxxxx, xxxxxxxx, xxxxxx.

Introducción

Se sugiere presentar en máximo **dos páginas** y considerar los siguientes puntos:

Capítulo uno

Introducción

1.1 Contextualización del Problema: El Agua y Saneamiento en el Sector Rural

El acceso a agua potable y saneamiento constituye un derecho humano fundamental, reconocido como una piedra angular para el desarrollo sostenible, la salud pública y la prosperidad económica. La comunidad internacional ha ratificado su importancia a través de la Agenda 2030, donde el Objetivo de Desarrollo Sostenible 6 (ODS 6) insta a "garantizar la disponibilidad y la gestión sostenible del agua y el saneamiento para todos" (Naciones Unidas, 2015). A pesar de los avances globales, persisten brechas significativas, especialmente en las zonas rurales de países en desarrollo, donde las comunidades a menudo dependen de modelos de gestión descentralizados y comunitarios para la prestación de estos servicios esenciales.

En el contexto de América Latina, y específicamente en Ecuador, las Juntas Administradoras de Agua Potable y Saneamiento (JAAPS) emergen como la estructura predominante y legalmente reconocida para la gestión del agua en el sector rural. Se estima que existen más de 5,000 de estas organizaciones en el país, brindando servicio a un porcentaje significativo de la población rural dispersa y desempeñando un rol crucial que el Estado no siempre logra cubrir (Banco Interamericano de Desarrollo (BID), 2022; Roa-García et al., 2019). Su labor no solo garantiza el suministro de agua a millones de personas, sino que también fomenta la cohesión social y la gobernanza local de los recursos naturales. Este modelo representa una forma de gestión democrática descentralizada; por lo tanto, fortalecer su capacidad operativa no es solo una mejora técnica, sino una intervención directa para robustecer las instituciones comunitarias y la resiliencia local.

Sin embargo, la sostenibilidad de estas organizaciones enfrenta un desafío paradójico. Si bien son efectivas para expandir la cobertura, a menudo luchan con limitaciones técnicas, financieras y administrativas que comprometen su viabilidad a largo plazo (Toma et al., 2020). La falta de herramientas tecnológicas adaptadas a su realidad operativa, caracterizada por recursos limitados y brechas de capacidad técnica, agrava estas dificultades y amenaza la calidad y continuidad del servicio. Este trabajo de titulación se enmarca en la búsqueda de soluciones tecnológicas pertinentes y apropiadas para fortalecer a estas organizaciones vitales, mejorando su autosuficiencia y capacidad de gestión.

1.2 Problemática

Si bien las JAAPS son un pilar en la gestión del agua rural, su modelo operativo tradicional se ve amenazado por un conjunto de ineficiencias críticas que comprometen su sostenibilidad financiera y la confianza de la comunidad. El núcleo de esta problemática reside en el proceso de toma de lecturas, una tarea manual que es fundamental para el ciclo de facturación y la gestión del recurso. Este proceso, que implica el desplazamiento de un operario para transcribir los valores de cada medidor en papel, es inherentemente lento, laborioso y propenso a errores humanos que contribuyen directamente a las *pérdidas comerciales* del sistema (Chaki et al., 2019). Estas pérdidas aparentes, causadas por errores en la lectura y en la manipulación de datos, generan una subvaloración del consumo real, conduciendo a una facturación imprecisa y a la pérdida de ingresos vitales para la junta (Agencia de Cooperación Internacional del Japón (JICA), 2025).

La magnitud del problema es alarmante. El Agua No Contabilizada (ANC), un indicador que engloba tanto las pérdidas técnicas (fugas) como las comerciales, alcanza un promedio nacional del 51.8 % en los sistemas gestionados por los Gobiernos Autónomos Descentralizados (GAD) Municipales, con cifras que pueden ser aún mayores en sistemas comunitarios más pequeños (Instituto Nacional de Estadística y Censos (INEC), 2024). Estas imprecisiones se ven agravadas por los desafíos logísticos. El personal de las JAAPS debe cubrir áreas geográficamente dispersas, a menudo con topografía compleja, lo que resulta en demoras operativas. Además, la dependencia de una conectividad a internet intermitente o inexistente en muchas de estas zonas ha sido una barrera histórica para la adopción de soluciones digitales, que frecuentemente requieren una conexión constante (Fieldeke et al., 2021). Esta “brecha digital” obliga a las JAAPS a perpetuar flujos de trabajo basados en papel, con la consecuente duplicación de esfuerzos para la digitación de datos, introduciendo una segunda fuente de posibles errores.

Las consecuencias de estas fallas operativas son sistémicas. Una facturación errónea erosiona la confianza de los usuarios, lo que puede derivar en una cultura de impago y afectar la recaudación. A su vez, la falta de datos de consumo fiables impide a la directiva realizar análisis técnicos esenciales, como el cálculo del balance hídrico o la detección temprana de fugas, componentes clave para la gestión sostenible del recurso (Agencia de Cooperación Internacional del Japón (JICA), 2025). En última instancia, este círculo vicioso de ineficiencia y debilidad técnica limita la capacidad de las JAAPS para planificar inversiones, realizar mantenimientos

y garantizar la sostenibilidad a largo plazo del servicio.

1.3 Justificación

La presente investigación se justifica en tres dimensiones interconectadas que responden directamente a la problemática expuesta.

En primer lugar, desde una perspectiva tecnológica, el proyecto es oportuno y pertinente. Los avances recientes en el campo del aprendizaje profundo (deep learning), específicamente en arquitecturas de redes neuronales convolucionales (CNN) optimizadas para dispositivos de bajos recursos, han abierto la puerta a soluciones que antes eran inviables. El uso de frameworks como TensorFlow Lite permite encapsular modelos de visión por computadora potentes en un formato ligero, capaz de ejecutar la inferencia directamente en un teléfono móvil estándar sin depender de una conexión a internet (Carvalho et al., 2023b). Esta capacidad de procesamiento local (edge computing) es precisamente la innovación técnica que permite superar la barrera de la conectividad intermitente, el principal obstáculo para la digitalización de procesos en las zonas rurales atendidas por las JAAPS.

En segundo lugar, la justificación social y económica es directa y de alto impacto. Al automatizar el proceso de lectura de medidores, el prototipo propuesto tiene el potencial de reducir drásticamente los errores de facturación, incrementando la precisión y, por ende, la recuperación de ingresos para las juntas. Esta optimización de recursos no solo fortalece la sostenibilidad financiera de la organización, sino que también libera tiempo del personal, que puede ser reasignado a tareas críticas de mantenimiento y operación de la red. De esta manera, el proyecto se alinea con la Meta 6.B de la Agenda 2030 para el Desarrollo Sostenible, que promueve explícitamente el apoyo y fortalecimiento de la participación de las comunidades locales en la mejora de la gestión del agua y el saneamiento (Naciones Unidas, 2015).

Finalmente, el proyecto presenta una clara justificación científica. Si bien existen soluciones genéricas de Reconocimiento Óptico de Caracteres (OCR), su rendimiento en condiciones no controladas ("in the wild") es a menudo deficiente. La contribución de esta tesis radica en el desarrollo y la validación de un pipeline de visión artificial especializado para el dominio específico de los medidores de agua en contextos rurales, los cuales presentan una alta variabilidad de modelos, estados de deterioro, condiciones de iluminación y oclusiones parciales. La investigación aportará un dataset específico para esta tarea y analizará la eficacia de arquitecturas de modelos ligeros y técnicas de *data augmentation* para lograr la alta precisión ($\geq 98\%$) requerida. Por lo tanto, el trabajo no solo resuelve un problema práctico, sino

que también contribuye con conocimiento aplicable al campo del OCR en entornos industriales desafiantes y en hardware con recursos limitados.

1.4 Objetivos

1.4.1 Objetivo general

Desarrollar un prototipo móvil que permita la lectura automática de medidores de agua potable mediante técnicas de procesamiento de imágenes, orientado a optimizar la gestión de las JAAPS en el sector rural ecuatoriano.

1.4.2 Objetivos específicos

1. Realizar una revisión sistemática de la literatura sobre técnicas de detección de objetos y reconocimiento óptico de caracteres (OCR) aplicadas a la lectura de medidores, con énfasis en modelos optimizados para dispositivos móviles.
2. Construir un dataset de imágenes de medidores de agua potable, capturadas en condiciones reales de las JAAPS, que sirva para el entrenamiento y la validación de los modelos de inteligencia artificial.
3. Diseñar, entrenar y optimizar un *pipeline* de visión artificial de dos etapas, compuesto por un detector de objetos para la localización del contador y un modelo de Reconocimiento Óptico de Caracteres (OCR) basado en redes neuronales convolucionales y recurrentes (CRNN), para la lectura de la secuencia de dígitos, asegurando una alta precisión y baja latencia en un entorno móvil *offline*.
4. Diseñar y desarrollar una aplicación móvil para la plataforma Android que integre el modelo de IA y ofrezca un flujo de trabajo completo, desde la captura de la imagen hasta el registro de la lectura de forma local.
5. Validar el prototipo en condiciones de campo controladas, evaluando su precisión, eficiencia y usabilidad en comparación con el método de lectura manual tradicional utilizado por las JAAPS.

1.5 Alcance y Limitaciones

A continuación, se definen las fronteras del presente trabajo de titulación, especificando tanto los entregables y funcionalidades que se desarrollarán, como los aspectos que quedan fuera del estudio.

1.5.1 Alcance del Proyecto

El alcance de esta investigación cubre los siguientes puntos:

- El desarrollo de un prototipo funcional de una aplicación móvil para la plataforma Android, capaz de capturar imágenes de medidores de agua.
- La creación de un dataset de imágenes propio, compuesto por fotografías de medidores de agua analógicos, recolectadas en condiciones de campo representativas de las Juntas Administradoras de Agua Potable y Saneamiento (JAAPS) rurales.
- El entrenamiento y la optimización de un modelo de aprendizaje profundo (OCR), específicamente diseñado para la detección y lectura de los dígitos de los medidores de agua, y preparado para su ejecución local en el dispositivo móvil (offline).
- La implementación de un flujo de trabajo en la aplicación que permite al usuario capturar la imagen, recibir la lectura procesada por el modelo de IA y registrarla de forma local en el dispositivo.
- La validación técnica del prototipo en un entorno de campo controlado, donde se medirá y comparará su precisión y el tiempo de lectura frente al método manual tradicional.

1.5.2 Limitaciones de la Investigación

Para mantener el enfoque del proyecto, se establecen las siguientes limitaciones:

- El prototipo no es un sistema de gestión comercial completo. No incluirá funcionalidades avanzadas de facturación, gestión de abonados, o generación de reportes complejos, aunque su diseño permitirá la integración futura con dichos sistemas.
- El modelo de OCR se especializará en los medidores de tipo analógico (de reloj o dial) identificados en el estudio. No se abordará la lectura de medidores digitales ni de modelos analógicos con características muy atípicas que no formen parte del dataset.
- La aplicación móvil se desarrollará exclusivamente para la plataforma Android. No se crearán versiones para otros sistemas operativos como iOS.
- La validación se centrará en la viabilidad y el rendimiento técnico (precisión, eficiencia) del prototipo. No se realizará un estudio a largo plazo sobre el impacto socioeconómico de la adopción de la herramienta en las JAAPS.

- El despliegue y las pruebas de campo se realizarán con un número limitado y representativo de JAAPS, por lo que los resultados no pueden ser generalizados a todas las juntas del país sin estudios adicionales de escalabilidad.

1.6 Estructura del Documento

El presente trabajo de titulación se organiza en cinco capítulos, estructurados de la siguiente manera para presentar la investigación de forma lógica y coherente:

- **Capítulo 1: Introducción.** En el presente capítulo se ha contextualizado la problemática de la gestión del agua en las JAAPS rurales, se ha planteado el problema de la lectura manual de medidores y se ha justificado la necesidad de la investigación desde una perspectiva tecnológica, social y científica. Además, se han definido los objetivos, el alcance y las limitaciones del proyecto.
- **Capítulo 2: Marco Teórico y Estado del Arte.** Este capítulo presentará una revisión sistemática de la literatura científica. Se abordarán los fundamentos de la visión por computadora, las arquitecturas de redes neuronales convolucionales para detección de objetos, y las técnicas de Reconocimiento Óptico de Caracteres (OCR), con un enfoque en su aplicación y optimización para dispositivos móviles.
- **Capítulo 3: Metodología.** Se detallará el plan de trabajo y el diseño experimental de la investigación. Se describirá el proceso de recolección y anotación de imágenes para la creación del dataset, la selección de la arquitectura del modelo de IA, las métricas de evaluación, y el protocolo diseñado para la validación del prototipo en condiciones de campo.
- **Capítulo 4: Desarrollo y Resultados.** En este capítulo se expondrá el proceso de desarrollo de la aplicación móvil y la implementación del modelo de IA. Posteriormente, se presentarán de manera objetiva los resultados obtenidos durante la fase de validación, incluyendo las métricas de precisión, eficiencia y una comparativa con el método manual.
- **Capítulo 5: Discusión.** Se realizará un análisis crítico y una interpretación de los resultados presentados en el capítulo anterior, poniéndolos en diálogo con la literatura científica y los objetivos de la investigación. Se examinarán las implicaciones de los hallazgos y el valor de la solución propuesta.

Capítulo dos

Estado del arte

2.1 Gestión del agua en comunidades rurales: contexto y desafíos tecnológicos

2.1.1 *Las JAAPS como modelo de gestión comunitaria del agua*

En Ecuador, el acceso al agua potable en zonas rurales es una tarea compleja que el Estado no logra cubrir en su totalidad. Como respuesta a esta necesidad, el marco legal ecuatoriano reconoce y promueve la gestión comunitaria del agua como un pilar fundamental para garantizar este derecho (Banco Interamericano de Desarrollo (BID), 2022, p. 16). Dentro de este esquema, las Juntas Administradoras de Agua Potable y Saneamiento (JAAPS) emergen como la figura organizativa predominante. Son organizaciones sin fines de lucro, conformadas y dirigidas por los propios miembros de la comunidad, responsables de la administración, operación y mantenimiento de los sistemas de agua potable a pequeña escala. Se estima que existen más de 5,000 de estas organizaciones en el país, brindando servicio a un porcentaje significativo de la población rural dispersa.

La estructura organizativa de una JAAP típica es democrática y voluntaria. Consta de una asamblea general de usuarios, que es la máxima autoridad, y un directorio elegido periódicamente, compuesto por un presidente, un tesorero, un secretario y vocales. Estos directivos, a menudo sin remuneración, son responsables de toda la gestión administrativa y técnica. Su labor es fundamental para la sostenibilidad del servicio, pero está sujeta a las capacidades y el tiempo que sus miembros puedan dedicar, lo cual representa un primer nivel de vulnerabilidad institucional (Toma et al., 2020). El éxito de este modelo depende en gran medida del compromiso comunitario y de la capacidad de la junta para gestionar eficientemente los recursos, tanto hídricos como financieros.

El proceso operativo de lectura de medidores, base para la facturación, es uno de los eslabones más críticos y donde se manifiestan mayores ineficiencias. Este proceso se desarrolla de manera casi exclusivamente manual y sigue una secuencia de pasos bien definida pero propensa a errores:

1. **Planificación de la ruta:** Un miembro de la junta, conocido como “operador”, organiza una ruta para visitar los domicilios de todos los usuarios del sistema, que pueden estar geográficamente dispersos en terrenos de difícil acceso.

2. **Toma de lectura manual:** El lector se desplaza a cada domicilio y registra visualmente el valor que marca el medidor de agua. Este dato se anota a mano en una libreta o formulario de papel. Aquí surgen los primeros problemas: medidores en mal estado, con visores opacos, sucios o ubicados en lugares de difícil acceso que complican una lectura correcta.
3. **Transcripción de datos:** Al finalizar la ruta, el lector o el tesorero de la junta transcribe los datos de la libreta a un registro central, que puede ser un cuaderno o una hoja de cálculo básica en una computadora, si se dispone de ella. Este doble paso de digitación es una fuente importante de errores.
4. **Cálculo del consumo y facturación:** Con la lectura actual y la del mes anterior, se calcula el consumo y se emite una factura o recibo de pago, nuevamente de forma manual.

Los errores en este proceso tienen un impacto directo y severo en la sostenibilidad financiera de las JAAPS. Un error de digitación puede resultar en una subfacturación, privando a la junta de ingresos necesarios para cubrir costos de operación, mantenimiento y cloración. O, por el contrario, puede generar una sobrefacturación, creando desconfianza y conflictos con los usuarios. Estudios preliminares en el contexto de esta investigación sugieren desviaciones de hasta un 10 % en los registros. Esta cifra es alarmante, pues se suma al problema del Agua No Contabilizada (ANC), que según informes nacionales puede llegar a superar el 50 % en sistemas gestionados localmente, aunque el promedio nacional para GAD Municipales ya es del 51.8 % (Instituto Nacional de Estadística y Censos (INEC), 2024, p. 15). La combinación de pérdidas técnicas (fugas) y comerciales (errores de lectura, conexiones clandestinas) debilita un modelo de gestión que ya opera con recursos muy limitados (Agencia de Cooperación Internacional del Japón (JICA), 2025).

2.1.2 Evolución tecnológica en la lectura de medidores de agua

La medición del consumo de agua es la piedra angular de la gestión comercial de cualquier proveedor de servicios. Históricamente, este proceso ha dependido de métodos manuales, cuyas limitaciones se han hecho cada vez más evidentes. La lectura manual tradicional, como la descrita para las JAAPS, es intensiva en mano de obra, lenta y con una alta propensión al error humano (Chaki et al., 2019). Los desafíos van desde las dificultades físicas de acceso a los medidores hasta los errores de transcripción, pasando por la falta de datos en tiempo real que impide una gestión proactiva de la red, como la detección temprana de fugas

o consumos anómalos.

Como respuesta a estas limitaciones, la industria del agua ha desarrollado tecnologías progresivamente más sofisticadas. La primera gran evolución fue la Lectura Automática de Medidores (AMR, por sus siglas en inglés). Los sistemas AMR permiten que los datos del medidor se transmitan de forma remota a un dispositivo de recopilación cercano, generalmente mediante tecnología de radiofrecuencia. Esto elimina la necesidad de que el personal acceda visualmente al medidor, reduciendo errores y acelerando el proceso, ya que un operador puede recoger las lecturas simplemente pasando en un vehículo cerca de los domicilios (*drive-by*) (Banco Interamericano de Desarrollo (IADB), 2022). Si bien AMR representa un avance significativo, todavía requiere el despliegue de personal en el campo y no proporciona una infraestructura de comunicación bidireccional.

El siguiente paso en esta evolución es la Infraestructura de Medición Avanzada (AMI), que utiliza redes de comunicación fijas (como redes celulares o de fibra óptica) para establecer un enlace bidireccional continuo entre el medidor inteligente y el sistema central de la empresa de servicios públicos. AMI no solo automatiza la lectura, sino que permite la monitorización en tiempo real, la gestión remota de la válvula de suministro y la provisión de información detallada sobre el consumo al usuario final (Global Growth Insights, 2023). Esta tecnología es la base de las redes de agua inteligentes o *smart water grids*.

A pesar de sus ventajas, la adopción de AMR y, especialmente, de AMI en zonas rurales de países en desarrollo ha sido prácticamente nula. La razón principal es la barrera económica. Los costos de inversión inicial son prohibitivos para organizaciones comunitarias como las JAAPS. Un medidor inteligente y su módulo de comunicación pueden costar entre 5 y 10 veces más que un medidor mecánico tradicional. A esto se suma el costo de la infraestructura de red, el software de gestión y la capacitación técnica especializada para su mantenimiento (Fieldeke et al., 2021). Adicionalmente, la falta de conectividad a internet fiable y la inestabilidad del suministro eléctrico en muchas áreas rurales representan obstáculos técnicos insuperables para estas tecnologías (Banco Interamericano de Desarrollo (IADB), 2022).

En este contexto, las soluciones basadas en visión artificial y dispositivos móviles emergen como una alternativa prometedora y de bajo costo. Este enfoque no requiere reemplazar la infraestructura de medidores existente. En su lugar, utiliza la cámara de un teléfono inteligente estándar para capturar una imagen del medidor mecánico y un software de Reconocimiento Óptico de Caracteres (OCR) para extraer la lectura digitalmente (Laroca et al., 2021). El costo

de implementación se reduce drásticamente, ya que el principal hardware es un smartphone, un dispositivo de uso cada vez más extendido incluso en zonas rurales. Investigaciones recientes han demostrado la alta precisión de los modelos de deep learning para esta tarea, incluso en condiciones de campo desafiantes, como medidores sucios, con reflejos o en ángulos difíciles (Hong et al., 2021; Liang et al., 2022; Peng et al., 2023). Esta aproximación representa un puente tecnológico: aprovecha la infraestructura de medición ya desplegada y la combina con la potencia de la inteligencia artificial en el borde (edge AI) para digitalizar el proceso de lectura con una inversión mínima (Carvalho et al., 2023b; Ktari et al., 2022).

2.2 Reconocimiento óptico de caracteres aplicado a medidores

Habiendo establecido la necesidad de una solución de bajo costo y alta eficiencia para las JAAPS en la sección anterior, esta sección profundiza en la tecnología clave que permite dicha solución: el Reconocimiento Óptico de Caracteres (OCR). Se examinan las tecnologías OCR específicamente aplicadas al reconocimiento de dígitos en medidores de agua, desde sus fundamentos y la evolución hacia el deep learning, hasta las arquitecturas de redes neuronales más avanzadas y los conjuntos de datos necesarios para su entrenamiento y validación.

2.2.1 Fundamentos del OCR en entornos industriales

El Reconocimiento Óptico de Caracteres es un campo de la inteligencia artificial y la visión por computadora cuyo objetivo es convertir imágenes que contienen texto, ya sea manuscrito, mecanografiado o impreso, en texto codificado que una máquina puede procesar. Históricamente, los sistemas de OCR se basaban en un pipeline de múltiples etapas, fuertemente dependiente de técnicas clásicas de procesamiento de imágenes. Este pipeline tradicional generalmente incluía: preprocesamiento de la imagen (ej. conversión a escala de grises, binarización mediante umbrales como el de Otsu), segmentación para aislar caracteres individuales (ej. mediante análisis de perfiles de proyección), extracción de características de cada carácter (ej. momentos, transformadas de Fourier) y, finalmente, clasificación usando algoritmos como Support Vector Machines (SVM) o k-Nearest Neighbors (k-NN) (Chaki et al., 2019).

Sin embargo, el entorno industrial, y en particular la lectura de medidores analógicos, presenta desafíos únicos que exponen las limitaciones de estos métodos tradicionales. A diferencia del texto en documentos, los dígitos de un medidor tienen características muy específicas:

- **Fuentes y alineación:** Los dígitos suelen ser de tipo siete segmentos o similares, pero sufren de una alineación imperfecta y rotaciones parciales, especialmente durante la

transición de un número al siguiente (ej. un '3' que está a medio camino de convertirse en un '4').

- **Condiciones de la carátula:** La superficie del medidor está expuesta a suciedad, rayones, condensación y reflejos especulares que pueden ocultar o distorsionar los dígitos.
- **Iluminación variable:** La captura de imágenes en campo se realiza bajo condiciones de iluminación no controladas, desde la luz solar directa hasta la sombra profunda.

Estos factores hacen que la segmentación precisa de los dígitos, un paso crucial para los métodos tradicionales, sea extremadamente frágil. Un fallo en la segmentación conduce inevitablemente a un error en el reconocimiento.

La llegada del aprendizaje profundo (deep learning) ha revolucionado el OCR. Las Redes Neuronales Convolucionales (CNNs) y arquitecturas más complejas permiten un enfoque de extremo a extremo (end-to-end) que aprende a extraer características relevantes directamente de los datos brutos de la imagen, mostrando una robustez significativamente mayor a las variaciones mencionadas. Para evaluar el rendimiento de estos sistemas, se utilizan métricas estándar como la Tasa de Error de Caracteres (CER, del inglés *Character Error Rate*) y la Tasa de Error de "Palabra" (WER, de *Word Error Rate*), donde una "palabra" se define como la secuencia completa de dígitos del medidor. Para que una solución de lectura automática sea viable para la facturación, la industria exige umbrales de precisión por dígito extremadamente altos, comúnmente superiores al 98 % o 99 %, ya que cualquier error tiene un impacto económico directo (Laroca et al., 2021).

2.2.2 Arquitecturas de redes neuronales para OCR

Las redes neuronales profundas han dado lugar a una variedad de arquitecturas para abordar el problema del OCR. Las más simples consisten en una CNN seguida de capas completamente conectadas para clasificar dígitos individuales previamente segmentados. Si bien superan a los clasificadores tradicionales, todavía dependen de una etapa de segmentación externa. Los modelos más avanzados y robustos integran la detección y el reconocimiento en un único pipeline end-to-end.

En el campo del OCR, estos modelos suelen dividirse en dos categorías principales. Primero, los **detectores de texto**, cuyo objetivo es localizar las regiones de la imagen que contienen texto (en nuestro caso, el contador de dígitos). Arquitecturas como EAST (Efficient and Accurate Scene Text Detector) o CRAFT (Character-Region Awareness for Text) han de-

mostrado una gran eficacia en la localización precisa de texto en escenas naturales mediante la predicción de bounding boxes o mapas de afinidad de caracteres (Peng et al., 2023). Segundo, los **reconocedores de texto**, que toman la región detectada como entrada y la transcriben a una secuencia de caracteres.

Una de las arquitecturas end-to-end más influyentes y exitosas es la Red Neuronal Convolutiva Recurrente (CRNN, *Convolutional Recurrent Neural Network*) (Laroca et al., 2021). Un modelo CRNN se compone de tres partes principales:

1. **Capas Convolucionales (CNN):** Extraen un mapa de características robustas de la imagen de entrada. Estas capas son invariantes a ciertas distorsiones, lo que las hace ideales para manejar las difíciles condiciones de los medidores.
2. **Capas Recurrentes (RNN):** Una Red Neuronal Recurrente, típicamente una LSTM (Long Short-Term Memory) bidireccional, procesa la secuencia de vectores de características generada por la CNN. Esto le permite al modelo aprender el contexto secuencial de los dígitos.
3. **Capa de Transcripción:** Utiliza una función de pérdida especializada, como la Clasificación Temporal Conexionista (CTC, *Connectionist Temporal Classification*), para traducir las predicciones por-paso-de-tiempo de la RNN a la secuencia final de etiquetas.

La función de pérdida CTC es fundamental, ya que elimina la necesidad de una segmentación explícita a nivel de carácter. Permite que el modelo sea entrenado con la imagen del contador y la secuencia de dígitos correcta, sin requerir la ubicación exacta de cada dígito. La pérdida CTC suma las probabilidades de todas las posibles alineaciones de la secuencia de predicciones con la secuencia objetivo, lo que permite al modelo aprender a manejar espacios en blanco y caracteres repetidos. Formalmente, la probabilidad de una secuencia objetivo π dada una secuencia de entrada y se define como:

$$P(\pi|y) = \sum_{\mathbf{a} \in \mathcal{A}_{\pi,y}} \prod_{t=1}^T p_t(a_t|y) \quad (2.1)$$

donde $\mathcal{A}_{\pi,y}$ es el conjunto de todas las posibles alineaciones y $p_t(a_t|y)$ es la probabilidad del carácter a_t en el tiempo t .

El principal *trade-off* en la elección de una arquitectura es entre la precisión y la eficiencia computacional. Modelos más grandes y complejos pueden ofrecer mayor precisión, pero

a costa de un mayor tamaño, un mayor tiempo de inferencia y un mayor consumo de energía, lo que los hace inadecuados para dispositivos móviles con recursos limitados (Carvalho et al., 2023b; Zou et al., 2021). Por tanto, la investigación actual se centra en arquitecturas ligeras (*lightweight*) que logren un equilibrio óptimo para la implementación en el borde (*edge computing*).

2.2.3 Datasets y benchmarks relevantes

El rendimiento de cualquier modelo de aprendizaje profundo está intrínsecamente ligado a la calidad y cantidad de los datos de entrenamiento. En el dominio de la lectura de medidores de agua, la creación de un dataset robusto y diverso es un desafío en sí mismo. Aunque existen algunos datasets públicos, a menudo presentan limitaciones. Por ejemplo, el **UFPR-AMR Dataset** (Laroca et al., 2021) y su extensión (Salomon et al., 2022) son referencias clave en la comunidad académica, pero pueden no capturar la enorme variabilidad de modelos de medidores, estados de degradación y condiciones ambientales presentes en un contexto específico como el de las JAAPS en Ecuador.

Las estrategias de anotación de datos son cruciales. Se debe decidir si anotar con simples *bounding boxes* alrededor del contador o realizar una segmentación a nivel de dígito, lo cual es más laborioso pero puede permitir enfoques más flexibles. La anotación de dígitos parcialmente visibles o en transición es particularmente desafiante y requiere un protocolo de anotación claro y consistente para garantizar la calidad de las etiquetas.

Dada la dificultad de recolectar y anotar miles de imágenes de campo, las técnicas de **aumento de datos (data augmentation)** son indispensables. Más allá de las transformaciones genéricas como rotaciones, escalado o cambios de brillo, se deben aplicar técnicas específicas del dominio para simular los desafíos del mundo real:

- **Transformaciones Geométricas:** Simulación de distorsiones de perspectiva para imitar la captura desde diferentes ángulos.
- **Simulación de Condiciones Adversas:** Aplicación de desenfoque de movimiento (*motion blur*), ruido gaussiano, y simulación de reflejos y gotas de agua sobre el visor.
- **Generación de Datos Sintéticos:** Uso de gráficos por computadora (CGI) para generar imágenes fotorrealistas de medidores en una variedad infinita de estados y condiciones. Esto permite un control total sobre las características de la imagen, incluyendo los dígitos en transición (Sripanuskul et al., 2022).

Estas técnicas no solo incrementan el tamaño del dataset, sino que también mejoran la robustez y la capacidad de generalización del modelo entrenado. Un benchmarking riguroso contra datasets públicos y, más importante aún, contra un conjunto de prueba representativo del entorno de despliegue final, es esencial para validar la eficacia del modelo propuesto.

La necesidad de modelos eficientes que puedan ejecutarse en dispositivos móviles con recursos limitados es el puente hacia la siguiente fase de esta investigación. Habiendo explorado las arquitecturas OCR, el siguiente paso es analizar cómo estas pueden ser optimizadas e implementadas para un rendimiento eficaz en el borde, abordando directamente las restricciones identificadas en las comunidades rurales.

2.3 Deep Learning en dispositivos móviles con recursos limitados

Las arquitecturas de deep learning para OCR, discutidas en la sección anterior, suelen ser computacionalmente intensivas. Su despliegue en un prototipo móvil, destinado a operar en el campo y a menudo en dispositivos con recursos limitados, no es trivial. Esta sección explora las tecnologías y estrategias que hacen posible la ejecución eficiente de modelos de deep learning en el borde (*edge computing*), abordando las limitaciones de hardware y los requisitos de rendimiento que impone una aplicación del mundo real.

2.3.1 Arquitecturas eficientes para edge computing

El *edge computing* se refiere al paradigma de procesar datos cerca de donde se generan, en lugar de enviarlos a un servidor centralizado en la nube. Para una aplicación de lectura de medidores, este enfoque ofrece ventajas críticas: funcionamiento sin conexión a internet, baja latencia en la respuesta y mayor privacidad de los datos. Sin embargo, requiere el uso de arquitecturas de redes neuronales diseñadas específicamente para ser ligeras y rápidas.

La evolución de estas arquitecturas se basa en innovaciones como la **convolución separable en profundidad (depthwise separable convolution)**, que reduce drásticamente la carga computacional. Esta técnica fue la piedra angular de la familia de redes **MobileNet**, que progresivamente introdujo mejoras como los *inverted residuals* y la búsqueda de arquitecturas neuronales (NAS). Paralelamente, la familia **EfficientNet** propuso un **método de escalado compuesto (compound scaling)** para balancear de manera sistemática la profundidad, el ancho y la resolución de la red. Estos desarrollos sentaron las bases para los modelos de visión móvil eficientes que se utilizan hoy en día (Poddar et al., 2024).

Investigaciones más recientes han continuado esta línea. **EfficientNetV2** (Tan & Le, 2021) mejoró la velocidad de entrenamiento y la eficiencia de parámetros. Más recientemente-

te, arquitecturas híbridas que combinan convoluciones con mecanismos de atención de los Transformers, como **MobileViT** (Mehta & Rastegari, 2022), han demostrado ser muy prometedoras, capturando representaciones locales y globales de manera eficiente. La elección final depende del trade-off específico entre la precisión deseada y la latencia máxima tolerable en el dispositivo objetivo (Poddar et al., 2024).

Tabla 2.1: Comparativa de arquitecturas eficientes modernas (ejemplo en ImageNet).

Modelo	Precisión Top-1 (%)	Parámetros (M)
MobileNetV3-Large	75.2	5.5
EfficientNet-B0	77.1	5.3
EfficientNetV2-S	83.9	21.5
MobileViT-S	78.4	5.6

2.3.2 Optimización y compresión de modelos

Diseñar una arquitectura eficiente es solo el primer paso. Para lograr un rendimiento óptimo en dispositivos de gama media, como los que probablemente usarían los operarios de las JAAPS, es necesario aplicar técnicas de optimización y compresión.

La **cuantización** es la técnica más común y efectiva, reduciendo la precisión de los pesos de punto flotante de 32 bits (FP32) a enteros de 8 bits (INT8). El **entrenamiento consciente de la cuantización (QAT)** simula la cuantización durante el entrenamiento y generalmente preserva mejor la precisión que la **cuantización post-entrenamiento (PTQ)**. Estudios recientes han demostrado que, con técnicas adecuadas, la pérdida de precisión por la cuantización INT8 puede ser mínima, incluso para tareas complejas de visión por computadora (Ghosh et al., 2023).

El **podado (pruning)** elimina pesos o canales redundantes del modelo para reducir su tamaño y acelerar la inferencia. La **destilación del conocimiento (knowledge distillation)** utiliza un modelo “profesor” grande para entrenar a un modelo “estudiante” más pequeño, transfiriendo su conocimiento y mejorando la precisión del modelo compacto. La combinación de estas técnicas se ha vuelto una práctica estándar para la optimización de modelos en el borde (Li et al., 2023).

2.3.3 Frameworks de inferencia móvil

Para desplegar estos modelos optimizados en un dispositivo Android, se necesita un framework de inferencia especializado. **TensorFlow Lite (TFLite)** es la solución líder, proporcionando un intérprete ligero y un conjunto de herramientas para la conversión y optimización

de modelos.

La característica principal de TFLite son los **delegados (delegates)**, que permiten re-dirigir la computación a aceleradores de hardware. El **delegado de GPU** utiliza la Unidad de Procesamiento Gráfico, mientras que el **delegado de NNAPI (Android Neural Networks API)** actúa como una capa de abstracción para acceder a aceleradores específicos de IA, como las Unidades de Procesamiento Neuronal (NPU) o los Procesadores de Señales Digitales (DSP). La correcta utilización de estos delegados es crucial para minimizar la latencia y el consumo de energía (Albonico et al., 2023). Estudios comparativos recientes analizan el rendimiento de estos delegados en diferentes generaciones de SoCs (System-on-Chip), proporcionando una guía valiosa para predecir el rendimiento en una amplia gama de dispositivos móviles.

La gestión de recursos, incluyendo el control de hilos de ejecución y la monitorización de la temperatura para evitar el *thermal throttling*, es esencial para la estabilidad de la aplicación. Herramientas como el *Profiler* de Android Studio y la *TFLite benchmark tool* son indispensables en el ciclo de desarrollo para asegurar que el prototipo no solo sea preciso, sino también robusto y eficiente en condiciones de uso prolongado en campo. La combinación de una arquitectura moderna, técnicas de compresión y el uso inteligente de TFLite es lo que permitirá construir una solución sostenible para las JAAPS.

2.4 Sistemas de visión artificial para lectura automática de medidores

La implementación práctica de sistemas de visión artificial para la lectura de medidores trasciende los componentes individuales de OCR y detección. Requiere una integración cuidadosa de múltiples etapas de procesamiento que operen de manera robusta en las condiciones del mundo real (Laroca et al., 2021). Estos sistemas deben no solo alcanzar una alta precisión en condiciones ideales, sino también mantener su desempeño ante la variabilidad inherente de los entornos no controlados, donde factores como una iluminación deficiente, ángulos de captura subóptimos y el deterioro físico de los equipos representan desafíos constantes (Hong et al., 2021). Esta sección desglosa la arquitectura de dichos sistemas, analiza las estrategias para superar los desafíos operativos y realiza una evaluación crítica de las implementaciones existentes.

2.4.1 Pipeline completo de procesamiento

Un sistema robusto de lectura automática de medidores comprende múltiples etapas interdependientes, cada una crítica para el éxito global del proceso. El pipeline típico inicia con la adquisición de la imagen y culmina con la validación y registro de la lectura, requiriendo

decisiones de diseño que equilibren precisión, eficiencia computacional y robustez (Khan et al., 2024).




Figura 2.1: Pipeline completo de procesamiento para la lectura automática de medidores.

La primera etapa computacional es la **detección y localización del medidor**. Mientras que métodos clásicos como la transformada de Hough o el análisis de contornos pueden funcionar en condiciones controladas, son demasiado frágiles para el campo. Los sistemas modernos utilizan modelos de detección de objetos basados en deep learning. Arquitecturas como YOLO (You Only Look Once), en sus versiones más recientes como YOLOv8, son particularmente adecuadas por su excelente equilibrio entre velocidad y precisión, lo que las hace ideales para su despliegue en móviles (Khan et al., 2024; Wang et al., 2025). Estos modelos pueden ser entrenados para localizar específicamente el *bounding box* del contador de dígitos, incluso en imágenes complejas con múltiples objetos de fondo.

Una vez localizada la Región de Interés (ROI), la etapa de **pre-procesamiento y normalización** es crucial para estandarizar la entrada al modelo OCR. Un paso fundamental es

la **corrección de perspectiva**. Capturar una imagen perfectamente frontal es casi imposible en la práctica. Por ello, se detectan los cuatro puntos de esquina del contador (a menudo con un modelo ligero como el propuesto por Peng et al. (2023)) para calcular una matriz de homografía y aplicar una transformación que rectifique la ROI a una vista frontal. A continuación, se aplican técnicas de normalización de iluminación como el *Contrast Limited Adaptive Histogram Equalization* (CLAHE) para mitigar los efectos de sombras y reflejos.

Finalmente, la ROI normalizada se envía a la etapa de **segmentación y reconocimiento**. Como se discutió en la sección 2.2.2, los modelos modernos como CRNN evitan la necesidad de una segmentación explícita de cada dígito, leyendo la secuencia completa. Esto aumenta la robustez, ya que no depende de que cada dígito esté perfectamente separado. La salida del modelo OCR debe ser sometida a un **post-procesamiento**, que puede incluir la validación de la coherencia numérica (ej., la lectura actual no puede ser inferior a la del mes anterior) y la implementación de una lógica para solicitar una nueva captura si la confianza de la predicción es baja.

2.4.2 Robustez ante condiciones adversas

La principal diferencia entre un prototipo de laboratorio y un sistema desplegable en campo es su capacidad para manejar condiciones no ideales. La robustez es, por tanto, una característica de diseño primordial.

Las **variaciones de iluminación** son el desafío más común. Los reflejos especulares pueden ocultar dígitos por completo, mientras que las sombras profundas pueden reducir el contraste hasta hacerlos ilegibles. Aunque las técnicas de normalización en tiempo de ejecución como CLAHE ayudan, la estrategia más efectiva es entrenar al modelo para que sea invariante a estas condiciones. Esto se logra mediante una agresiva **augmentación de datos (data augmentation)** durante el entrenamiento, donde se simulan programáticamente una amplia gama de condiciones de iluminación, reflejos, y contrastes sobre el dataset de entrenamiento (Hong et al., 2021).

Las **variaciones geométricas**, como los ángulos de captura extremos o la distorsión de la lente, se abordan principalmente con la corrección de perspectiva mencionada anteriormente. Sin embargo, para que esta funcione, el modelo de detección de esquinas debe ser robusto. Entrenarlo en imágenes con una amplia variedad de ángulos y distorsiones es fundamental para asegurar que la rectificación sea precisa.

El **deterioro físico de los medidores** es otro factor crítico, especialmente en sistemas

de agua que pueden tener décadas de uso. Las carátulas rayadas, la condensación interna que empaña el visor, o la suciedad acumulada son problemas frecuentes. Un modelo de deep learning bien entrenado puede aprender a “ver a través” de muchas de estas obstrucciones, pero los casos severos pueden requerir estrategias más avanzadas. Algunos sistemas proponen un pre-clasificador que evalúa la calidad de la imagen de la ROI. Si la calidad es demasiado baja (ej. por desenfoque de movimiento o una obstrucción severa), el sistema puede rechazar la imagen y solicitar al operario una nueva captura, en lugar de arriesgarse a una lectura incorrecta (Laroca et al., 2021). Técnicas de mejora de imagen en tiempo real, como la super-resolución ligera o el deblurring, son un área de investigación activa, pero su costo computacional a menudo las hace inviables para dispositivos móviles de gama media (Carvalho et al., 2023a).

2.4.3 Implementaciones existentes: análisis crítico

En los últimos años, han surgido numerosas propuestas académicas y algunas soluciones comerciales para la lectura automática de medidores. Un análisis crítico de estas implementaciones revela tanto el progreso del campo como las brechas que aún existen.

Las **soluciones académicas** han demostrado consistentemente la viabilidad de los enfoques basados en deep learning, alcanzando precisiones superiores al 99

Las **soluciones comerciales** de empresas de servicios tecnológicos a menudo se presentan como productos pulidos, pero operan como “cajas negras” con poca información pública sobre sus arquitecturas, rendimiento en condiciones adversas o costos reales. Generalmente están diseñadas para grandes empresas de servicios públicos urbanos y se basan en un modelo de negocio de licencia por dispositivo o por lectura, lo cual es económicamente inviable para una JAAP. Además, estas soluciones suelen requerir una infraestructura de backend en la nube, lo que las hace dependientes de una conectividad a internet constante, un requisito prohibitivo en el contexto de esta tesis (Fieldeke et al., 2021).

Tabla 2.2: Análisis crítico de tipos de implementaciones de lectura automática.

Criterio	Métodos Tradicionales	Soluciones Académicas (DL)	Soluciones Comerciales
Precisión	Baja a media, frágil	Muy alta (>99 %) en benchmarks	Alta (declarada)
Robustez	Muy baja	Alta, dependiente del dataset	Desconocida, propietaria
Costo	Bajo (desarrollo)	Bajo a medio (requiere datos)	Alto (licencias, TCO)
Hardware	Ligero	Variable, optimizable para móviles	Generalmente requiere backend
Conectividad	No necesaria	Puede ser offline	Generalmente requiere online
Adaptabilidad	Específico, difícil de generalizar	Alta, re-entrenable	Baja, caja negra
Viabilidad JAAPS	Inviabile (frágil)	Potencialmente viable	Inviabile (costo, conectividad)

Las **limitaciones para contextos rurales** son la principal brecha que estas implemen-

taciones no abordan satisfactoriamente. La dependencia de la conectividad, los altos costos, los requisitos de hardware y la falta de adaptabilidad a la diversidad de medidores antiguos y deteriorados instalados en las zonas rurales de Ecuador son barreras significativas.

Esto define una clara **oportunidad de mejora y un nicho para la presente investigación**: el desarrollo de un sistema de código abierto, diseñado desde cero para operación offline, optimizado para hardware de gama media-baja, y entrenado en un dataset específico que capture la realidad de los medidores gestionados por las JAAPS. Las lecciones aprendidas de las implementaciones existentes son claras: la clave no está solo en alcanzar la máxima precisión en un benchmark, sino en diseñar una solución holística, sostenible y verdaderamente adaptada a las restricciones y necesidades del usuario final. Esto prepara el terreno para el diseño metodológico de nuestro prototipo.

2.5 Desarrollo de aplicaciones móviles offline con IA integrada

La construcción de un prototipo funcional para las JAAPS requiere la convergencia de las tres áreas previamente analizadas: la gestión comunitaria del agua, los sistemas de visión por computadora y la optimización de modelos para el borde. Esta sección final del marco teórico se centra en la disciplina que une estos campos: el desarrollo de aplicaciones móviles con capacidad de operación offline e inteligencia artificial integrada. Se abordan los patrones arquitectónicos, los desafíos técnicos de la integración de modelos de IA en Android y las consideraciones críticas de usabilidad para un despliegue exitoso en contextos rurales.

2.5.1 Arquitecturas offline-first

El diseño de una aplicación para zonas rurales con conectividad intermitente o nula exige un cambio de paradigma desde el tradicional modelo *cloud-first* hacia un enfoque *offline-first*. En este modelo, la aplicación se diseña para funcionar de manera autónoma, considerando la conexión a la red como un recurso opcional y no como un requisito. La fuente de verdad principal es la base de datos local del dispositivo, no un servidor remoto (**OfflineFirstPatterns**). Esto garantiza que el operario de la JAAP pueda realizar su trabajo de lectura de medidores sin interrupciones, independientemente de su ubicación geográfica.

Para implementar esto, se utiliza comúnmente el **Patrón de Repositorio (Repository Pattern)**. Este patrón de diseño aísla las fuentes de datos (red, base de datos local) de la lógica de negocio de la aplicación. El repositorio expone una interfaz limpia para acceder a los datos, y en su interior gestiona si los obtiene de la caché local o si necesita sincronizarlos con un servidor remoto cuando haya conexión (**AndroidDevGuideRepo**).




Figura 2.2: *Arquitectura recomendada para una aplicación offline-first en Android.*

La **sincronización eventual** es el mecanismo que mantiene los datos locales y remotos consistentes a lo largo del tiempo. Cuando el usuario registra una nueva lectura de medidor sin conexión, la aplicación no falla; en su lugar, guarda la transacción en una cola de sincronización local. Una herramienta como **WorkManager** de Android Jetpack es ideal para gestionar esta cola, ya que permite programar tareas de sincronización que se ejecutarán de manera garantizada cuando se cumplan las condiciones de red necesarias, incluso si la aplicación se cierra (**AndroidDevWorkManager**). En la resolución de conflictos, una estrategia simple y efectiva es la de “el último en escribir gana” (*last-write-wins*), que es suficiente para el caso de uso de lecturas de medidores, donde las entradas son secuenciales y rara vez conflictivas.

Para el **almacenamiento local**, la biblioteca **Room Database** es el estándar de oro en Android. Room es una capa de abstracción sobre SQLite que reduce el código repetitivo, verifica las consultas SQL en tiempo de compilación y se integra perfectamente con componentes de arquitectura como LiveData o Flow (**AndroidDevRoom**). Para optimizar el almacenamiento, las imágenes capturadas deben ser comprimidas (ej. a formato WebP con calidad del 75-80 %) antes de guardarlas, y se debe implementar una política de limpieza para eliminar imágenes antiguas una vez que han sido sincronizadas y verificadas.

2.5.2 Integración de modelos de IA en Android

Integrar un modelo de TensorFlow Lite (TFLite) en una aplicación Android es un proceso que requiere una gestión cuidadosa del rendimiento y los recursos. El ciclo de vida de la inferencia debe ser manejado eficientemente para proporcionar una experiencia de usuario fluida y evitar agotar la batería del dispositivo.

La implementación técnica comienza con la inicialización del intérprete de TFLite. Es una buena práctica realizar esta operación en un hilo de fondo para no bloquear el hilo principal

de la UI. El siguiente fragmento de código en Kotlin ilustra la inicialización, configurando el número de hilos y un delegado de GPU para aceleración por hardware:

```
// Ejemplo de inicialización de modelo TFLite en Kotlin
private fun initializeInterpreter(modelPath: String): Interpreter {
    val modelBuffer = FileUtil.loadMappedFile(context, modelPath)
    val options = Interpreter.Options()
    options.setNumThreads(4)

    // Intentar usar el delegado de GPU
    val gpuDelegate = GpuDelegate()
    options.addDelegate(gpuDelegate)

    try {
        return Interpreter(modelBuffer, options)
    } catch (e: Exception) {
        // Si falla la GPU, volver a intentarlo solo con CPU
        options.removeDelegate(gpuDelegate)
        return Interpreter(modelBuffer, options)
    }
}
```

El manejo de **hilos y concurrencia** es vital. La inferencia del modelo, que puede tardar varios cientos de milisegundos, nunca debe ejecutarse en el hilo principal para no causar que la aplicación deje de responder (ANR). Las **Coroutines** de Kotlin son la herramienta moderna y recomendada para gestionar operaciones asíncronas de manera limpia y eficiente. Se puede lanzar una corutina en un despachador de fondo (como 'Dispatchers.IO' o 'Dispatchers.Default') para ejecutar el pre-procesamiento de la imagen y la inferencia del modelo, y luego publicar el resultado de vuelta en el hilo principal para actualizar la UI.

La **optimización de la memoria** es otro aspecto crítico. Los modelos de TFLite pueden ser cargados como 'MappedByteBuffer' para un uso más eficiente de la memoria. Además, los 'Bitmaps' de Android son objetos grandes y deben ser manejados con cuidado, reciclándolos explícitamente cuando ya no se necesitan o usando librerías de carga de imágenes que

gestionen esto automáticamente.

Finalmente, la experiencia de usuario durante la captura se mejora enormemente con una **UI/UX de captura guiada**. En lugar de una simple aplicación de cámara, se debe utilizar la API **CameraX** de Jetpack, que simplifica enormemente el desarrollo de funcionalidades de cámara complejas. Se puede superponer sobre la vista previa de la cámara un recuadro o guía visual que ayude al operario a alinear correctamente el medidor. El sistema puede analizar los fotogramas de la vista previa en tiempo real para proporcionar feedback inmediato sobre la calidad (ej. “Acérquese más”, “Mucha luz”, “Mantenga el dispositivo estable”) antes de que el usuario tome la foto, aumentando drásticamente la tasa de éxito de la primera captura.

2.5.3 Consideraciones de usabilidad rural

Una aplicación técnicamente perfecta puede fracasar si no se adapta al contexto y a las capacidades de sus usuarios finales. Para las JAAPS, donde los operarios pueden ser adultos mayores con baja alfabetización digital, el diseño de la interfaz y la experiencia de usuario (UI/UX) es tan importante como la precisión del modelo de IA (**HCI4D**).

El diseño debe ser **minimalista y centrado en la tarea**. Se debe priorizar la iconografía universal sobre el texto denso. Los flujos de trabajo deben ser lineales y divididos en pasos pequeños y claros. Por ejemplo, en lugar de una pantalla con muchas opciones, la aplicación podría guiar al usuario: “Paso 1: Apunte al medidor”, “Paso 2: Confirme la lectura”. Un breve tutorial interactivo que se ejecuta la primera vez que se abre la aplicación es fundamental.

El **feedback al usuario** debe ser constante, visual y auditivo. Un borde verde alrededor de la guía de la cámara puede indicar que el medidor está bien alineado. Un sonido de “clic” y una vibración pueden confirmar que la foto se tomó correctamente. La lectura reconocida por el OCR debe mostrarse en números grandes y claros, pidiendo una simple confirmación (ej. un botón verde de “Correcto” y uno rojo de “Reintentar”). Los mensajes de error deben ser simples y accionables, como “La imagen está muy borrosa. Por favor, intente de nuevo con más luz” en lugar de “Error de inferencia: 7.23”.

Finalmente, la aplicación debe adaptarse al **contexto físico de uso**. Esto incluye interfaces de alto contraste para ser visibles bajo la luz directa del sol, botones lo suficientemente grandes para ser presionados con guantes, y flujos de trabajo que se puedan completar con una sola mano. La suma de estas consideraciones de diseño centrado en el ser humano es lo que transformará un potente motor de IA en una herramienta verdaderamente útil y adoptable por las comunidades a las que busca servir.

Tabla 2.3: *Tabla de consideraciones de diseño de UI/UX para contextos rurales.*

Consideración	Implementación Sugerida
Baja alfabetización digital	Iconos grandes y universales, mínimo texto, tutoriales guiados.
Condiciones de campo	Interfaz de alto contraste (modo para luz solar), botones grandes para uso con guantes, operación con una mano.
Confirmación de acciones	Feedback visual (colores), auditivo (sonidos) y háptico (vibración) para cada acción clave.
Manejo de errores	Mensajes de error en lenguaje simple con sugerencias claras para la recuperación. Logging local para soporte técnico remoto.
Batería y recursos	Modo de ahorro de energía opcional, optimización del uso de la cámara y del procesador.
Contexto cultural	Soporte para español y, potencialmente, quechua. Uso de formatos de fecha y número locales.

De acuerdo, Luis. Hemos llegado a la sección culminante de tu estado del arte. Este es el momento de unir todas las piezas, demostrar un dominio crítico del campo y justificar de manera contundente por qué tu trabajo es necesario, innovador y viable.

Como tu director de tesis y colega investigador, he redactado esta sección final con el rigor analítico que se espera. El objetivo es claro: sintetizar, comparar, encontrar las grietas en el conocimiento actual y posicionar tu propuesta como la solución lógica y precisa para esas grietas.

Texto para chapter2.tex Fragmento de código

2.6 Análisis comparativo y oportunidades de innovación

El presente capítulo ha realizado un recorrido exhaustivo desde el contexto socio-operativo de las Juntas Administradoras de Agua Potable y Saneamiento (JAAPS) hasta las minucias técnicas del deep learning en dispositivos móviles. Esta sección final tiene como objetivo sintetizar el conocimiento adquirido, realizar una evaluación crítica y comparativa de las soluciones existentes, identificar las brechas tecnológicas y de investigación, y, a partir de este análisis, justificar de manera sólida el enfoque propuesto por esta tesis. Se busca responder a la pregunta fundamental: ¿dónde se sitúa la oportunidad para una contribución científica y práctica significativa?

2.6.1 Matriz de evaluación de soluciones existentes

Para contextualizar la propuesta de esta tesis, es imperativo comparar las alternativas existentes frente a un conjunto de criterios ponderados por las realidades del entorno rural ecuatoriano. Ninguna solución puede ser evaluada en el vacío; su valor es relativo a las nece-

sidades, capacidades y limitaciones del contexto de aplicación. Se han definido tres dominios de criterios: técnicos, operativos y sociales.

Tabla 2.4: *Matriz de evaluación comparativa de soluciones para lectura de medidores en el contexto de las JAAPS.*

Criterio		Lectura Manual (Baseline)	AMI/AMR Comercial	App OCR (Cloud-based)	Académico (Genérico)	Propuesta Tesis (Offline-first)
Técnicos	Precisión	Baja (~90-95 %), sujeta a error humano.	Muy alta (>99.5 %).	Alta (>98 %), dependiente de la calidad de imagen.	Alta (>99 % en benchmarks), no validada en campo.	Objetivo: >98.5 % en campo.
	Latencia	Días (proceso completo).	Segundos a minutos.	Segundos (dependiente de red).	ms a segundos (dependiente de hardware).	<2 segundos en dispositivo.
	Offline	Totalmente offline.	No, requiere infraestructura de red fija.	No, requiere conexión a internet para procesar.	Parcialmente, no diseñado para ello.	Totalmente offline (diseño central).
	Consumo Energético	N/A.	Alto (infraestructura de red).	Moderado (uso de red y cámara).	No especificado.	Optimizado para bajo consumo.
Operativos	Costo Inicial	Cero.	Prohibitivo (>\$50k).	Bajo (<\$1k para desarrollo inicial).	N/A (investigación).	Muy bajo (<\$500 para prototipo).
	Costo Mantenimiento	Tiempo del operario.	Alto (licencias, soporte, hardware).	Moderado (costos de servidor/API).	N/A.	Casi nulo (software libre).
	Escalabilidad	Muy baja y lineal.	Alta, con alta inversión.	Moderada, limitada por costos de nube.	N/A.	Alta, sin costo de infraestructura.
	Capacitación	Baja.	Alta (personal técnico especializado).	Moderada.	Alta (requiere conocimiento de IA).	Baja, diseñada para usabilidad.
Sociales	Adopción Rural	Establecida.	Muy baja, por barreras económicas y técnicas.	Baja, por dependencia de red.	N/A.	Alta (diseñada para el contexto).
	Sostenibilidad	Baja (depende de voluntarios y es ineficiente).	Baja (insostenible para JAAPS).	Media (depende de pagos recurrentes).	N/A.	Alta (autonomía local).
	Alineación Local	Total.	Nula.	Baja.	Baja.	Total (co-diseño implícito).

El análisis de la matriz revela un panorama claro. La **lectura manual**, a pesar de su imprecisión y lentitud, persiste porque es la única solución con costo cero y que funciona offline. Los sistemas **AMI/AMR comerciales** son técnicamente superiores en todo, pero sus barreras económicas y de infraestructura los hacen completamente inviables para el modelo de gestión comunitaria. Las aplicaciones **OCR basadas en la nube** resuelven el problema de la precisión, pero intercambian la dependencia de una infraestructura física por una dependencia de la conectividad a internet, que es igualmente una barrera crítica en las zonas rurales de Ecuador.

Las **soluciones académicas** publicadas han sentado las bases técnicas, demostrando

que el reconocimiento de dígitos con alta precisión es posible mediante deep learning. Sin embargo, como se discutió en la sección 2.4.3, tienden a operar en condiciones de laboratorio, utilizan datasets que no representan la diversidad y el deterioro de los medidores en campo, y rara vez abordan de manera integral los requisitos de una implementación offline, robusta y usable para personal no especializado.

2.6.2 Brechas identificadas en el estado del arte

La síntesis de las secciones anteriores y la matriz de evaluación permiten identificar un conjunto de brechas críticas en el estado del arte, que representan la oportunidad para la innovación.

Brechas Técnicas:

- **Robustez en el “último 1 %”:** Mientras que muchos modelos alcanzan >99 % de precisión en benchmarks, falta investigación sobre las causas de fallo en el <1 % restante, que a menudo corresponden a las condiciones más extremas (reflejos severos, oclusión parcial, dígitos en transición) que son frecuentes en campo.
- **Generalización a la “fauna” de medidores locales:** Los modelos suelen entrenarse en datasets con poca variedad de medidores. No existe una solución probada que generalice bien a la enorme diversidad de modelos, antigüedades y estados de conservación de los medidores instalados en la zona andina.
- **Ausencia de un pipeline integral y optimizado para el borde:** No se ha documentado en la literatura una solución que integre un pipeline completo (detección, rectificación, reconocimiento) y que esté explícitamente optimizado mediante técnicas como la cuantización y el podado para funcionar eficientemente en dispositivos móviles de gama media-baja, prevalentes en el contexto rural.

Brechas de Implementación y Contexto:

- **El “abismo” del costo y la conectividad:** Existe una brecha abismal entre las soluciones comerciales (altamente funcionales pero inaccesibles) y la realidad operativa de las JAAPS. Ninguna solución comercial actual está diseñada para un modelo de negocio de costo casi nulo y operación offline.
- **Falta de validación en campo real latinoamericano:** La gran mayoría de los estudios académicos se realizan en Asia, Europa o Norteamérica, o en contextos urbanos de

Brasil. Faltan estudios que validen estas tecnologías en las condiciones geográficas, climáticas y socio-técnicas específicas de las comunidades rurales andinas.

- **El eslabón perdido de la usabilidad:** Se ha prestado poca atención al diseño de la interfaz de usuario y la experiencia de usuario (UI/UX) para operarios con baja alfabetización digital. La tecnología, sin una interfaz que facilite su adopción, está destinada al fracaso.

2.6.3 *Justificación del enfoque propuesto*

El análisis anterior demuestra que no existe una solución que aborde simultáneamente los requisitos técnicos, operativos y sociales de las JAAPS. Esta intersección de necesidades no cubiertas es precisamente donde se posiciona y justifica la presente tesis. El enfoque propuesto no busca simplemente mejorar la precisión en un pequeño porcentaje, sino crear una solución holística y apropiada tecnológicamente.

Ventajas y Alineación con el Contexto: La propuesta de desarrollar un prototipo móvil para la lectura de medidores con operación 100 % offline y optimizado para hardware de gama media responde directamente a las principales barreras identificadas:

1. **Resuelve la barrera de la conectividad:** Al ser offline-first, la herramienta es funcional en el 100
2. **Supera la barrera del costo:** Al basarse en software de código abierto y hardware de consumo (smartphones que los operarios a menudo ya poseen), el costo de implementación y mantenimiento es marginal, alineándose con el modelo económico de las juntas.
3. **Cierra la brecha de la usabilidad:** El diseño centrado en el usuario para personal con capacidades digitales variables es un pilar de la propuesta, buscando maximizar la adopción y minimizar la frustración.
4. **Aborda la diversidad de medidores:** La creación de un dataset específico del contexto ecuatoriano permitirá entrenar un modelo adaptado a la realidad local, en lugar de usar modelos genéricos con menor rendimiento.

Contribuciones Científicas y Prácticas Esperadas: Esta tesis aspira a realizar las siguientes contribuciones originales al campo:

- **Técnica:** El diseño y validación de un pipeline completo de visión artificial (detección + OCR) optimizado para una alta eficiencia (latencia <2s) en dispositivos móviles de recur-

sos limitados, con un análisis detallado de los trade-offs de las técnicas de cuantización en esta tarea específica.

- **Empírica:** La creación y publicación de un nuevo dataset de imágenes de medidores de agua del contexto rural ecuatoriano, anotado y validado, que sirva como benchmark para futuras investigaciones en la región.
- **Metodológica:** El desarrollo de un modelo de implementación y validación de una solución de IA en un entorno comunitario real, documentando no solo los resultados técnicos sino también el proceso de adopción, capacitación y el impacto socioeconómico medible.

En resumen, el estado del arte muestra que las herramientas existen, pero están desarticuladas y no han sido ensambladas y adaptadas para el problema específico que nos ocupa. La innovación de esta tesis no radica en inventar un nuevo algoritmo de deep learning desde cero, sino en el ****diseño, la integración, la optimización y la validación de un sistema completo en un contexto real y desatendido****, demostrando que la inteligencia artificial puede ser una herramienta poderosa y accesible para fortalecer la gestión comunitaria del agua. Este capítulo ha sentado las bases teóricas y ha justificado la necesidad de este trabajo; el siguiente capítulo detallará la metodología para llevarlo a cabo.

Capítulo tres

Metodología

3.1 Enfoque general del desarrollo

3.2 Fases metodológicas del proyecto

3.2.1 *Revisión de literatura*

3.2.2 *Construcción del dataset*

3.2.3 *Entrenamiento y optimización de modelos*

3.2.4 *Desarrollo de la aplicación*

3.2.5 *Validación del prototipo*

3.3 Herramientas y tecnologías utilizadas

3.4 Consideraciones éticas y operativas

Capítulo cuatro

Desarrollo del sistema

- 4.1 Diseño de la arquitectura del sistema**
- 4.2 Adquisición, etiquetado y depuración del dataset**
- 4.3 Diseño y entrenamiento del modelo OCR ligero**
- 4.4 Implementación de lógica de captura asistida de imágenes**
- 4.5 Desarrollo de la aplicación móvil y sincronización de datos**
- 4.6 Integración del sistema y pruebas internas**

Capítulo cinco

Evaluación y resultados

- 5.1 Diseño de experimentos y métricas de evaluación**
- 5.2 Resultados de precisión, latencia y eficiencia energética**
- 5.3 Comparativa con procesos tradicionales de lectura**
- 5.4 Validación en campo con usuarios reales**
- 5.5 Discusión de resultados y cumplimiento de objetivos**

Capítulo seis

Conclusiones y recomendaciones

- 6.1 Conclusiones generales**
- 6.2 Lecciones aprendidas del proceso de desarrollo**
- 6.3 Limitaciones técnicas y metodológicas**
- 6.4 Recomendaciones para futuras investigaciones**
- 6.5 Posibilidades de escalabilidad y transferencia tecnológica**

Referencias

- Agencia de Cooperación Internacional del Japón (JICA). (2025). *Agua No Contabilizada: Documento Técnico 2025* (inf. téc.) (Documento de trabajo sobre la gestión de pérdidas de agua en Ecuador). JICA.
- Albonico, A., Pagliari, D. J., Risso, M., Averta, G., & Garza, P. (2023). A Benchmark of Deep Learning Frameworks for Mobile and Embedded Devices. *2023 IEEE 7th International Conference on Fog and Edge Computing (ICFEC)*, 90-99. <https://doi.org/10.1109/ICFEC58326.2023.00019>
- Banco Interamericano de Desarrollo (BID). (2022). *La Gestión Comunitaria del Agua en América Latina: Modelos, Desafíos y Oportunidades* (inf. téc.) (Documento de análisis sectorial sobre los servicios de agua y saneamiento). BID.
- Banco Interamericano de Desarrollo (IADB). (2022). *La Medición Inteligente en América Latina y el Caribe: Recomendaciones regulatorias para incentivar el despliegue* (inf. téc.). IADB. <https://publications.iadb.org/publications/spanish/document/La-Medicion-Inteligente-en-America-Latina-y-el-Caribe-Recomendaciones-regulatorias-para-incentivar-el-despliegue-de-la-medicion-inteligente-a-nivel-nacional.pdf>
- Carvalho, R., Melo, J., Graça, R., Santos, G., & Vasconcelos, M. J. M. (2023a). Deep Learning-Powered System for Real-Time Digital Meter Reading on Edge Devices. *Applied Sciences*, 13(4), 2315. <https://doi.org/10.3390/app13042315>
- Carvalho, R., Melo, J., Graça, R., Santos, G., & Vasconcelos, M. J. M. (2023b). Deep learning-powered system for real-time digital meter reading on edge devices. *Applied Sciences*, 13(4), 2315. <https://doi.org/10.3390/app13042315>
- Chaki, S., Shila, D. A., & Jahan, N. (2019). Automation of water meter billing process based on digital image processing approach. *Journal of Advances in Technology and Engineering Research*, 5(5), 207-218. <https://doi.org/10.20474/jater-5.5.3>
- Fielder, I. C., Schraven, A., & Jensen, C. B. (2021). Barriers to the Digital Transformation of Rural Water Services in Sub-Saharan Africa. *Water*, 13(16), 2273. <https://doi.org/10.3390/w13162273>
- Ghosh, A., PU, R., & Muralidhara, V. N. (2023). A Survey on Quantization Techniques in Deep Neural Networks. *SN Computer Science*, 4(4), 348. <https://doi.org/10.1007/s42979-023-01783-0>

- Global Growth Insights. (2023). Análisis del mercado de medidores de agua inteligentes 2023-2033 [Informe de mercado sobre tecnologías de medición de agua.].
- Hong, Q., Ding, Y., Lin, J., Wang, M., Wei, Q., Wang, X., & Zeng, M. (2021). Image-Based Automatic Watermeter Reading under Challenging Environments. *Sensors*, 21(2), 434. <https://doi.org/10.3390/s21020434>
- Instituto Nacional de Estadística y Censos (INEC). (2024). *Encuesta de Gestión de Agua Potable y Saneamiento 2023* (inf. téc.) (Publicado en el sitio web del INEC con resultados del año 2023). INEC. Quito, Ecuador.
- Khan, F., Rafique, S., & Khan, G. M. (2024). Low-Cost Smart Metering Using Deep Learning [DOI no encontrado]. *International Journal of Innovations in Science & Technology (IJIST), Special Issue*, 93-104.
- Ktari, J., Frikha, T., Hamdi, M., Elmannai, H., & Hmam, H. (2022). Lightweight AI Framework for Industry 4.0 Case Study: Water Meter Recognition. *Big Data and Cognitive Computing*, 6(3), 72. <https://doi.org/10.3390/bdcc6030072>
- Laroca, R., Araujo, A. B., Zanlorensi, L. A., Almeida, E. C. D., & Menotti, D. (2021). Towards Image-Based Automatic Meter Reading in Unconstrained Scenarios: A Robust and Efficient Approach. *IEEE Access*, 9, 67569-67584. <https://doi.org/10.1109/ACCESS.2021.3077415>
- Li, J., Yipeng-Gen, Chuan-Chi & Yichuan-Li. (2023). A Survey on Deep Learning-based Edge-AI. *arXiv preprint arXiv:2307.03967*.
- Liang, Y., Liao, Y., Li, S., Wu, W., Qiu, T., & Zhang, W. (2022). Research on water meter reading recognition based on deep learning. *Scientific Reports*, 12(1), 12861. <https://doi.org/10.1038/s41598-022-17255-3>
- Mehta, S., & Rastegari, M. (2022). MobileViT: Light-weight, General-purpose, and Mobile-friendly Vision Transformer. *International Conference on Learning Representations (ICLR)*.
- Naciones Unidas. (2015). Transformar nuestro mundo: la Agenda 2030 para el Desarrollo Sostenible [Resolución aprobada por la Asamblea General el 25 de septiembre de 2015. Consultado el 16 de junio de 2025]. <https://sdgs.un.org/2030agenda>
- Peng, J., Zhou, W., Han, Y., Li, M., & Liu, W. (2023). Deep learning-based autonomous real-time digital meter reading recognition method for natural scenes. *Measurement*, 222, 113615. <https://doi.org/10.1016/j.measurement.2023.113615>

- Poddar, A. K., Singh, S., & Chakraborty, T. (2024). A survey of deep learning models for resource-constrained edge devices. *Artificial Intelligence Review*. <https://doi.org/10.1007/s10462-024-10775-8>
- Roa-García, M. C., Brown, S., & Urquijo, J. (2019). Water Governance in Latin America: A Look at the Water-Energy-Food Nexus. *Water*, 11(1), 131. <https://doi.org/10.3390/w11010131>
- Salomon, G., Laroca, R., & Menotti, D. (2022). Image-Based Automatic Dial Meter Reading in Unconstrained Scenarios [También disponible como preimpresión de arXiv arXiv:2201.02850]. *Measurement*. <https://doi.org/10.1016/j.measurement.2022.112025>
- Sripanuskul, N., Buayai, P., & Mao, X. (2022). Generative Data Augmentation for Automatic Meter Reading Using CNNs. *IEEE Access*, 10, 28471-28486. <https://doi.org/10.1109/ACCESS.2022.3157706>
- Tan, M., & Le, Q. V. (2021). EfficientNetV2: Smaller Models and Faster Training. *Proceedings of the 38th International Conference on Machine Learning (ICML)*, 10096-10106.
- Toma, C., Márquez, W., Pumisacho, V., Aldás, M., & Márquez, M. (2020). Factors Affecting the Sustainability of Rural Drinking Water Services in the Andean Region of Ecuador. *Sustainability*, 12(23), 9964. <https://doi.org/10.3390/su12239964>
- Wang, H., Wang, N., & An, X. (2025). CAM-YOLO v8: A model for water meter word wheel region segmentation. *Proceedings of the 2nd International Conference on Generative Artificial Intelligence and Information Security (GAIS)*. <https://doi.org/10.1145/3728725.3728769>
- Zou, F., Shi, Z., Gan, Z., Liao, L., & Xu, J. (2021). Water Meter Reading Recognition Based on Lightweight CNN. *Proceedings of the International Conference on Frontiers of Electronics, Information and Computation Technologies (ICFEICT)*. <https://doi.org/10.1145/3474198.3478237>