



UNIVERSIDAD TÉCNICA PARTICULAR DE LOJA

La Universidad Católica de Loja

FACULTAD DE INGENIERÍAS Y ARQUITECTURA

MAESTRÍA EN INTELIGENCIA ARTIFICIAL APLICADA

**Desarrollo de un prototipo móvil para la lectura de
medidores de agua potable usando técnicas de
procesamiento de imágenes**

Trabajo de titulación previo a la obtención del título de:

MAGÍSTER EN INTELIGENCIA ARTIFICIAL APLICADA

Autor: Pillaga Zhagñay, Luis Antonio

Director: Riofrio Calderón, Guido Eduardo

LOJA

2025

Aprobación del director del Trabajo de Titulación

Loja, 15 de febrero de 2025

Doctor

Luis Rodrigo Barba Guamán

Director de la maestría de Inteligencia Artificial Aplicada

Loja.-

De mi consideración:

Me permito comunicar que, en calidad de director del presente Trabajo de Titulación nominado: Desarrollo de un prototipo móvil para la lectura de medidores de agua potable usando técnicas de procesamiento de imágenes realizado por Luis Antonio Pillaga Zhagñay ha sido orientado y revisado durante su ejecución, así mismo ha sido verificado a través de la herramienta de similitud académica institucional, y cuenta con un porcentaje de coincidencia aceptable. En virtud de ello, y por considerar que el mismo cumple con todos los parámetros establecidos por la Universidad, doy mi aprobación a fin de continuar con el proceso académico correspondiente.

Particular que comunico para los fines pertinentes.

Atentamente,

Director: Guido Eduardo Riofrio Calderón, PhD.

C.I.: 1103214969

Correo electrónico: geriofrio@utpl.edu.ec

Declaración de autoría y cesión de derechos

Yo, Luis Antonio Pillaga Zhagñay, declaro y acepto en forma expresa lo siguiente:

Ser autor del Trabajo de Titulación denominado: Desarrollo de un prototipo móvil para la lectura de medidores de agua potable usando técnicas de procesamiento de imágenes, de la maestría en Inteligencia Artificial Aplicada, específicamente de los contenidos comprendidos en: Introducción, Capítulo 1: Marco Teórico, Capítulo 2: Metodología, Capítulo 3: Desarrollo y Resultados, Conclusiones y Recomendaciones, siendo Guido Eduardo Riofrio Calderón, director del presente trabajo; también declaro que la presente investigación no vulnera derechos de terceros ni utiliza fraudulentamente obras preexistentes. Además, ratifico que las ideas, criterios, opiniones, procedimientos y resultados vertidos en el presente trabajo investigativo, son de mi exclusiva responsabilidad. Eximo expresamente a la Universidad Técnica Particular de Loja y a sus representantes legales de posibles reclamos o acciones judiciales o administrativas, en relación a la propiedad intelectual de este trabajo.

Que la presente obra, producto de mis actividades académicas y de investigación, forma parte del patrimonio de la Universidad Técnica Particular de Loja, de conformidad con el artículo 20, literal j), de la Ley Orgánica de Educación Superior; y, artículo 91 del Estatuto Orgánico de la UTPL, que establece: “Forman parte del patrimonio de la Universidad la propiedad intelectual de investigaciones, trabajos científicos o técnicos y tesis de grado que se realicen a través, o con el apoyo financiero, académico o institucional (operativo) de la Universidad”, en tal virtud, cedo a favor de la Universidad Técnica Particular de Loja la titularidad de los derechos patrimoniales que me corresponden en calidad de autor/a, de forma incondicional, completa, exclusiva y por todo el tiempo de su vigencia.

La Universidad Técnica Particular de Loja queda facultada para ingresar el presente trabajo al Sistema Nacional de Información de la Educación Superior del Ecuador para su difusión pública, en cumplimiento del artículo 144 de la Ley Orgánica de Educación Superior.

Autor: Luis Antonio Pillaga Zhagñay

C.I.: 0301971495

Correo electrónico: lapillaga2@utpl.edu.ec

Dedicatoria

Este trabajo representa el fruto de años de esfuerzo, dedicación y el apoyo incondicional de personas muy especiales en mi vida. Con profundo cariño y gratitud, dedico este logro:

A mi madre Julia Zhagñay, por cada una de sus palabras de aliento durante todos mis años de estudio. Su apoyo incondicional ha sido mi fortaleza, y agradezco profundamente su mejor legado: el valor de siempre procurar ser una buena persona.

Para mi segunda madre, Evangelina Dután, quien con un corazón inmenso y sin necesidad de lazos de sangre, siempre cuidó de mí. Aunque hoy ya no estás, siento que desde el cielo continúas guiando mis pasos.

A mi nueva familia, Lesly y Luis Nicolás, por ser la inspiración y la fuerza que necesitaba para dar este importante paso. Su apoyo y paciencia han sido el pilar fundamental para poder terminar este trabajo.

Finalmente, extendiendo mi gratitud a cada ser humano que ha formado parte de mi camino, aportando a mi crecimiento personal y profesional.

Agradecimiento

TODO

Índice de contenido

Carátula	I
Aprobación del director del Trabajo de Titulación.....	I
Declaración de autoría y cesión de derechos	II
Dedicatoria	III
Agradecimiento	IV
Resumen	1
Abstract.....	2
Introducción.....	3
1 Introducción	4
1.1 Contextualización del Problema: El Agua y Saneamiento en el Sector Rural.....	4
1.2 Problemática	4
1.3 Justificación	5
1.4 Objetivos.....	6
1.4.1 Objetivo general	6
1.4.2 Objetivos específicos	6
1.5 Alcance y Limitaciones	7
1.5.1 Alcance del Proyecto	7
1.5.2 Limitaciones de la Investigación	8
1.6 Estructura del Documento	8
2 Estado del arte	10
2.1 Gestión del agua en comunidades rurales: contexto y desafíos tecnológicos	10
2.1.1 Las JAAPS como modelo de gestión comunitaria del agua	10
2.1.2 Evolución tecnológica en la lectura de medidores de agua	11
2.2 Reconocimiento óptico de caracteres aplicado a medidores	13
2.2.1 Fundamentos del OCR en entornos industriales	13
2.2.2 Arquitecturas de redes neuronales para OCR	14
2.2.3 Datasets y benchmarks relevantes	15
2.3 Deep Learning en dispositivos móviles con recursos limitados.....	15
2.3.1 Arquitecturas eficientes para edge computing	16
2.3.2 Optimización y compresión de modelos	16

2.3.3	Frameworks de inferencia móvil	17
2.4	Sistemas de visión artificial para lectura automática de medidores	17
2.4.1	Pipeline completo de procesamiento	17
2.4.2	Robustez ante condiciones adversas	18
2.4.3	Implementaciones existentes: análisis crítico	19
2.5	Desarrollo de aplicaciones móviles offline con IA integrada.....	19
2.5.1	Arquitecturas offline-first.....	20
2.5.2	Integración de modelos de IA en Android	20
2.5.3	Consideraciones de usabilidad rural	21
2.6	Análisis comparativo y oportunidades de innovación	22
2.6.1	Matriz de evaluación de soluciones existentes	22
2.6.2	Brechas identificadas en el estado del arte	22
2.6.3	Justificación del enfoque propuesto	24
3	Metodología	26
3.1	Enfoque general del desarrollo	26
3.2	Fases metodológicas del proyecto	26
3.2.1	Revisión de literatura	26
3.2.2	Construcción del dataset.....	26
3.2.3	Entrenamiento y optimización de modelos	26
3.2.4	Desarrollo de la aplicación	26
3.2.5	Validación del prototipo	26
3.3	Herramientas y tecnologías utilizadas	26
3.4	Consideraciones éticas y operativas	26
4	Desarrollo del sistema.....	27
4.1	Diseño de la arquitectura del sistema.....	27
4.2	Adquisición, etiquetado y depuración del dataset	27
4.3	Diseño y entrenamiento del modelo OCR ligero	27
4.4	Implementación de lógica de captura asistida de imágenes	27
4.5	Desarrollo de la aplicación móvil y sincronización de datos.....	27
4.6	Integración del sistema y pruebas internas	27
5	Evaluación y resultados	28
5.1	Diseño de experimentos y métricas de evaluación	28

5.2	Resultados de precisión, latencia y eficiencia energética	28
5.3	Comparativa con procesos tradicionales de lectura	28
5.4	Validación en campo con usuarios reales	28
5.5	Discusión de resultados y cumplimiento de objetivos	28
6	Conclusiones y recomendaciones	29
6.1	Conclusiones generales	29
6.2	Lecciones aprendidas del proceso de desarrollo	29
6.3	Limitaciones técnicas y metodológicas.....	29
6.4	Recomendaciones para futuras investigaciones	29
6.5	Posibilidades de escalabilidad y transferencia tecnológica	29
	Referencias	30

Índice de tablas

2.1	Comparativa de arquitecturas eficientes modernas (ejemplo en ImageNet).....	16
2.2	Análisis crítico de tipos de implementaciones de lectura automática.....	19
2.3	Tabla de consideraciones de diseño de UI/UX para contextos rurales.	22
2.4	Matriz de evaluación comparativa de soluciones para lectura de medidores en el contexto de las JAAPS.	23

Índice de figuras

2.1	Pipeline completo de procesamiento para la lectura automática de medidores.....	18
2.2	Arquitectura recomendada para una aplicación offline-first en Android.	20

Resumen

El resumen se presentará en un único párrafo con un máximo de **180 palabras**, sintetiza el aporte que brinda el trabajo realizado. **Obligatoriamente** debe contener las palabras clave **(máximo tres)**.

Ejemplo:

TODO

Palabras clave: xxxxxxxxx, xxxxxxxx, xxxxxx.

Abstract

Abstract es el resumen traducido al idioma inglés en donde se incluyen las palabras claves.

Obligatoriamente debe contener las palabras claves (**máximo tres**).

Ejemplo:

TODO

Keywords: xxxxxxxxxx, xxxxxxxx, xxxxxx.

Introducción

Se sugiere presentar en máximo **dos páginas** y considerar los siguientes puntos:

Capítulo uno

Introducción

1.1 Contextualización del Problema: El Agua y Saneamiento en el Sector Rural

El acceso a agua potable y saneamiento constituye un derecho humano fundamental, reconocido como una piedra angular para el desarrollo sostenible, la salud pública y la prosperidad económica. La comunidad internacional ha ratificado su importancia a través de la Agenda 2030, donde el Objetivo de Desarrollo Sostenible 6 (ODS 6) insta a "garantizar la disponibilidad y la gestión sostenible del agua y el saneamiento para todos" (Naciones Unidas, 2015). A pesar de los avances globales, persisten brechas significativas, especialmente en las zonas rurales de países en desarrollo, donde las comunidades a menudo dependen de modelos de gestión descentralizados y comunitarios para la prestación de estos servicios esenciales.

En América Latina, y particularmente en Ecuador, la gestión del agua en zonas rurales recae sobre las Juntas Administradoras de Agua Potable y Saneamiento (JAAPS), la estructura legalmente reconocida para esta función. Se estima que más de 5,000 de estas organizaciones operan en el país y cumplen un rol esencial que el Estado no siempre puede asumir, dando servicio a una parte importante de la población rural. Su trabajo va más allá del suministro de agua, pues también fortalece la cohesión social y la gestión local de los recursos naturales. Por ello, mejorar la capacidad operativa de este modelo de gestión democrática significa robustecer directamente a las instituciones comunitarias y su resiliencia.

A pesar de su importancia, la sostenibilidad de estas organizaciones es un desafío. Aunque son efectivas para ampliar la cobertura, sus constantes limitaciones técnicas, financieras y administrativas comprometen su futuro a largo plazo. Esta situación se agrava por la falta de herramientas tecnológicas diseñadas para un entorno de recursos limitados y brechas de conocimiento técnico, lo que pone en riesgo la calidad del servicio. Este trabajo de titulación se enfoca, precisamente, en buscar una solución tecnológica que fortalezca a estas organizaciones, mejorando tanto su gestión como su autosuficiencia.

1.2 Problemática

Aunque las JAAPS son un pilar para el agua rural, su operación tradicional sufre de ineficiencias críticas que amenazan tanto su sostenibilidad financiera como la confianza de los usuarios. El principal problema se concentra en la toma de lecturas, un proceso manual que es clave para la facturación. El método actual, que obliga a un operario a transcribir a papel los

datos de cada medidor, es por naturaleza lento y propenso a errores humanos que generan *pérdidas comerciales* (Chaki et al., 2019). Estos fallos en la lectura y el manejo de datos, conocidos como pérdidas aparentes, subvaloran el consumo real y resultan en facturas incorrectas que afectan directamente los ingresos de la junta (Agencia de Cooperación Internacional del Japón (JICA), 2025).

Las cifras del problema son preocupantes. El Agua No Contabilizada (ANC), que mide tanto fugas como pérdidas comerciales, promedia un 51.8 % a nivel nacional en sistemas municipales, y se estima que la cifra es mayor en los sistemas comunitarios (Instituto Nacional de Estadística y Censos (INEC), 2024). A estas imprecisiones se suman los retos logísticos: el personal de las JAAPS debe recorrer áreas dispersas y de difícil acceso, causando demoras. A su vez, la falta de una conexión a internet fiable en estas zonas ha sido una barrera para adoptar soluciones digitales (Fieldeke et al., 2021). Esta “brecha digital” fuerza a las juntas a seguir usando papel, lo que duplica el trabajo de digitación y abre la puerta a más errores.

Estas fallas operativas provocan consecuencias en todo el sistema. Una factura incorrecta reduce la confianza del usuario, lo que puede llevar a una cultura de no pago que afecta la recaudación. Al mismo tiempo, sin datos de consumo fiables, la directiva no puede realizar análisis técnicos clave como el balance hídrico o la detección de fugas, ambos vitales para la sostenibilidad del recurso (Agencia de Cooperación Internacional del Japón (JICA), 2025). Como resultado, se crea un círculo vicioso de ineficiencia que limita la capacidad de las JAAPS para invertir, dar mantenimiento y, en definitiva, asegurar la viabilidad del servicio a largo plazo.

1.3 Justificación

La presente investigación se justifica en tres dimensiones interconectadas que responden directamente a la problemática expuesta.

En primer lugar, desde una perspectiva tecnológica, el proyecto es oportuno y pertinente. Los avances recientes en el campo del aprendizaje profundo (deep learning), específicamente en arquitecturas de redes neuronales convolucionales (CNN) optimizadas para dispositivos de bajos recursos, han abierto la puerta a soluciones que antes eran inviables. El uso de frameworks como TensorFlow Lite permite encapsular modelos de visión por computadora potentes en un formato ligero, capaz de ejecutar la inferencia directamente en un teléfono móvil estándar sin depender de una conexión a internet (Carvalho et al., 2023). Esta capacidad de procesamiento local (edge computing) es precisamente la innovación técnica que permite superar la barrera de la conectividad intermitente, el principal obstáculo para la digitalización

de procesos en las zonas rurales atendidas por las JAAPS.

En segundo lugar, la justificación social y económica es directa y de alto impacto. Al automatizar el proceso de lectura de medidores, el prototipo propuesto tiene el potencial de reducir drásticamente los errores de facturación, incrementando la precisión y, por ende, la recuperación de ingresos para las juntas. Esta optimización de recursos no solo fortalece la sostenibilidad financiera de la organización, sino que también libera tiempo del personal, que puede ser reasignado a tareas críticas de mantenimiento y operación de la red. De esta manera, el proyecto se alinea con la Meta 6.B de la Agenda 2030 para el Desarrollo Sostenible, que promueve explícitamente el apoyo y fortalecimiento de la participación de las comunidades locales en la mejora de la gestión del agua y el saneamiento (Naciones Unidas, 2015).

Finalmente, el proyecto presenta una clara justificación científica. Si bien existen soluciones genéricas de Reconocimiento Óptico de Caracteres (OCR), su rendimiento en condiciones no controladas (“in the wild”) es a menudo deficiente. La contribución de esta tesis radica en el desarrollo y la validación de un pipeline de visión artificial especializado para el dominio específico de los medidores de agua en contextos rurales, los cuales presentan una alta variabilidad de modelos, estados de deterioro, condiciones de iluminación y oclusiones parciales. La investigación aportará un dataset específico para esta tarea y analizará la eficacia de arquitecturas de modelos ligeros y técnicas de *data augmentation* para lograr la alta precisión ($\geq 98\%$) requerida. Por lo tanto, el trabajo no solo resuelve un problema práctico, sino que también contribuye con conocimiento aplicable al campo del OCR en entornos industriales desafiantes y en hardware con recursos limitados.

1.4 Objetivos

1.4.1 Objetivo general

Desarrollar un prototipo móvil que permita la lectura automática de medidores de agua potable mediante técnicas de procesamiento de imágenes, orientado a optimizar la gestión de las JAAPS en el sector rural ecuatoriano.

1.4.2 Objetivos específicos

1. Fundamentar el diseño técnico del sistema mediante un análisis crítico del estado del arte en arquitecturas de OCR y visión artificial optimizadas para entornos móviles.
2. Crear un dataset especializado que capture la diversidad de medidores y las condiciones de campo adversas (suciedad, oclusiones, iluminación variable) propias de las JAAPS, para contextualizar el entrenamiento del modelo.

3. Implementar un pipeline de IA eficiente, integrando detección y reconocimiento, que logre una precisión de lectura $>98\%$ con inferencia local (*offline*) en dispositivos móviles de gama media.
4. Integrar el pipeline optimizado en una aplicación Android funcional, diseñada con una arquitectura *offline-first* para asegurar su operatividad en zonas de conectividad intermitente o nula.
5. Cuantificar la mejora en eficiencia y precisión del prototipo mediante una validación comparativa en campo contra el método de lectura manual, estableciendo métricas de rendimiento en un contexto real.

1.5 Alcance y Limitaciones

A continuación, se definen las fronteras del presente trabajo de titulación, especificando tanto los entregables y funcionalidades que se desarrollarán, como los aspectos que quedan fuera del estudio.

1.5.1 Alcance del Proyecto

El alcance de esta investigación cubre los siguientes puntos:

- El desarrollo de un prototipo funcional de una aplicación móvil para la plataforma Android, capaz de capturar imágenes de medidores de agua.
- La creación de un dataset de imágenes propio, compuesto por fotografías de medidores de agua analógicos, recolectadas en condiciones de campo representativas de las Juntas Administradoras de Agua Potable y Saneamiento (JAAPS) rurales.
- El entrenamiento y la optimización de un modelo de aprendizaje profundo (OCR), específicamente diseñado para la detección y lectura de los dígitos de los medidores de agua, y preparado para su ejecución local en el dispositivo móvil (*offline*).
- La implementación de una aplicación móvil que captura imágenes de medidores para posteriormente ser procesadas por el modelo de IA, extraer la lectura y registrarla en el dispositivo.
- La validación técnica del prototipo en un entorno de campo controlado, donde se medirá y comparará su precisión y el tiempo de lectura frente al método manual tradicional.

1.5.2 Limitaciones de la Investigación

Para mantener el enfoque del proyecto, se establecen las siguientes limitaciones:

- El prototipo no es un sistema de gestión comercial completo. No incluirá funcionalidades avanzadas de facturación, gestión de abonados, o generación de reportes complejos, aunque su diseño permitirá la integración futura con dichos sistemas.
- El modelo de OCR se especializará en los medidores de tipo analógico (de reloj o dial) identificados en el estudio. No se abordará la lectura de medidores digitales ni de modelos analógicos con características muy atípicas que no formen parte del dataset.
- La aplicación móvil será desarrollada únicamente para el sistema operativo Android.
- La validación se centrará en la viabilidad y el rendimiento técnico (precisión, eficiencia) del prototipo. No se realizará un estudio a largo plazo sobre el impacto socioeconómico de la adopción de la herramienta en las JAAPS.
- El despliegue y las pruebas de campo se realizarán con un número limitado y representativo de JAAPS, por lo que los resultados no pueden ser generalizados a todas las juntas del país sin estudios adicionales de escalabilidad.

1.6 Estructura del Documento

El presente trabajo de titulación se articula en seis capítulos, diseñados para presentar la investigación de forma lógica y coherente.

- **Capítulo 1: Introducción.** Presenta la problemática de la lectura manual de medidores en las JAAPS rurales, justificando la solución propuesta y definiendo los objetivos y el alcance del proyecto.
- **Capítulo 2: Estado del Arte.** Analiza la literatura científica sobre gestión del agua, visión por computadora y modelos de OCR optimizados para dispositivos móviles, estableciendo el fundamento teórico del trabajo.
- **Capítulo 3: Metodología.** Detalla el diseño experimental y las fases del proyecto, incluyendo la creación del dataset, la selección y entrenamiento de los modelos de IA, y el protocolo para la validación en campo.

- **Capítulo 4: Desarrollo del sistema.** Describe la implementación técnica del prototipo, detallando la arquitectura del sistema, la optimización del modelo y el desarrollo de la aplicación Android con funcionalidad *offline*.
- **Capítulo 5: Evaluación y resultados.** Expone los resultados cuantitativos de la validación en campo, comparando la precisión y eficiencia del prototipo frente al método manual mediante métricas de rendimiento objetivas.
- **Capítulo 6: Conclusiones y recomendaciones.** Discute los hallazgos de la investigación, extrae las conclusiones sobre la viabilidad de la solución, y propone recomendaciones para trabajos futuros y la escalabilidad del proyecto.

Los capítulos subsiguientes amplían cada uno de estos aspectos, articulando la solución propuesta con el estado actual de la investigación y las necesidades operativas de las JAAPS.

Capítulo dos

Estado del arte

2.1 Gestión del agua en comunidades rurales: contexto y desafíos tecnológicos

2.1.1 *Las JAAPS como modelo de gestión comunitaria del agua*

En el Ecuador, la cobertura de servicios de agua potable en zonas rurales representa un desafío que el Estado no ha logrado suplir por completo. Para atender esta carencia, el marco legal ecuatoriano impulsa la gestión comunitaria del agua como un eje clave para la garantía de este derecho (Banco Interamericano de Desarrollo (BID), 2022, p. 16). Bajo este esquema, las Juntas Administradoras de Agua Potable y Saneamiento (JAAPS) se han consolidado como la principal forma de organización. Se trata de entidades sin fines de lucro, creadas y gestionadas por los propios miembros de la comunidad, quienes asumen la responsabilidad sobre la administración, operación y mantenimiento de los sistemas de agua a pequeña escala. Se calcula que en el país operan más de 5,000 de estas juntas, las cuales proveen servicio a una porción considerable de la población rural dispersa.

La estructura de una JAAP es, por naturaleza, democrática y voluntaria. Su máxima autoridad es la asamblea general de usuarios, de la cual emana un directorio electo periódicamente, integrado por un presidente, un tesorero, un secretario y vocales. Estos directivos, que generalmente no perciben remuneración, cargan con la totalidad de la gestión administrativa y técnica. Aunque su labor es vital para la sostenibilidad del servicio, esta se ve limitada por las capacidades y el tiempo que sus miembros pueden dedicar, lo que constituye una vulnerabilidad institucional intrínseca (Toma et al., 2020). El éxito del modelo recae, en gran medida, en el compromiso de la comunidad y en la habilidad de la junta para administrar con eficacia los recursos hídricos y financieros.

El proceso de lectura de medidores, que sirve de base para la facturación, es uno de los eslabones más críticos y donde se concentran las mayores ineficiencias. Dicho proceso es casi enteramente manual y sigue una secuencia de pasos propensa a errores:

1. **Planificación de la ruta:** El operador de la junta traza un recorrido para visitar los domicilios de los usuarios, los cuales pueden estar geográficamente dispersos en terrenos de difícil acceso.
2. **Toma de lectura manual:** El lector se desplaza a cada domicilio y registra de manera

visual el valor del medidor. Este dato se anota a mano en una libreta. Aquí afloran los primeros inconvenientes: medidores deteriorados, con visores opacos o sucios, o situados en lugares que dificultan una lectura precisa.

3. **Transcripción de datos:** Al finalizar la ruta, los datos de la libreta son transcritos a un registro centralizado, que puede ser un cuaderno o una hoja de cálculo básica. Este doble paso de digitación es una fuente significativa de errores.
4. **Cálculo del consumo y facturación:** Utilizando la lectura actual y la del mes anterior, se calcula el consumo y se emite la factura o recibo de pago, nuevamente de forma manual.

Los errores en este ciclo tienen un impacto directo y severo en la sostenibilidad financiera de las JAAPS. Un simple error de transcripción puede derivar en una subfacturación, privando a la junta de ingresos vitales para cubrir costos operativos, de mantenimiento y de cloración. A la inversa, una sobrefacturación puede erosionar la confianza y generar conflictos con los usuarios. Estudios preliminares en el marco de esta investigación sugieren que las desviaciones en los registros pueden alcanzar hasta un 10 %. Esta cifra es alarmante, pues se agrava con el problema del Agua No Contabilizada (ANC), que en sistemas gestionados localmente puede superar el 50 %, en un país donde el promedio nacional para GAD Municipales ya es del 51.8 % (Instituto Nacional de Estadística y Censos (INEC), 2024, p. 15). La combinación de pérdidas técnicas, como fugas, y comerciales, como errores de lectura, debilita un modelo de gestión que ya opera con recursos extremadamente limitados (Agencia de Cooperación Internacional del Japón (JICA), 2025).

2.1.2 Evolución tecnológica en la lectura de medidores de agua

La medición del consumo es la piedra angular en la gestión comercial de cualquier proveedor de agua. Tradicionalmente, este proceso ha recaído en métodos manuales, cuyas limitaciones son cada vez más evidentes. La lectura manual, tal como la que practican las JAAPS, es lenta, intensiva en mano de obra y altamente susceptible al error humano (Chaki et al., 2019). Los retos abarcan desde las dificultades de acceso físico a los medidores y los errores de transcripción, hasta la ausencia de datos en tiempo real que impide una gestión proactiva de la red, como la detección temprana de fugas.

Como respuesta, la industria ha desarrollado tecnologías cada vez más sofisticadas. La primera gran innovación fue la Lectura Automática de Medidores (AMR). Los sistemas AMR transmiten los datos del medidor de forma remota a un dispositivo de recolección cercano,

usualmente por radiofrecuencia. Esto elimina la necesidad de una inspección visual del medidor, reduciendo errores y agilizando el proceso, ya que un operador puede recoger las lecturas desde un vehículo (*drive-by*) (Banco Interamericano de Desarrollo (IADB), 2022). Si bien AMR fue un avance notable, aún requiere el despliegue de personal en campo y carece de comunicación bidireccional.

El siguiente paso evolutivo es la Infraestructura de Medición Avanzada (AMI), la cual emplea redes de comunicación fijas (celulares, fibra óptica) para crear un enlace bidireccional continuo entre el medidor inteligente y el sistema central. AMI no solo automatiza la lectura, sino que también posibilita la monitorización en tiempo real, la gestión remota de válvulas y el suministro de información detallada del consumo al usuario final (Global Growth Insights, 2023). Esta tecnología es el fundamento de las redes de agua inteligentes o *smart water grids*.

Pese a sus beneficios, la adopción de AMR y, sobre todo, de AMI en zonas rurales de países en desarrollo es prácticamente inexistente. El principal impedimento es la barrera económica. Los costos de inversión inicial son prohibitivos para organizaciones comunitarias como las JAAPS. Un medidor inteligente puede costar entre 5 y 10 veces más que uno mecánico tradicional, a lo que se suma el costo de la infraestructura de red, el software y la capacitación técnica para su mantenimiento (Fieldeke et al., 2021). Adicionalmente, la falta de conectividad fiable a internet y la inestabilidad del suministro eléctrico en muchas áreas rurales plantean obstáculos técnicos insalvables (Banco Interamericano de Desarrollo (IADB), 2022).

En este escenario, las soluciones basadas en visión artificial y dispositivos móviles surgen como una alternativa prometedora y de bajo costo. Este enfoque no precisa reemplazar la infraestructura de medidores existente. En su lugar, utiliza la cámara de un smartphone para capturar una imagen del medidor mecánico y un software de Reconocimiento Óptico de Caracteres (OCR) para extraer la lectura (Laroca et al., 2021). El costo se reduce drásticamente, pues el hardware principal es un teléfono inteligente, dispositivo de uso extendido incluso en zonas rurales. Investigaciones recientes han confirmado la alta precisión de los modelos de *deep learning* para esta tarea, aun en condiciones desafiantes como medidores sucios, con reflejos o en ángulos complejos (Hong et al., 2021; Liang et al., 2022; Peng et al., 2023). Esta aproximación constituye un puente tecnológico que aprovecha la infraestructura de medición existente y la combina con la inteligencia artificial en el borde (*edge AI*) para digitalizar el proceso con una inversión mínima (Carvalho et al., 2023; Ktari et al., 2022).

2.2 Reconocimiento óptico de caracteres aplicado a medidores

Tras establecer la necesidad de una solución de bajo costo para las JAAPS, esta sección profundiza en la tecnología clave que la habilita: el Reconocimiento Óptico de Caracteres (OCR). Se exploran las variantes de OCR aplicadas a medidores, desde sus fundamentos y evolución hacia el *deep learning*, hasta las arquitecturas de redes neuronales y los conjuntos de datos necesarios para su desarrollo.

2.2.1 Fundamentos del OCR en entornos industriales

El OCR es un campo de la visión por computadora que busca convertir imágenes de texto en datos codificados y procesables por una máquina. Históricamente, los sistemas OCR se apoyaban en un pipeline de múltiples etapas basado en técnicas de procesamiento de imágenes. Este incluía el preprocesamiento de la imagen (escala de grises, binarización de Otsu), la segmentación para aislar caracteres, la extracción de características de cada uno y, finalmente, su clasificación mediante algoritmos como Support Vector Machines (SVM) (Chaki et al., 2019).

Sin embargo, el entorno industrial, y específicamente la lectura de medidores analógicos, presenta desafíos que exponen las debilidades de los métodos tradicionales. Los dígitos en un medidor poseen características particulares:

- **Fuentes y alineación:** Los dígitos, a menudo de tipo siete segmentos, sufren de alineación imperfecta y rotaciones parciales, sobre todo durante la transición entre números (un '3' a medio camino de ser un '4').
- **Condiciones de la carátula:** La superficie está expuesta a suciedad, rayones, condensación y reflejos que pueden ocultar o distorsionar los dígitos.
- **Iluminación variable:** La captura en campo se realiza bajo condiciones de luz no controladas, desde sol directo hasta sombras profundas.

Estos factores hacen que la segmentación precisa de los dígitos, un paso crucial en los métodos clásicos, sea extremadamente frágil, llevando a errores de reconocimiento.

El arribo del aprendizaje profundo (*deep learning*) ha revolucionado el OCR. Las Redes Neuronales Convolucionales (CNNs) permiten un enfoque de extremo a extremo (*end-to-end*) que aprende a extraer características relevantes directamente de la imagen, mostrando una robustez muy superior. Para evaluar estos sistemas se emplean métricas como la Tasa de

Error de Caracteres (CER) y la Tasa de Error de "Palabra"(WER), donde una "palabra" es la secuencia completa de dígitos. Para que una solución sea viable para facturación, la industria demanda una precisión por dígito superior al 98 % o 99 %, ya que cualquier error tiene un impacto económico directo (Laroca et al., 2021).

2.2.2 Arquitecturas de redes neuronales para OCR

Las redes neuronales profundas han generado diversas arquitecturas para el problema del OCR. Los modelos más avanzados y robustos integran la detección y el reconocimiento en un único pipeline *end-to-end*. Estos se dividen en dos categorías: los **detectores de texto**, que localizan las regiones de interés (ej. EAST, CRAFT), y los **reconocedores de texto**, que transcriben la región detectada a una secuencia de caracteres (Peng et al., 2023).

Una de las arquitecturas más influyentes es la Red Neuronal Convolutiva Recurrente (CRNN) (Laroca et al., 2021). Un modelo CRNN se compone de tres partes:

1. **Capas Convolucionales (CNN):** Extraen un mapa de características robustas de la imagen.
2. **Capas Recurrentes (RNN):** Una red LSTM bidireccional procesa la secuencia de características generada por la CNN, permitiendo al modelo aprender el contexto secuencial.
3. **Capa de Transcripción:** Utiliza una función de pérdida como la Clasificación Temporal Conexionista (CTC) para traducir las predicciones de la RNN a la secuencia final de etiquetas.

La función de pérdida CTC es fundamental, pues elimina la necesidad de segmentar cada carácter explícitamente. Permite entrenar el modelo solo con la imagen y la secuencia de dígitos correcta, sin requerir la ubicación exacta de cada uno. La pérdida CTC suma las probabilidades de todas las posibles alineaciones entre la predicción y el objetivo. Formalmente, la probabilidad de una secuencia π dada una entrada y se define como:

$$P(\pi|y) = \sum_{\mathbf{a} \in \mathcal{A}_{\pi,y}} \prod_{t=1}^T p_t(a_t|y) \quad (2.1)$$

donde $\mathcal{A}_{\pi,y}$ es el conjunto de todas las alineaciones posibles y $p_t(a_t|y)$ es la probabilidad del carácter a_t en el tiempo t .

El principal compromiso en la elección de una arquitectura radica en el balance entre precisión y eficiencia computacional. Modelos más grandes pueden ser más precisos, pero su

tamaño, latencia y consumo energético los hacen inadecuados para dispositivos móviles (Carvalho et al., 2023; Zou et al., 2021). Por ello, la investigación actual se enfoca en arquitecturas ligeras (*lightweight*) para la implementación en el borde (*edge computing*).

2.2.3 Datasets y benchmarks relevantes

El rendimiento de cualquier modelo de aprendizaje profundo depende de la calidad y cantidad de los datos de entrenamiento. En el dominio de la lectura de medidores, la creación de un dataset robusto es un desafío. Aunque existen datasets públicos como **UFPR-AMR Dataset** (Laroca et al., 2021) y su extensión (Salomon et al., 2022), estos no siempre capturan la enorme variabilidad de medidores y condiciones presentes en contextos específicos como el de las JAAPS en Ecuador.

La dificultad de recolectar y anotar miles de imágenes de campo hace que las técnicas de **aumento de datos** (*data augmentation*) sean indispensables. Más allá de transformaciones genéricas, se deben aplicar técnicas específicas para simular los desafíos del mundo real:

- **Transformaciones Geométricas:** Simulación de distorsiones de perspectiva para imitar la captura desde diferentes ángulos.
- **Simulación de Condiciones Adversas:** Aplicación de desenfoque de movimiento, ruido y simulación de reflejos o gotas de agua.
- **Generación de Datos Sintéticos:** Uso de gráficos por computadora (CGI) para generar imágenes fotorrealistas de medidores en una variedad infinita de estados y condiciones, incluyendo los dígitos en transición (Sripanuskul et al., 2022).

Estas técnicas no solo incrementan el tamaño del dataset, sino que también mejoran la robustez y capacidad de generalización del modelo. Un *benchmarking* riguroso contra un conjunto de prueba representativo del entorno de despliegue final es esencial para validar la eficacia del modelo.

2.3 Deep Learning en dispositivos móviles con recursos limitados

El despliegue de las arquitecturas de OCR en un prototipo móvil, destinado a operar con recursos limitados, presenta desafíos significativos. Esta sección examina las estrategias que permiten la ejecución eficiente de modelos de *deep learning* en el borde (*edge computing*), abordando las restricciones de hardware y los requisitos de rendimiento.

2.3.1 Arquitecturas eficientes para edge computing

El *edge computing* implica procesar datos cerca de su origen, lo cual para la lectura de medidores ofrece ventajas como el funcionamiento offline, baja latencia y mayor privacidad. Esto requiere el uso de arquitecturas de redes neuronales diseñadas para ser ligeras y rápidas.

La evolución de estas arquitecturas se apoya en innovaciones como la **convolución separable en profundidad (*depthwise separable convolution*)**, pilar de la familia de redes **MobileNet**. Por su parte, la familia **EfficientNet** introdujo un **método de escalado compuesto (*compound scaling*)** para balancear sistemáticamente la profundidad, el ancho y la resolución de la red (Poddar et al., 2024).

Desarrollos posteriores como **EfficientNetV2** (Tan & Le, 2021) mejoraron la velocidad de entrenamiento y la eficiencia. Más recientemente, arquitecturas híbridas que combinan convoluciones y mecanismos de atención de los Transformers, como **MobileViT** (Mehta & Rastegari, 2022), han mostrado resultados prometedores. La elección final depende del balance específico entre la precisión deseada y la latencia tolerable en el dispositivo objetivo (Poddar et al., 2024).

Tabla 2.1: Comparativa de arquitecturas eficientes modernas (ejemplo en ImageNet).

Modelo	Precisión Top-1 (%)	Parámetros (M)
MobileNetV3-Large	75.2	5.5
EfficientNet-B0	77.1	5.3
EfficientNetV2-S	83.9	21.5
MobileViT-S	78.4	5.6

2.3.2 Optimización y compresión de modelos

Un diseño de arquitectura eficiente es solo el primer paso. Para un rendimiento óptimo en dispositivos de gama media, es crucial aplicar técnicas de optimización. La **cuantización**, que reduce la precisión de los pesos de punto flotante de 32 bits (FP32) a enteros de 8 bits (INT8), es la más común. El **entrenamiento consciente de la cuantización (QAT)** suele preservar mejor la precisión que la **cuantización post-entrenamiento (PTQ)** (Ghosh et al., 2023).

Otras técnicas como el **podado (*pruning*)**, que elimina pesos redundantes, y la **destilación del conocimiento (*knowledge distillation*)**, que usa un modelo "profesor" grande para entrenar un modelo "estudiante" pequeño, son prácticas estándar para la optimización de modelos en el borde (Li et al., 2023).

2.3.3 Frameworks de inferencia móvil

Para el despliegue de estos modelos en Android, se requiere un framework de inferencia como **TensorFlow Lite (TFLite)**. TFLite proporciona un intérprete ligero y herramientas para la conversión de modelos. Su característica principal son los **delegados (delegates)**, que redirigen la computación a aceleradores de hardware como la GPU o las Unidades de Procesamiento Neuronal (NPU) a través de la API de redes neuronales de Android (NNAPI). El uso correcto de estos delegados es vital para minimizar la latencia y el consumo de energía (Albonico et al., 2023).

La gestión de recursos, como el control de hilos y la monitorización de la temperatura para evitar el *thermal throttling*, es esencial para la estabilidad de la aplicación en condiciones de uso prolongado. Herramientas como el *Profiler* de Android Studio y la *TFLite benchmark tool* son indispensables durante el desarrollo para asegurar la robustez y eficiencia del prototipo.

2.4 Sistemas de visión artificial para lectura automática de medidores

La implementación práctica de un sistema de visión para la lectura de medidores requiere una integración cuidadosa de múltiples etapas de procesamiento para operar de manera robusta en el mundo real (Laroca et al., 2021). Estos sistemas deben mantener su desempeño ante la variabilidad de entornos no controlados, donde la iluminación, los ángulos de captura y el deterioro de los equipos plantean desafíos constantes (Hong et al., 2021).

2.4.1 Pipeline completo de procesamiento

Un sistema robusto de lectura automática se compone de varias etapas interdependientes. El pipeline típico comienza con la adquisición de la imagen y termina con la validación de la lectura, lo que exige un equilibrio entre precisión, eficiencia y robustez (Khan et al., 2024).

La primera etapa computacional es la **detección y localización del medidor**. Los sistemas modernos emplean modelos de detección de objetos como YOLOv8, que ofrecen un excelente balance entre velocidad y precisión para su despliegue en móviles (Khan et al., 2024; Wang et al., 2025).

Una vez localizada la Región de Interés (ROI), la etapa de **pre-procesamiento y normalización** es crucial. Un paso fundamental es la **corrección de perspectiva**, donde se detectan las cuatro esquinas del contador para calcular una matriz de homografía y rectificar la ROI a una vista frontal. Enfoques avanzados, como los propuestos por (Peng et al., 2023), utilizan modelos ligeros adicionales para esta tarea, mejorando la precisión. A continuación, técnicas como CLAHE normalizan la iluminación.

Diagrama de Flujo del Pipeline de Lectura Automática:

1. **Adquisición de Imagen:** El usuario captura una imagen del medidor.
2. **Detección del Medidor (YOLOv8):** Un modelo de detección de objetos localiza el medidor.
3. **Extracción y Pre-procesamiento de ROI:**
 - Se recorta la Región de Interés (ROI) del contador.
 - **Corrección de Perspectiva:** Se aplica una transformación de homografía para rectificar la ROI.
 - **Normalización de Iluminación:** Se utilizan técnicas como CLAHE para estandarizar el contraste.
4. **Reconocimiento de Dígitos (CRNN):** La ROI procesada se introduce en un modelo OCR.
5. **Post-procesamiento y Validación:**
 - **Validación de Coherencia:** Se verifica que la lectura sea numéricamente coherente.
 - **Confirmación del Usuario:** La lectura se muestra al usuario para su confirmación final.

Figura 2.1: Pipeline completo de procesamiento para la lectura automática de medidores.

Finalmente, la ROI normalizada se envía a la etapa de **reconocimiento**. Modelos como CRNN leen la secuencia completa de dígitos, lo que aumenta la robustez. La salida del modelo se somete a un **post-procesamiento** que incluye la validación de coherencia numérica y puede solicitar una nueva captura si la confianza de la predicción es baja. Adicionalmente, se puede integrar un clasificador de calidad de imagen para rechazar capturas de baja calidad antes del reconocimiento, mejorando la fiabilidad del sistema (Laroca et al., 2021).

2.4.2 Robustez ante condiciones adversas

La diferencia entre un prototipo de laboratorio y un sistema de campo es su capacidad para manejar condiciones no ideales. Las **variaciones de iluminación**, como reflejos y sombras, son el desafío más común. Aunque técnicas como CLAHE ayudan en tiempo de ejecución, la estrategia más efectiva es entrenar el modelo con una agresiva **augmentación de datos**, simulando programáticamente una amplia gama de condiciones adversas, una técnica de probada eficacia (Hong et al., 2021).

Las **variaciones geométricas**, como ángulos de captura extremos, se abordan con la

corrección de perspectiva, la cual depende de un modelo de detección de esquinas robusto. El **deterioro físico de los medidores** (rayones, condensación, suciedad) es otro factor crítico. Un modelo bien entrenado puede aprender a ignorar muchas de estas obstrucciones, pero los casos severos pueden requerir un pre-clasificador que evalúe la calidad de la imagen y solicite una nueva captura si es necesario (Laroca et al., 2021).

2.4.3 Implementaciones existentes: análisis crítico

En los últimos años, han surgido diversas propuestas académicas y comerciales. Las **soluciones académicas** han demostrado la viabilidad del *deep learning*, alcanzando precisiones superiores al 99 % en datasets públicos (Liang et al., 2022; Maheshwari & Singh, 2023). Sin embargo, a menudo se validan en condiciones que no representan la extrema variabilidad de los entornos rurales en países en desarrollo.

Las **soluciones comerciales** operan como “cajas negras”, con poca información pública sobre su arquitectura o rendimiento real. Están diseñadas para grandes empresas de servicios públicos urbanos, con un modelo de negocio de licenciamiento inviable para una JAAP y, por lo general, dependientes de una conexión constante a internet, un requisito prohibitivo en este contexto (Fieldeke et al., 2021).

Tabla 2.2: Análisis crítico de tipos de implementaciones de lectura automática.

Criterio	Métodos Tradicionales	Soluciones Académicas (DL)	Soluciones Comerciales
Precisión	Baja a media, frágil	Muy alta (>99 %) en benchmarks	Alta (declarada)
Robustez	Muy baja	Alta, dependiente del dataset	Desconocida, propietaria
Costo	Bajo (desarrollo)	Bajo a medio (requiere datos)	Alto (licencias, TCO)
Hardware	Ligero	Variable, optimizable para móviles	Generalmente requiere backend
Conectividad	No necesaria	Puede ser offline	Generalmente requiere online
Adaptabilidad	Específico, difícil de generalizar	Alta, re-entrenable	Baja, caja negra
Viabilidad JAAPS	Inviabile (frágil)	Potencialmente viable	Inviabile (costo, conectividad)

Las **limitaciones para contextos rurales** son la principal brecha que estas implementaciones no cubren. La dependencia de la conectividad, los altos costos y la falta de adaptabilidad a la diversidad de medidores antiguos definen una clara **oportunidad para la presente investigación**: el desarrollo de un sistema de código abierto, diseñado para operación offline, optimizado para hardware de bajo costo, y entrenado con un dataset que capture la realidad de los medidores gestionados por las JAAPS.

2.5 Desarrollo de aplicaciones móviles offline con IA integrada

La construcción de un prototipo para las JAAPS requiere la convergencia de la gestión comunitaria del agua, la visión por computadora y la optimización de modelos. Esta sección se enfoca en la disciplina que une estos campos: el desarrollo de aplicaciones móviles con

capacidad offline e inteligencia artificial integrada.

2.5.1 Arquitecturas offline-first

Diseñar una aplicación para zonas con conectividad intermitente exige un enfoque *offline-first*, donde la aplicación funciona de manera autónoma y la conexión a la red es un recurso opcional. La fuente de verdad principal es la base de datos local del dispositivo.

Para ello, se emplea el **Patrón de Repositorio (Repository Pattern)**, que aísla las fuentes de datos (red, base de datos local) de la lógica de negocio. El repositorio gestiona si los datos se obtienen de la caché local o se sincronizan con un servidor cuando hay conexión. La **sincronización eventual** se maneja con herramientas como **WorkManager** de Android Jetpack, que programa tareas de sincronización para cuando se restablezca la conexión. Para el almacenamiento local, la biblioteca **Room Database** sobre SQLite es el estándar en Android.




Figura 2.2: Arquitectura recomendada para una aplicación offline-first en Android.

2.5.2 Integración de modelos de IA en Android

Integrar un modelo de TensorFlow Lite (TFLite) en una aplicación Android requiere una gestión cuidadosa del rendimiento. La inicialización del intérprete de TFLite debe realizarse en un hilo de fondo para no bloquear la UI. El siguiente fragmento en Kotlin muestra una inicialización que configura el número de hilos y un delegado de GPU.

```
// Ejemplo de inicialización de modelo TFLite en Kotlin
private fun initializeInterpreter(modelPath: String): Interpreter {
    val modelBuffer = FileUtil.loadMappedFile(context, modelPath)
    val options = Interpreter.Options()
    options.setNumThreads(4)

    // Intentar usar el delegado de GPU
    val gpuDelegate = GpuDelegate()
```

```

options.addDelegate(gpuDelegate)

try {
    return Interpreter(modelBuffer, options)
} catch (e: Exception) {
    // Si falla la GPU, volver a intentarlo solo con CPU
    options.removeDelegate(gpuDelegate)
    return Interpreter(modelBuffer, options)
}
}

```

El manejo de **hilos y concurrencia** es vital. La inferencia del modelo debe ejecutarse en un hilo de fondo para no causar bloqueos (ANR). Las **Coroutines** de Kotlin son la herramienta recomendada para gestionar operaciones asíncronas. La **optimización de la memoria** también es crítica; los 'Bitmaps' de Android deben manejarse con cuidado y los modelos de TFLite pueden ser cargados como 'MappedByteBuffer' para un uso más eficiente de la memoria. Finalmente, una **UI/UX de captura guiada**, utilizando la API **CameraX**, puede superponer un recuadro sobre la vista previa de la cámara para ayudar al operario a alinear el medidor y proporcionar feedback en tiempo real.

2.5.3 Consideraciones de usabilidad rural

Una aplicación técnicamente robusta puede fracasar si no se adapta a sus usuarios finales. Para los operarios de las JAAPS, que pueden tener baja alfabetización digital, el diseño de la interfaz y la experiencia de usuario (UI/UX) es tan crucial como la precisión del modelo.

El diseño debe ser **minimalista y centrado en la tarea**, priorizando la iconografía sobre el texto. Los flujos de trabajo deben ser lineales y divididos en pasos claros. El **feedback al usuario** debe ser constante y multisensorial (visual, auditivo, háptico) para confirmar acciones. Los mensajes de error deben ser simples y accionables.

La aplicación debe, además, adaptarse al **contexto físico de uso**, con interfaces de alto contraste para visibilidad bajo luz solar y botones grandes. La suma de estas consideraciones de diseño centrado en el ser humano es lo que puede transformar un motor de IA en una herramienta adoptable y útil para las comunidades a las que busca servir.

Tabla 2.3: *Tabla de consideraciones de diseño de UI/UX para contextos rurales.*

Consideración	Implementación Sugerida
Baja alfabetización digital	Iconos grandes y universales, mínimo texto, tutoriales guiados.
Condiciones de campo	Interfaz de alto contraste (modo para luz solar), botones grandes para uso con guantes, operación con una mano.
Confirmación de acciones	Feedback visual (colores), auditivo (sonidos) y háptico (vibración) para cada acción clave.
Manejo de errores	Mensajes de error en lenguaje simple con sugerencias claras para la recuperación. Logging local para soporte técnico remoto.
Batería y recursos	Modo de ahorro de energía opcional, optimización del uso de la cámara y del procesador.
Contexto cultural	Soporte para español y, potencialmente, quechua. Uso de formatos de fecha y número locales.

2.6 Análisis comparativo y oportunidades de innovación

El presente capítulo ha realizado un recorrido desde el contexto socio-operativo de las JAAPS hasta los detalles técnicos del deep learning móvil. Esta sección final sintetiza el conocimiento, evalúa críticamente las soluciones existentes, identifica las brechas en la investigación y, a partir de ello, justifica el enfoque propuesto por esta tesis.

2.6.1 Matriz de evaluación de soluciones existentes

Para contextualizar la propuesta, es imperativo comparar las alternativas existentes frente a criterios ponderados por las realidades del entorno rural ecuatoriano. Ninguna solución puede ser evaluada en el vacío; su valor es relativo a las necesidades y limitaciones del contexto de aplicación.

El análisis de la matriz revela un panorama claro. La **lectura manual**, pese a su imprecisión, persiste por ser la única solución de costo cero y funcionamiento offline. Los sistemas **AMI/AMR comerciales**, aunque técnicamente superiores, son inviables por sus barreras económicas y de infraestructura. Las aplicaciones **OCR basadas en la nube** resuelven la precisión, pero sustituyen la dependencia de infraestructura física por la de conectividad, una barrera igualmente crítica en el Ecuador rural. Las **soluciones académicas** han sentado las bases técnicas, pero tienden a operar en condiciones de laboratorio y rara vez abordan integralmente los requisitos de una implementación offline y usable para personal no especializado.

2.6.2 Brechas identificadas en el estado del arte

La síntesis anterior permite identificar un conjunto de brechas críticas que representan la oportunidad para la innovación.

Tabla 2.4: Matriz de evaluación comparativa de soluciones para lectura de medidores en el contexto de las JAAPS.

Criterio		Lectura Manual (Baseline)	AMI/AMR Comercial	App OCR (Cloud-based)	Académico (Genérico)	Propuesta Tesis (Offline-first)
Técnicos	Precisión	Baja (~90-95 %), sujeta a error humano.	Muy alta (>99.5 %).	Alta (>98 %), dependiente de la calidad de imagen.	Alta (>99 % en benchmarks), no validada en campo.	Objetivo: >98.5 % en campo.
	Latencia	Días (proceso completo).	Segundos a minutos.	Segundos (dependiente de red).	ms a segundos (dependiente de hardware).	<2 segundos en dispositivo.
	Offline	Totalmente offline.	No, requiere infraestructura de red fija.	No, requiere conexión a internet para procesar.	Parcialmente, no diseñado para ello.	Totalmente offline (diseño central).
	Consumo Energético	N/A.	Alto (infraestructura de red).	Moderado (uso de red y cámara).	No especificado.	Optimizado para bajo consumo.
Operativos	Costo Inicial	Cero.	Prohibitivo (>\$50k).	Bajo (<\$1k para desarrollo inicial).	N/A (investigación).	Muy bajo (<\$500 para prototipo).
	Costo Mantenimiento	Tiempo del operario.	Alto (licencias, soporte, hardware).	Moderado (costos de servidor/API).	N/A.	Casi nulo (software libre).
	Escalabilidad	Muy baja y lineal.	Alta, con alta inversión.	Moderada, limitada por costos de nube.	N/A.	Alta, sin costo de infraestructura.
	Capacitación	Baja.	Alta (personal técnico especializado).	Moderada.	Alta (requiere conocimiento de IA).	Baja, diseñada para usabilidad.
Sociales	Adopción Rural	Establecida.	Muy baja, por barreras económicas y técnicas.	Baja, por dependencia de red.	N/A.	Alta (diseñada para el contexto).
	Sostenibilidad	Baja (depende de voluntarios y es ineficiente).	Baja (insostenible para JAAPS).	Media (depende de pagos recurrentes).	N/A.	Alta (autonomía local).
	Alineación Local	Total.	Nula.	Baja.	Baja.	Total (co-diseño implícito).

Brechas Técnicas:

- **Robustez en el “último 1 %”:** Mientras que muchos modelos alcanzan >99 % de precisión en benchmarks, falta investigación sobre las causas de fallo en el <1 % restante, que a menudo corresponden a las condiciones más extremas (reflejos severos, oclusión parcial, dígitos en transición) que son frecuentes en campo.
- **Generalización a la “fauna” de medidores locales:** Los modelos suelen entrenarse en datasets con poca variedad de medidores. No existe una solución probada que generalice bien a la enorme diversidad de modelos, antigüedades y estados de conservación de los medidores instalados en la zona andina.
- **Ausencia de un pipeline integral y optimizado para el borde:** No se ha documen-

tado en la literatura una solución que integre un pipeline completo (detección, rectificación, reconocimiento) y que esté explícitamente optimizado mediante técnicas como la cuantización y el podado para funcionar eficientemente en dispositivos móviles de gama media-baja, prevalentes en el contexto rural.

Brechas de Implementación y Contexto:

- **El “abismo” del costo y la conectividad:** Existe una brecha abismal entre las soluciones comerciales (altamente funcionales pero inaccesibles) y la realidad operativa de las JAAPS. Ninguna solución comercial actual está diseñada para un modelo de negocio de costo casi nulo y operación offline.
- **Falta de validación en campo real latinoamericano:** La gran mayoría de los estudios académicos se realizan en Asia, Europa o Norteamérica, o en contextos urbanos de Brasil. Faltan estudios que validen estas tecnologías en las condiciones geográficas, climáticas y socio-técnicas específicas de las comunidades rurales andinas.
- **El eslabón perdido de la usabilidad:** Se ha prestado poca atención al diseño de la interfaz de usuario y la experiencia de usuario (UI/UX) para operarios con baja alfabetización digital. La tecnología, sin una interfaz que facilite su adopción, está destinada al fracaso.

2.6.3 Justificación del enfoque propuesto

El análisis anterior demuestra que no existe una solución que aborde simultáneamente los requisitos técnicos, operativos y sociales de las JAAPS. Esta intersección de necesidades no cubiertas es precisamente donde se posiciona y justifica la presente tesis. El enfoque propuesto no busca simplemente mejorar la precisión en un pequeño porcentaje, sino crear una solución holística y apropiada tecnológicamente.

Ventajas y Alineación con el Contexto: La propuesta de desarrollar un prototipo móvil para la lectura de medidores con operación 100 % offline y optimizado para hardware de gama media responde directamente a las principales barreras identificadas:

1. **Resuelve la barrera de la conectividad:** Al ser offline-first, la herramienta es funcional en el 100 % del territorio de operación de las JAAPS.
2. **Supera la barrera del costo:** Al basarse en software de código abierto y hardware de consumo (smartphones que los operarios a menudo ya poseen), el costo de implementación y mantenimiento es marginal, alineándose con el modelo económico de las juntas.

3. **Cierra la brecha de la usabilidad:** El diseño centrado en el usuario para personal con capacidades digitales variables es un pilar de la propuesta, buscando maximizar la adopción y minimizar la frustración.
4. **Aborda la diversidad de medidores:** La creación de un dataset específico del contexto ecuatoriano permitirá entrenar un modelo adaptado a la realidad local, en lugar de usar modelos genéricos con menor rendimiento.

Contribuciones Científicas y Prácticas Esperadas: Esta tesis aspira a realizar las siguientes contribuciones originales al campo:

- **Técnica:** El diseño y validación de un pipeline completo de visión artificial (detección + OCR) optimizado para una alta eficiencia (latencia <2s) en dispositivos móviles de recursos limitados, con un análisis detallado de los trade-offs de las técnicas de cuantización en esta tarea específica.
- **Empírica:** La creación y publicación de un nuevo dataset de imágenes de medidores de agua del contexto rural ecuatoriano, anotado y validado, que sirva como benchmark para futuras investigaciones en la región.
- **Metodológica:** El desarrollo de un modelo de implementación y validación de una solución de IA en un entorno comunitario real, documentando no solo los resultados técnicos sino también el proceso de adopción, capacitación y el impacto socioeconómico medible.

El estado del arte muestra que las herramientas existen, pero están desarticuladas y no han sido ensambladas y adaptadas para el problema específico que nos ocupa. La innovación de esta tesis no radica en inventar un nuevo algoritmo de deep learning desde cero, sino en el **diseño, la integración, la optimización y la validación de un sistema completo en un contexto real y desatendido**, demostrando que la inteligencia artificial puede ser una herramienta poderosa y accesible para fortalecer la gestión comunitaria del agua. Este capítulo ha sentado las bases teóricas y ha justificado la necesidad de este trabajo; el siguiente capítulo detallará la metodología para llevarlo a cabo.

Capítulo tres

Metodología

3.1 Enfoque general del desarrollo

3.2 Fases metodológicas del proyecto

3.2.1 *Revisión de literatura*

3.2.2 *Construcción del dataset*

3.2.3 *Entrenamiento y optimización de modelos*

3.2.4 *Desarrollo de la aplicación*

3.2.5 *Validación del prototipo*

3.3 Herramientas y tecnologías utilizadas

3.4 Consideraciones éticas y operativas

Capítulo cuatro

Desarrollo del sistema

- 4.1 Diseño de la arquitectura del sistema**
- 4.2 Adquisición, etiquetado y depuración del dataset**
- 4.3 Diseño y entrenamiento del modelo OCR ligero**
- 4.4 Implementación de lógica de captura asistida de imágenes**
- 4.5 Desarrollo de la aplicación móvil y sincronización de datos**
- 4.6 Integración del sistema y pruebas internas**

Capítulo cinco

Evaluación y resultados

- 5.1 Diseño de experimentos y métricas de evaluación**
- 5.2 Resultados de precisión, latencia y eficiencia energética**
- 5.3 Comparativa con procesos tradicionales de lectura**
- 5.4 Validación en campo con usuarios reales**
- 5.5 Discusión de resultados y cumplimiento de objetivos**

Capítulo seis

Conclusiones y recomendaciones

- 6.1 Conclusiones generales**
- 6.2 Lecciones aprendidas del proceso de desarrollo**
- 6.3 Limitaciones técnicas y metodológicas**
- 6.4 Recomendaciones para futuras investigaciones**
- 6.5 Posibilidades de escalabilidad y transferencia tecnológica**

Referencias

- Agencia de Cooperación Internacional del Japón (JICA). (2025). *Agua No Contabilizada: Documento Técnico 2025* (inf. téc.) (Documento de trabajo sobre la gestión de pérdidas de agua en Ecuador). JICA.
- Albonico, A., Pagliari, D. J., Risso, M., Averta, G., & Garza, P. (2023). A Benchmark of Deep Learning Frameworks for Mobile and Embedded Devices. *2023 IEEE 7th International Conference on Fog and Edge Computing (ICFEC)*, 90-99. <https://doi.org/10.1109/ICFEC58326.2023.00019>
- Banco Interamericano de Desarrollo (BID). (2022). *La Gestión Comunitaria del Agua en América Latina: Modelos, Desafíos y Oportunidades* (inf. téc.) (Documento de análisis sectorial sobre los servicios de agua y saneamiento). BID.
- Banco Interamericano de Desarrollo (IADB). (2022). *La Medición Inteligente en América Latina y el Caribe: Recomendaciones regulatorias para incentivar el despliegue* (inf. téc.). IADB. <https://publications.iadb.org/publications/spanish/document/La-Medicion-Inteligente-en-America-Latina-y-el-Caribe-Recomendaciones-regulatorias-para-incentivar-el-despliegue-de-la-medicion-inteligente-a-nivel-nacional.pdf>
- Carvalho, R., Melo, J., Graça, R., Santos, G., & Vasconcelos, M. J. M. (2023). Deep learning-powered system for real-time digital meter reading on edge devices. *Applied Sciences*, 13(4), 2315. <https://doi.org/10.3390/app13042315>
- Chaki, S., Shila, D. A., & Jahan, N. (2019). Automation of water meter billing process based on digital image processing approach. *Journal of Advances in Technology and Engineering Research*, 5(5), 207-218. <https://doi.org/10.20474/jater-5.5.3>
- Fieldeke, I. C., Schraven, A., & Jensen, C. B. (2021). Barriers to the Digital Transformation of Rural Water Services in Sub-Saharan Africa. *Water*, 13(16), 2273. <https://doi.org/10.3390/w13162273>
- Ghosh, A., PU, R., & Muralidhara, V. N. (2023). A Survey on Quantization Techniques in Deep Neural Networks. *SN Computer Science*, 4(4), 348. <https://doi.org/10.1007/s42979-023-01783-0>
- Global Growth Insights. (2023). Análisis del mercado de medidores de agua inteligentes 2023-2033 [Informe de mercado sobre tecnologías de medición de agua.].

- Hong, Q., Ding, Y., Lin, J., Wang, M., Wei, Q., Wang, X., & Zeng, M. (2021). Image-Based Automatic Watermeter Reading under Challenging Environments. *Sensors*, 21(2), 434. <https://doi.org/10.3390/s21020434>
- Instituto Nacional de Estadística y Censos (INEC). (2024). *Encuesta de Gestión de Agua Potable y Saneamiento 2023* (inf. téc.) (Publicado en el sitio web del INEC con resultados del año 2023). INEC. Quito, Ecuador.
- Khan, F., Rafique, S., & Khan, G. M. (2024). Low-Cost Smart Metering Using Deep Learning [DOI no encontrado]. *International Journal of Innovations in Science & Technology (IJIST)*, Special Issue, 93-104.
- Ktari, J., Frikha, T., Hamdi, M., Elmannai, H., & Hmam, H. (2022). Lightweight AI Framework for Industry 4.0 Case Study: Water Meter Recognition. *Big Data and Cognitive Computing*, 6(3), 72. <https://doi.org/10.3390/bdcc6030072>
- Laroca, R., Araujo, A. B., Zanlorensi, L. A., Almeida, E. C. D., & Menotti, D. (2021). Towards Image-Based Automatic Meter Reading in Unconstrained Scenarios: A Robust and Efficient Approach. *IEEE Access*, 9, 67569-67584. <https://doi.org/10.1109/ACCESS.2021.3077415>
- Li, J., Yipeng-Gen, Chuan-Chi & Yichuan-Li. (2023). A Survey on Deep Learning-based Edge-AI. *arXiv preprint arXiv:2307.03967*.
- Liang, Y., Liao, Y., Li, S., Wu, W., Qiu, T., & Zhang, W. (2022). Research on water meter reading recognition based on deep learning. *Scientific Reports*, 12(1), 12861. <https://doi.org/10.1038/s41598-022-17255-3>
- Maheshwari, U., & Singh, K. K. (2023). Automatic Meter Detection and Recognition: A Robust Approach Based on Image Processing Techniques. *International Journal for Research in Applied Science and Engineering Technology (IJRASET)*, 11(6). <https://doi.org/10.22214/ijraset.2023.54438>
- Mehta, S., & Rastegari, M. (2022). MobileViT: Light-weight, General-purpose, and Mobile-friendly Vision Transformer. *International Conference on Learning Representations (ICLR)*.
- Naciones Unidas. (2015). Transformar nuestro mundo: la Agenda 2030 para el Desarrollo Sostenible [Resolución aprobada por la Asamblea General el 25 de septiembre de 2015. Consultado el 16 de junio de 2025]. <https://sdgs.un.org/2030agenda>

- Peng, J., Zhou, W., Han, Y., Li, M., & Liu, W. (2023). Deep learning-based autonomous real-time digital meter reading recognition method for natural scenes. *Measurement*, 222, 113615. <https://doi.org/10.1016/j.measurement.2023.113615>
- Poddar, A. K., Singh, S., & Chakraborty, T. (2024). A survey of deep learning models for resource-constrained edge devices. *Artificial Intelligence Review*. <https://doi.org/10.1007/s10462-024-10775-8>
- Salomon, G., Laroca, R., & Menotti, D. (2022). Image-Based Automatic Dial Meter Reading in Unconstrained Scenarios [También disponible como preimpresión de arXiv arXiv:2201.02850]. *Measurement*. <https://doi.org/10.1016/j.measurement.2022.112025>
- Sripanuskul, N., Buayai, P., & Mao, X. (2022). Generative Data Augmentation for Automatic Meter Reading Using CNNs. *IEEE Access*, 10, 28471-28486. <https://doi.org/10.1109/ACCESS.2022.3157706>
- Tan, M., & Le, Q. V. (2021). EfficientNetV2: Smaller Models and Faster Training. *Proceedings of the 38th International Conference on Machine Learning (ICML)*, 10096-10106.
- Toma, C., Márquez, W., Pumisacho, V., Aldás, M., & Márquez, M. (2020). Factors Affecting the Sustainability of Rural Drinking Water Services in the Andean Region of Ecuador. *Sustainability*, 12(23), 9964. <https://doi.org/10.3390/su12239964>
- Wang, H., Wang, N., & An, X. (2025). CAM-YOLO v8: A model for water meter word wheel region segmentation. *Proceedings of the 2nd International Conference on Generative Artificial Intelligence and Information Security (GAIIIS)*. <https://doi.org/10.1145/3728725.3728769>
- Zou, F., Shi, Z., Gan, Z., Liao, L., & Xu, J. (2021). Water Meter Reading Recognition Based on Lightweight CNN. *Proceedings of the International Conference on Frontiers of Electronics, Information and Computation Technologies (ICFEICT)*. <https://doi.org/10.1145/3474198.3478237>